

# Clustering und dessen Einsatz bei einer automatischen Fahrspurerkennung

---

STEFFEN SCHMID, WS 18/19

IT-DESIGNERS GMBH

HOCHSCHULE FURTWANGEN – FAKULTÄT INFORMATIK

# Gliederung

---

1. Hintergrund und Ziele der Masterarbeit
2. Grundlagen Clusteranalyse
3. Realisierung der Fahrspurerkennung
4. Ergebnisse der Fahrspurerkennung
5. Fazit

# 1. Hintergrund und Ziele der Arbeit

---

## Hintergrund

- Masterthesis im Rahmen des MEC-View Teilprojektes „Luftbeobachtung“
- Ziele des Projektes:
  - Auswertung von Luftaufnahmen des Straßenverkehrs (Fahrzeugpositionen, Geschwindigkeiten etc.)
  - Analyse des Fahrverhaltens der Verkehrsteilnehmer
  - Erstellung von Verkehrssimulationen

## Motivation und Ziele

- Automatische Erkennung von Fahrspuren in Luftaufnahmen
- Kenntnis der Fahrspuren ermöglicht genauere Untersuchung der Fahrverhalten
- Verzicht auf visuell gestützte Verfahren
- Erkennung der Spuren anhand von Trajektoriedaten

# 1. Hintergrund und Ziele der Arbeit

---

- Integration der Spurerkennung in die MEC-View „*Vehicle-Tracker*“ Anwendung
- Erkennung von Fahrspuren in unterschiedlichen Straßentopologien
  - Landstraßen
  - Autobahnen
  - Kreuzungen
  - Kreisverkehre
  - etc.

# 1. Hintergrund und Ziele der Arbeit

---




Abb. 1.1: Fahrspurdefinition mittels Trajektoriedaten

# 2. Grundlagen Clusteranalyse

---

- Methodik aus dem Gebiet Data-Mining / Machine Learning

*Gruppierung von Datenobjekten aufgrund ihrer Eigenschaften und Beziehungen, sodass sich die Objekte in einer Gruppe möglichst stark ähneln und sich von Objekten anderer Gruppen möglichst stark unterscheiden.*

- Ziele:
  - Datenverständnis
  - Identifikation von „Mustern“ in Daten
  - Weiterverarbeitung der einzelnen Cluster
- Einsetzbar in unterschiedlichsten Anwendungsgebieten
- Große Vielfalt an Clustering-Verfahren existiert

## 2. Grundlagen Clusteranalyse

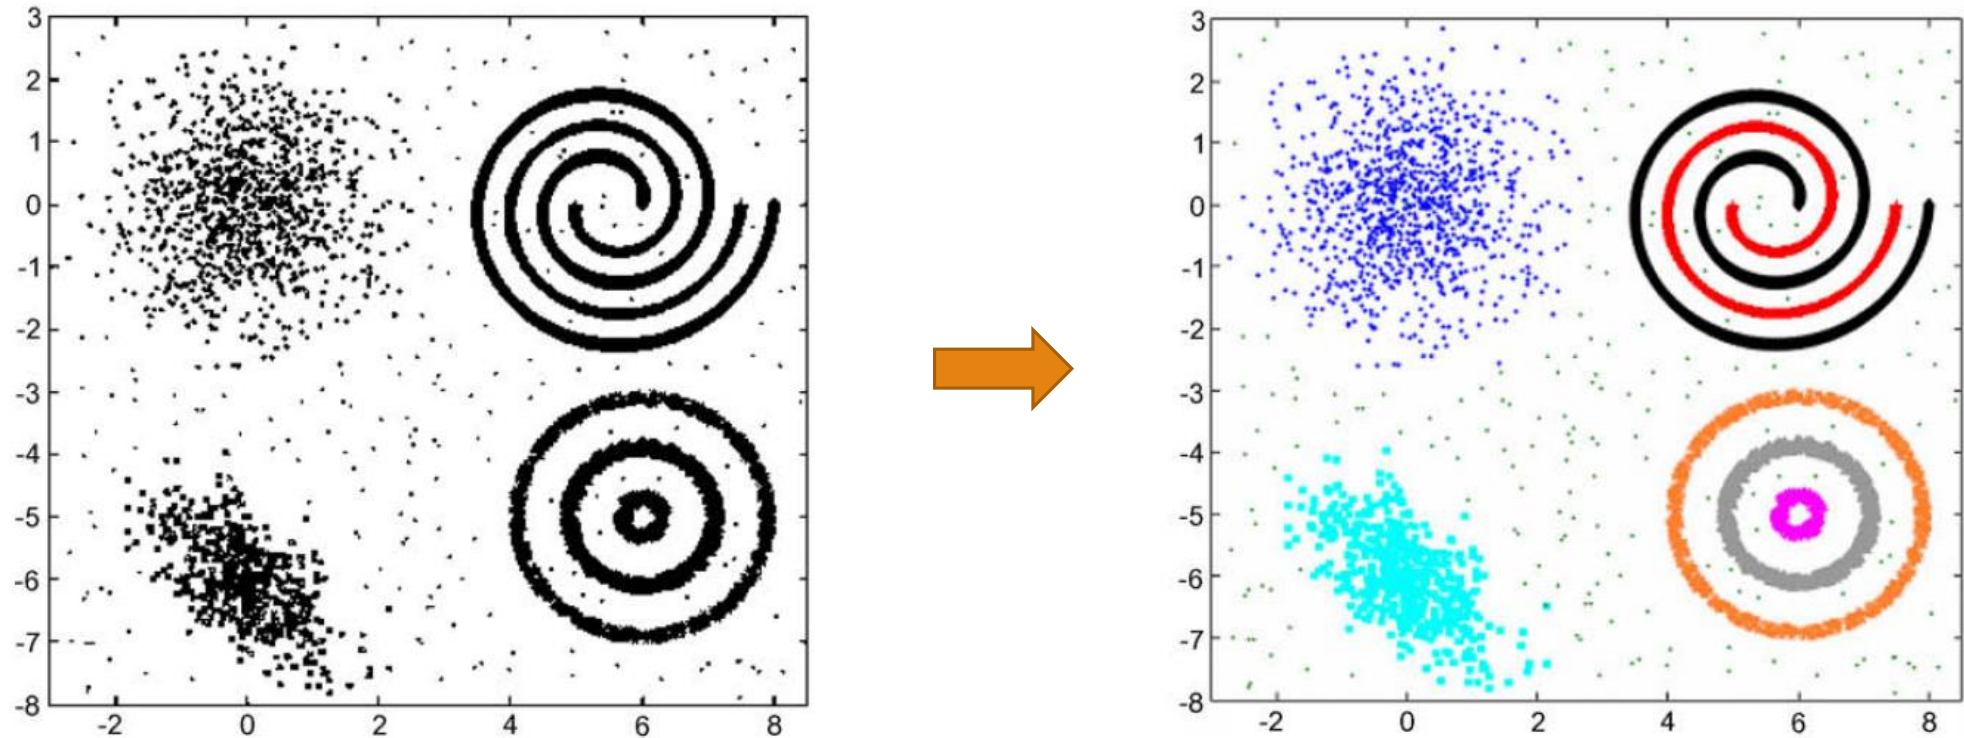


Abb. 2.1: Beispiel Cluster-Identifikation [1]

## 2. Grundlagen Clusteranalyse

### Ablauf einer Clusteranalyse

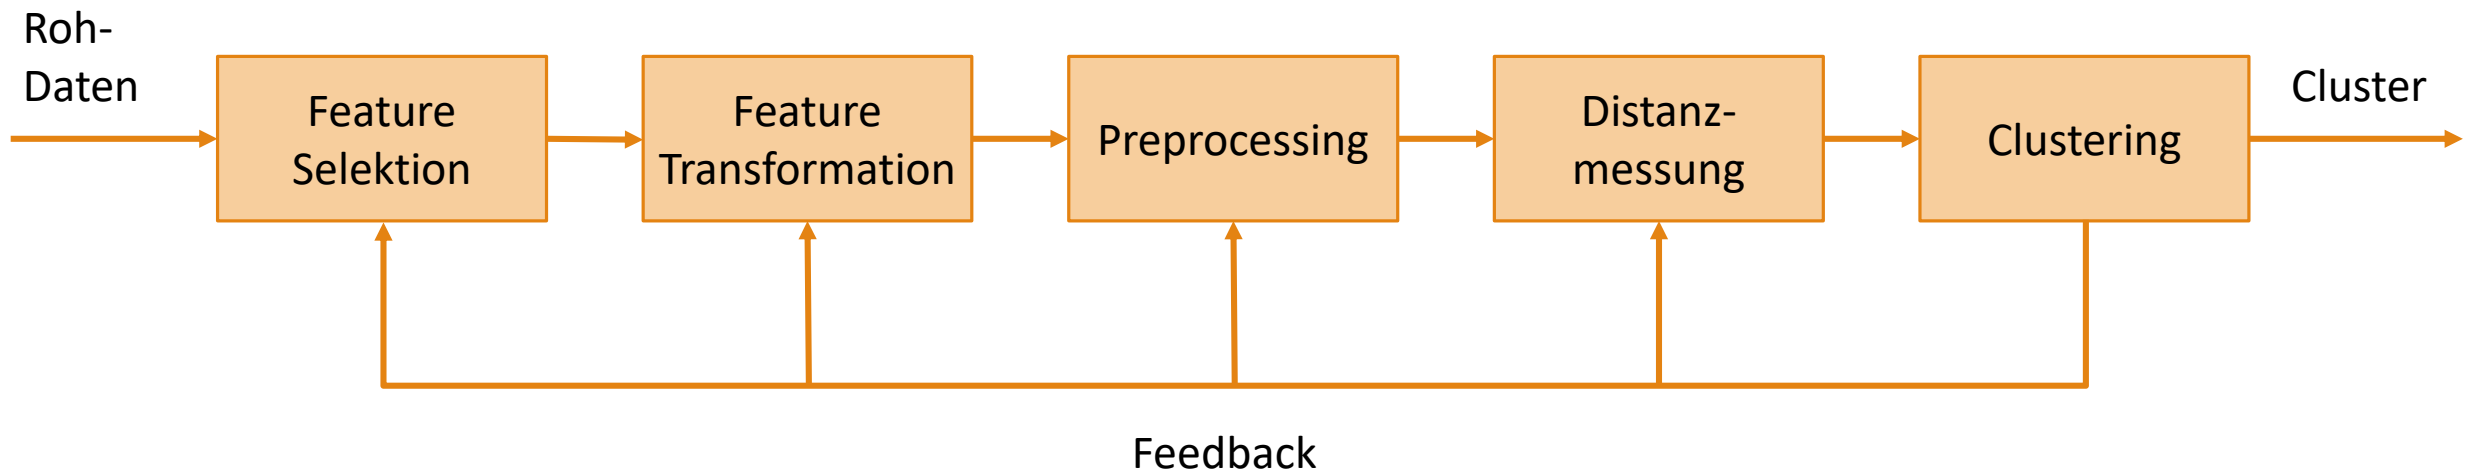


Abb. 2.2: Ablauf einer Clusteranalyse



# 2. Grundlagen Clusteranalyse

---

## Übersicht Clustering-Ansätze

- Vernetzungs-Modelle
  - Clusterbildung anhand von Distanz zwischen Objekten (z.B. *Agglomeratives Clustering*)
- Prototypen-Modelle
  - Clusterbildung anhand von Distanz von Objekten zu Prototypen (z.B. *k-Means Clustering*)
- Distributions-Modelle
  - Clusterbildung anhand statistischer Zugehörigkeit zu Wahrscheinlichkeitsverteilung (z.B. *EM Clustering*)
- Dichte-Modelle
  - Clusterbildung anhand von Regionen hoher Objektdichte (z.B. *DBSCAN Clustering*)

# 2. Grundlagen Clusteranalyse

---

## Distanzmaße

*Ein Distanz- oder Ähnlichkeitsmaß definiert zahlenmäßig wie „ähnlich“ beziehungsweise „unähnlich“ sich zwei Objekte sind.*

- Distanzmaß hat maßgeblichen Einfluss auf Ergebnis der Clusteranalyse
- Wahl abhängig von zu untersuchende Daten und Zielen

# 2. Grundlagen Clusteranalyse

---

## Herausforderungen

- Angemessene Datenvorbereitung und Vorverarbeitung
- Wahl eines passenden Cluster-Algorithmus
- Wahl eines passenden Distanzmaßes
- Optimale Parametrisierung
- Interpretation und Validierung der Ergebnisse

# 3. Realisierung der Fahrspurerkennung

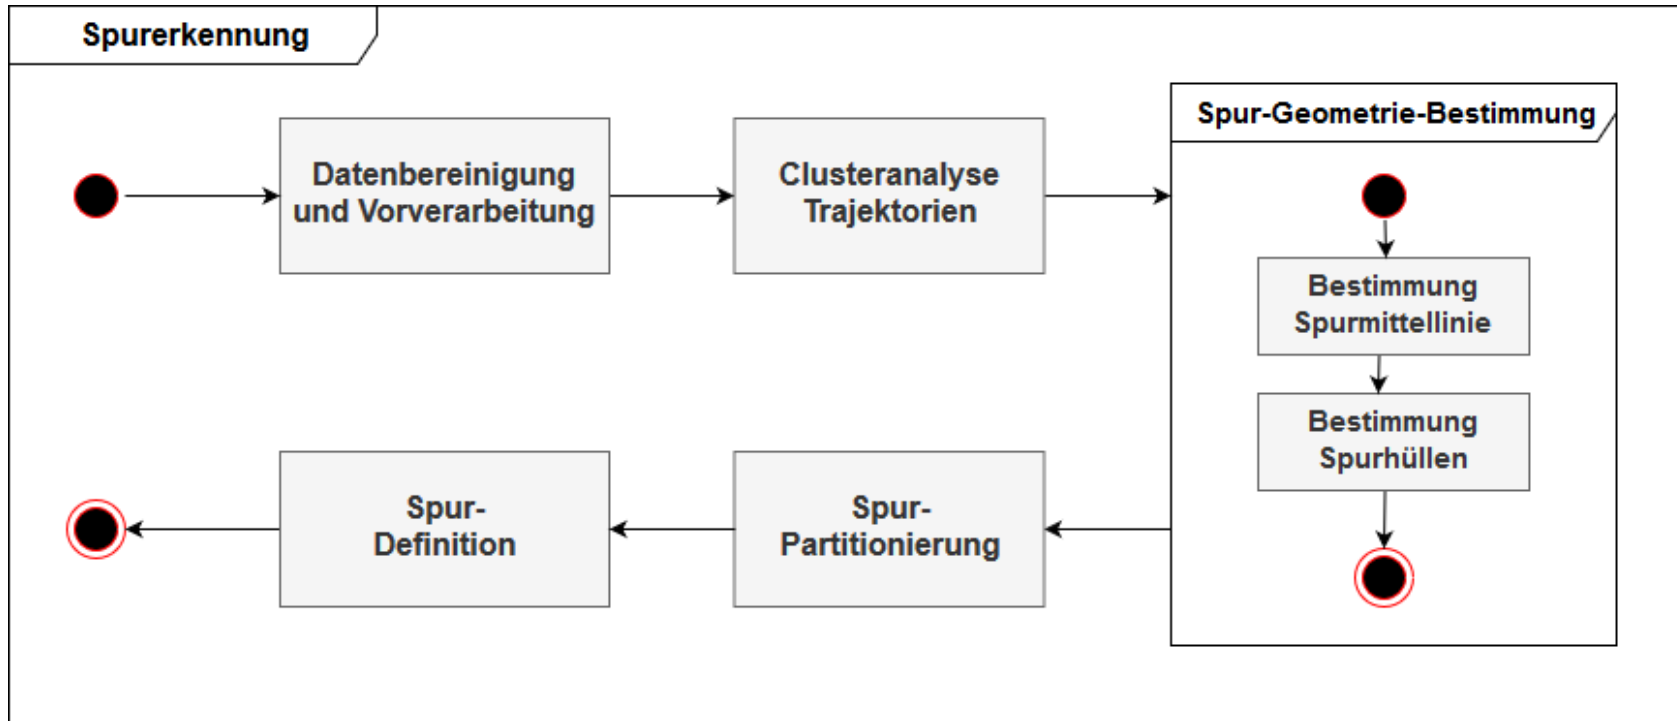


Abb. 3.1: Basisablauf der Spurerkennung

## 3.1 Vorverarbeitung der Trajektoriedaten

---




Abb. 3.2: Vorverarbeitung Trajektoriedaten

## 3.2 Clusteranalyse der Trajektorien

---

- Ziel: Identifikation von Spur-Clustern in Trajektoriedaten
- Gewählter Ansatz: DBSCAN Clusteralgorithmus und LCSS Distanzmaß
- Vorteile des Ansatzes:
  - Automatische Bestimmung der Clusteranzahl
  - Umgang mit Ausreißern
  - Vergleichsweise geringe, intuitive Parametrisierung
  - Gute Performance

## 3.2 Clusteranalyse der Trajektorien




Abb. 3.3: Clusteranalyse der Trajektorien

## 3.3 Bestimmung der Spur-Geometrien

---

- Spur-Geometrien werden aus Trajektorie-Clustern abgeleitet
- Aufbau Spur-Geometrie:
  - Mittellinie
  - Zwei Hüll-Linien




Abb. 3.4: Aufbau Spur-Geometrie



## 3.3 Bestimmung der Spur-Geometrien

### Bestimmung der Spur-Mittellinien




Abb. 3.5: Bestimmung der Spur-Mittellinien

# 3.3 Bestimmung der Spur-Geometrien

## Bestimmung der Spurhüllen




Abb. 3.6: Bestimmung der Spur-Hüllen

## 3.4 Partitionierung der Spuren

---




Abb. 3.7: Partitionierung der Spur-Geometrien

# 4. Ergebnisse der Fahrspurerkennung

---



Abb. 4.1: Fahrspuren Datensatz *Neckartor*



## 4. Ergebnisse der Fahrspurerkennung

---




Abb. 4.2: Fahrspuren Datensatz *Entennest*

## 4. Ergebnisse der Fahrspurerkennung

---



Abb. 4.3: Fahrspuren Datensatz *Düsseldorf*



## 4. Ergebnisse der Fahrspurerkennung

---




Abb. 4.4: Fahrspuren Datensatz *Heilbronner-Straße*



## 4. Ergebnisse der Fahrspurerkennung

---



Abb. 4.5: Fahrspuren Datensatz *Steinheim*



# 5. Fazit

---

- Clusteranalysen können in den unterschiedlichsten Anwendungsgebieten eingesetzt werden
- Qualität der Clustering-Ergebnisse hängt von vielen Faktoren ab
- Qualität der Spurerkennung auch maßgeblich abhängig von Clusteranalyse

# Fragen

---

# Quellen und Referenzen

---

- **[1]:** JAIN, Anil K. Data clustering: 50 years beyond K-means. *Pattern recognition letters*, 2010, 31. Jg., Nr. 8, S. 651-666.
- MEC-View Projektwebseite: <http://mec-view.de/>