



Masterarbeit
im Studiengang
Informatik

Fahrspurerkennung in Luftaufnahmen mittels Fahrzeugtrajektorien

Prüfer: Prof. Dr. Christoph Reich
Zweitprüfer: Dr. Stefan Kaufmann
Firma: IT-Designers GmbH
Vorgelegt am: 11. Februar 2019
Vorgelegt von: Steffen Schmid
257721
Robert-Gerwig-Platz 1
78120 Furtwangen
steffen.schmid@hs-furtwangen.de

Abstract

In this thesis a method for automatic detection of driving lanes in aerial photographs based on trajectory data was developed. The work was created in the context of the MEC-View research project, which is funded by the german Federal Ministry of Economics and Energy (BMWi). In this project, among other things, the driving behavior of vehicles is being investigated using aerial observations. Lane informations are important because they are required in the analysis of overtaking and lane change maneuvers. The insights gained from traffic analyses will be used in the MEC-View project to optimize the driving behavior of autonomous vehicles in the future.

The method developed in the scope of this work can recognize lanes on roads with differently complex lane topologies. The algorithmically defined track geometries usually correspond very well to the real lane profiles. In these respects, the procedure developed goes beyond the approaches for lane identification presented so far in the related work. The lane recognition algorithm uses a cluster analysis and a newly developed, multi-stage procedure to derive lane geometries from trajectory data.

In an evaluation, the strengths and weaknesses of the developed track detection method were determined. It was shown that this method can reliably identify lanes in most of the aerial photographs examined. The primary requirement for this is that each lane of an examined road section is described by a sufficient number of intact trajectories.

The developed Lane recognition approach has been integrated into the *Vehicle-Tracker* application, which is used in the MEC-View subproject “Air Observation” for the analysis of traffic. Thanks to the automatic lane recognition, aerial photographs of road traffic can be evaluated more quickly in the future.

Kurzfassung

In dieser Arbeit wurde ein Verfahren zur automatischen Erkennung von Fahrspuren in Luftaufnahmen auf Basis von Trajektoriedaten entwickelt. Umgesetzt wurde die Thesis im Rahmen des vom BMWi geforderten Forschungsprojekt MEC-View, in welchem unter anderem das Fahrverhalten von Fahrzeugen anhand von Luftbeobachtungen untersucht wird. Fahrspurinformationen sind für solche Analysen wichtig, da nur mit ihnen beispielsweise Überhol- oder Spurwechselvorgänge untersucht werden können. Die Erkenntnisse, welche aus Verkehrsanalysen gewonnen werden, sollen im MEC-View Projekt in Zukunft zur Optimierung des Fahrverhaltens von autonomen Fahrzeugen eingesetzt werden.

Das im Rahmen dieser Arbeit entwickelte Verfahren kann Fahrspuren auf Straßen mit unterschiedlich komplexen Fahrbahnverläufen vollautomatisch erkennen. Die algorithmisch definierten Spur-Geometrien stimmen meist sehr gut mit den realen Fahrspurverläufen überein. In diesen Punkten geht das entwickelte Verfahren über die bislang von den verwandten Arbeiten vorgestellten Ansätze zur Fahrspuridentifikation hinaus. Der Spurerkennungsalgorithmus nutzt eine Clusteranalyse und ein neu entwickeltes, mehrstufiges Verfahren zur Ableitung von Fahrspur-Geometrien aus Trajektoriedaten.

In einer Evaluation wurden die Stärken und Schwächen des entwickelten Spurerkennungsverfahrens ermittelt. Es zeigte sich, dass dieses in den untersuchten Luftaufnahmen Fahrspuren meist sehr zuverlässig identifizieren kann. Primäre Anforderung hierfür ist, dass jede Fahrspur eines untersuchten Straßenabschnitts von ausreichend vielen intakten Trajektorien beschrieben wird.

Die Spurerkennung wurde in die Anwendung *Vehicle-Tracker* integriert, welche im MEC-View Teilprojekt "Luftbeobachtung" zur Analyse des Verkehrs eingesetzt wird. Dank der automatischen Spurerkennung können in Zukunft Luftaufnahmen des Straßenverkehrs schneller und mit einem höheren Automatisierungsgrad ausgewertet werden.

Danksagung

An dieser Stelle möchte ich mich bei allen Personen bedanken, die mit ihrer tatkräftigen Unterstützung zum Gelingen dieser Masterarbeit beigetragen haben.

Ganz besonders gilt dieser Dank meinen beiden Betreuern Herrn Prof. Dr. Christoph Reich von der Hochschule Furtwangen und Herrn Dr. Stefan Kaufmann von der Firma IT-Designers GmbH, welche mich sehr unterstützt haben und immer für Fragen zur Verfügung standen. Vielen Dank für die aufgebrachte Zeit und die guten Ratschläge.

Des Weiteren gilt mein Dank der Firma IT-Designers GmbH, welche mir diese Arbeit ermöglicht hat und durch eine tolle Arbeitsatmosphäre zu ihrem Gelingen beigetragen hat.

Schlussendlich möchte ich mich noch bei meiner Familie bedanken, welche mich während meines kompletten Studiums unterstützt und motiviert hat.

Inhaltsverzeichnis

Abstract	iii
Kurzfassung	v
Abkürzungsverzeichnis	xv
1 Einleitung	1
1.1 Rahmen der Arbeit	2
1.1.1 Das Projekt MEC-View	2
1.1.2 Das MEC-View Teilprojekt Luftbeobachtung	3
1.2 Motivation und Ziele	3
1.3 Aufbau dieser Arbeit	4
2 Rekonstruktion von Fahrzeugtrajektorien aus Luftaufnahmen	7
2.1 Erkennung und Verfolgung von Fahrzeugen in Videoaufnahmen	7
2.1.1 Fahrzeug-Detektion	8
2.1.2 Fahrzeugverfolgung	9
2.2 Positionsbestimmung in Videoaufnahmen	9
2.3 Herausforderungen bei der Rekonstruktion von Fahrzeugtrajektorien	12
3 Clusteranalysen	15
3.1 Cluster-Sets und Cluster	17
3.1.1 Eigenschaften von Cluster-Sets	17
3.1.2 Eigenschaften von Clustern	18
3.2 Clusteralgorithmen	19
3.2.1 Vernetzungsmodelle	20
3.2.2 Prototyp-Modelle	21
3.2.3 Verteilungsmodelle	23
3.2.4 Dichtemodelle	24
3.3 Distanzmaße zum Vergleich von Fahrzeugtrajektorien	26
3.3.1 HU-Distanz	27
3.3.2 Hausdorff-Distanz	27
3.3.3 Longest-Common-Subsequence	28
3.3.4 Wahl eines Distanzmaßes	29

4 Verwandte Arbeiten	31
4.1 Clusteranalyse von Trajektorien	31
4.2 Erkennung und Definition von Fahrspuren	37
4.3 Defizite vorhandener Lösungen und benötigte Neuerungen	42
5 Konzeption des Spurerkennungs-Moduls	45
5.1 Überblick über das Gesamtsystem	45
5.2 Anforderungen an die Spurerkennung	46
5.2.1 Funktionale Anforderungen	46
5.2.2 Nicht funktionale Anforderungen	47
5.3 Entwurf des Moduls	47
6 Realisierung der Fahrspurerkennung	49
6.1 Repräsentation und Vorverarbeitung der Trajektoriedaten	49
6.1.1 Trajektorie-Repräsentation	49
6.1.2 Vorverarbeitung der Trajektorien	52
6.2 Clusteranalyse der Trajektorien	55
6.2.1 Ansatz Spectral-Clustering und modifizierte Hausdorff-Distanz . . .	55
6.2.2 Ansatz DBSCAN und LCSS	59
6.2.3 Erkennung von Abbiegespuren	62
6.2.4 Automatische Parametrisierung der Clusteranalyse	65
6.3 Spur-Geometrie Bestimmung	67
6.3.1 Ausfilterung von Spurwechselvorgängen	67
6.3.2 Bestimmung der Spurmittellinien	69
6.3.3 Angleichung benachbarter Spurenden	71
6.3.4 Bestimmung der Spurhüllen	72
6.3.5 Partitionierung von Fahrspuren	77
6.3.6 Optimierung der Spur-Geometrien	81
6.3.7 Anlegen der Fahrspuren in der Anwendung Vehicle-Tracker	83
7 Auswertung und Ergebnisse	85
7.1 Evaluierung der Datenvorverarbeitung	85
7.2 Evaluierung der Clusteranalyse	87
7.3 Evaluierung der Spur-Geometrie-Bestimmung	89
7.4 Ergebnisse der Spurerkennung	91
8 Zusammenfassung und Ausblick	95
8.1 Ergebnisse dieser Arbeit	95
8.2 Ausblick	96
Literaturverzeichnis	97
A Anhang - Verwendete Datensätze	105

Abbildungsverzeichnis

1.1	Überblick MEC-View Projekt	2
2.1	Aufbau eines CNN	8
2.2	Bildprojektion im Lochkameramodell	10
2.3	False-Positive Detektionen	13
2.4	Fahrbahn Verdeckung	13
2.5	Fahrzeug-Detektion bei niedrigem Aufnahmewinkel	14
3.1	Rohdaten und erwünschtes Clustering-Ergebnis	16
3.2	Ablauf einer Clusteranalyse	16
3.3	Visualisierung verschiedener Clusterarten	19
3.4	Darstellung Funktionsweise Agglomeratives Clustering	20
3.5	Funktionsweise k-Means Clusteralgorithmus	22
3.6	Funktionsweise des EM-Clusteralgorithmus	24
3.7	Schritte des DBSCAN Algorithmus	25
3.8	Konzept Erreichbarkeit in DBSCAN	25
3.9	Trajektorien im zwei-dimensionalen Raum	26
4.1	Zweistufiger Clustering-Vorgang von Hu et al.	32
4.2	Funktionsweise der modifizierten Hausdorff-Distanz	33
4.3	Zerlegung einer Trajektorie in Sub-Trajektorien (Chen et al.)	34
4.4	Verschiebung einer Trajektorie im Raum	35
4.5	Ergebnisse Spurmittellinien-Erkennung (Ren et al.)	37
4.6	Spurhüllen in Hu et al.	38
4.7	Routen-Definition und Ergebnisse Routen-Erkennung (Makris et al.)	39
4.8	Referenztrajektorien und Pfade (Morris et al.)	40
4.9	Ergebnisse Histogramm Erstellung und Spurextraktion (Hsieh et al.)	42
5.1	Kontext des Moduls Spurerkennung	45
5.2	Basis-Ablauf des Spurerkennungsalgorithmus	47
6.1	Erkannte Fahrzeuge und deren Front-Positionen	50
6.2	Aufbau Trajektorie-Klasse	50
6.3	Stuttgarter Neckartor und rekonstruierte Trajektorien	51
6.4	Beispiel Defekte in Trajektoriedaten	52
6.5	Ergebnisse der zwei ersten Vorverarbeitungsschritte	54
6.6	Konzept Identifikation von unterbrochenen Trajektorien	55

6.7	Ergebnisse Clusteranalyse Ansatz Atev et al.	58
6.8	Ergebnisse Clusteranalyse Ansatz DBSCAN und LCSS-Distanz	62
6.9	Abbiegespur Neckartor Kreuzung	63
6.10	Ergebnis Clusteranalyse inklusive Abbiegespur-Cluster	64
6.11	Ergebnis Clusteranalyse Düsseldorf Datensatz	65
6.12	Weg-Zeit-Diagramme mit und ohne Trajektorie-Schnittpunkten	66
6.13	Trajektorie-Cluster mit Spurwechselvorgängen	68
6.14	Bereinigte Trajektorie-Cluster ohne Spurwechselvorgänge	69
6.15	Ergebnisse Spurmittellinien-Bestimmung	70
6.16	Konzept Spurenden-Angleichung	71
6.17	Ergebnis Spurenden-Angleichung	72
6.18	Konzept Bestimmung Spürhüllen	73
6.19	Aufbau LaneGeometry Klasse	73
6.20	Konzept Berechnung Spurhüllpunkte	75
6.21	Ergebnisse Spur-Geometrie-Bestimmung	76
6.22	Beispiele Pseudo-Spur-Geometrien	76
6.23	Primäre und Sekundäre Spur-Geometrien einer Kreuzung	78
6.24	Überlagerung zweier Spur-Abschnitte	79
6.25	Ergebnisse Spur-Partitionierung	81
6.26	Beispiel zu schmale Spur-Geometrien	81
6.27	Ergebnis Spur-Optimierung	82
6.28	Datenmodell der Fahrspurdefinition	83
7.1	Ergebnis Trajektorie-Vorverarbeitung der Heilbronner-Straße	85
7.2	Straßenabschnitt Datensatz Steinheim	86
7.3	Ergebnis Trajektorie-Cluster der Heilbronner-Straße	87
7.4	Ergebnisse Test Clusteranalyse auf Neckartor Datensatz	88
7.5	Ergebnisse Clusteranalyse Steinheim	89
7.6	Ergebnisse der Spur-Geometrie-Bestimmung	90
7.7	Partitionierungsproblem in den Spur-Geometrien	91
7.8	Erkannte Fahrspuren auf geraden Straßenabschnitten	92
7.9	Erkannte Fahrspuren auf Kreuzungen	92
7.10	Erkannte Fahrspuren auf kreisförmigen Fahrbahnen	93

Listings

6.1	Pseudocode Trajektorie Resampling	53
6.2	Pseudocode LCSS Bestimmung	60
6.3	Pseudocode Split-Punkt Bestimmung	64
6.4	Pseudocode Cluster Post-Processing	68
6.5	Pseudocode Mittellinien-Bestimmung	70
6.6	Pseudocode Überprüfung der Parallelität zweier Mittellinien	74
6.7	Pseudocode Identifikation Spurwechsel-Spur	77
6.8	Pseudocode Auswahl zu partitionierende Fahrspur	80

Wichtige Definitionen

1	Trajektorie	7
2	Clusteranalyse	15
3	Distanzmaß	15

Abkürzungsverzeichnis

BMWi	Bundesministerium für Wirtschaft und Energie
CNN	Convolutional Neural Network
CV	Computer Vision
DBSCAN	Density-based spatial clustering of applications with noise
DTW	Dynamic Time Warping
EM	Expectation-Maximization
GMM	Gaussian-Mixture-Model
HMM	Hidden Markov Model
LCSS	Longest Common Subsequence
MEC	Mobile Edge Computing
ML	Machine Learning
RAA	Richtlinien für die Anlage von Autobahnen
RAL	Richtlinien für die Anlage von Landstraßen
ROI	Region of Interest
UAV	Unmanned Aerial Vehicle

1 Einleitung

Staus und zäh fließender Verkehr sind sowohl auf Schnell- und Autobahnen, als auch in Städten ein großes Problem und Ärgernis für Autofahrer. Sie kosten diese nicht nur wertvolle Zeit, sondern auch viel Geld. Laut einer Studie von [Cookson et al., 2017] kosten Staus jeden deutschen Autofahren pro Jahr durchschnittlich 1770 €. In Summe ergeben sich hieraus beinahe 80 Milliarden Euro an Kosten. Staus sind allerdings nicht nur finanziell für Privatpersonen oder Unternehmen ein Problem, sondern sie erhöhen auch das Unfallrisiko und tragen maßgeblich zur schlechten Luftqualität in Innenstädten bei. Aufgrund längerer Fahrzeiten und der häufigen Be- und Entschleunigung, steigt der Kraftstoffverbrauch der Fahrzeuge und dadurch auch die Schadstoffbelastung in der Luft [Hemmerle, 2016].

Die wichtigste Voraussetzung, um Staus präventiv entgegenwirken zu können, ist, den Verkehr so gut wie möglich zu verstehen. Nötig ist ein Verständnis des Straßenverkehrs als Ganzes, sowie der Auswirkungen, welche einzelne Verkehrsteilnehmer und deren Verhalten, auf diesen haben. Hierzu ist das Erstellen von Simulationen sowie die Auswertung realer Verkehrsaufkommen in Analysen unerlässlich. Die auf diese Weise gesammelten Erkenntnisse bilden die Grundlage, um Straßenabschnitte und Infrastrukturanlagen wie Ampeln, insbesondere auch in Innenstädten, intelligent zu gestalten. In Zukunft könnten auch autonome Fahrzeuge von Erkenntnissen aus Verkehrsanalysen profitieren.

Dank der Tatsache, dass unbemannte Luftfahrzeuge (UAV) wie Drohnen immer leichter und günstiger verfügbar sind, und die von ihnen erstellten Aufnahmen teils eine sehr gute Qualität besitzen, werden diese immer häufiger zur Analyse des Straßenverkehrs eingesetzt. Über Methoden aus dem Umfeld des maschinellen Sehens und maschinellen Lernens, kann aus Luftaufnahmen eine Vielzahl an interessanter Informationen extrahiert werden.

Diese Arbeit beschäftigt sich mit der Realisierung einer automatischen Fahrspurerkennung in Luftaufnahmen. Hierzu werden die Trajektoriedaten von Fahrzeugen ausgewertet, welche aus Luftaufnahmen rekonstruiert wurden. Die Analyse von Verkehrssituationen wird, aufgrund der oben genannten Probleme und der zunehmenden Relevanz des autonomen Fahrens, immer wichtiger. Eine automatisierte Spurerkennung ist ein wichtiger Teil des Analyseprozesses, da mit Hilfe der erkannten Spuren unter anderem Spurwechsel- und Überholvorgänge sowie das Verhalten der Fahrzeuge auf einer Spur untereinander untersucht werden können.

1.1 Rahmen der Arbeit

Diese Masterarbeit wurde im Rahmen des Forschungsprojektes MEC-View umgesetzt. Das Projekt und dessen Teilprojekt Luftbeobachtung wird nachfolgend vorgestellt.

1.1.1 Das Projekt MEC-View

Das Forschungsprojekt MEC-View, welches vom Bundesministerium für Wirtschaft und Energie (BMWi) gefordert wird, hat das Ziel, autonomes Fahren im urbanen Raum zu ermöglichen und für alle Verkehrsteilnehmer sicher zu gestalten. Gerade in Innenstädten sind die Möglichkeiten des autonomen Fahrens, aufgrund von unübersichtlichen Kreuzungen, Fußgängern und Fahrradfahrern, verdeckten Sichten und anderen Faktoren, begrenzt. Abbildung 1.1 gibt einen Überblick über das Forschungsprojekt und veranschaulicht dessen Ziel.

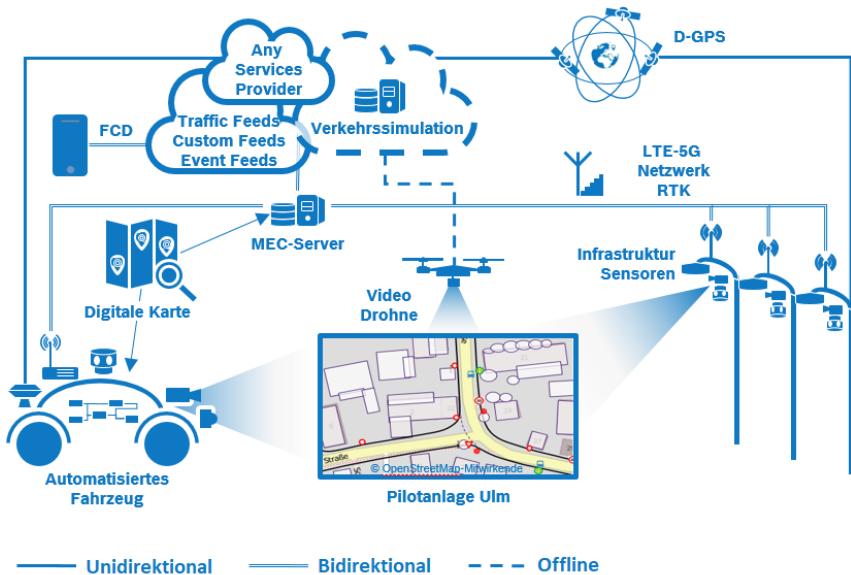


Abbildung 1.1: Überblick MEC-View Projekt [MEC-View, 2018]

In urbanen Gebieten sollen neben Daten von fahrzeuginternen Sensoren auch Informationen externer Infrastruktur-Sensoren verwendet werden, damit autonome Fahrzeuge eine fundierte Verhaltensentscheidung auf Basis eines detaillierten Umfeldmodells treffen können. Im Rahmen des Forschungsprojektes MEC-View wird eine Pilot-Anlage zur Umfelderfassung an einer vorfahrtberechtigten Straßenkreuzung in Ulm aufgebaut und getestet. In dieser Anlage werden die Verkehrsteilnehmer über Kameras und LIDAR-Sensoren erfasst und die ermittelten Daten über ein schnelles LTE/5G-Mobilfunknetz an einen *Mobile Edge Computing* (MEC) Server übertragen. Hier werden die Daten in Echtzeit zu einem Umfeldmodell fusioniert, welches anschließend den autonomen Fahrzeugen zur besseren

Navigation zur Verfügung gestellt wird. Beteiligt an diesem Forschungsprojekt sind neben der IT-Designers GmbH unter anderem auch die Daimler AG, die Robert Bosch GmbH, Osram, Nokia und die Universität Ulm. Jeder Projektpartner ist verantwortlich für unterschiedliche Teilespekte des Projektes. Die IT-Designers GmbH, bei welcher diese Arbeit angefertigt wird, entwickelt den MEC-Server und ist verantwortlich für das Teilprojekt *Luftbeobachtung*. [MEC-View, 2018]

1.1.2 Das MEC-View Teilprojekt Luftbeobachtung

Im MEC-View Teilprojekt *Luftbeobachtung* werden Verkehrsanalysen und Simulationen erstellt, welche dabei helfen das Verhalten des Verkehrs besser zu verstehen und es somit ermöglichen, diesen zu optimieren. Mithilfe der Analysen kann beispielsweise untersucht werden, wie durch die Anpassung von Verkehrssteuerungsanlagen oder durch die Änderung des Fahrverhaltens einzelner Fahrzeuge, eine Verbesserung der Verkehrssituation erreicht werden kann. Die Erkenntnisse können insbesondere auch in die Verhaltenssteuerung von autonomen Fahrzeugen mit einfließen. Aus diesem Grund sind entsprechende Untersuchungen auch für das MEC-View Hauptprojekt relevant.

Die Untersuchungen werden im MEC-View Projekt anhand von Luftbeobachtungen durchgeführt, welche von Drohnen getätigt werden. In den Videoaufnahmen werden mithilfe eines neuronalen Netzes die Positionen und Fahrzeugklassen der Verkehrsteilnehmer ermittelt. Mittels dieser kann anschließend beispielsweise die Geschwindigkeit und Beschleunigung der einzelnen Fahrzeuge bestimmt werden. Zur Erstellung der Analysen ist es zudem wichtig, eine Kenntnis der Topologie der untersuchten Straßen, das heißt des Verlaufs der Fahrbahnen und Spuren, zu besitzen. In Kombination mit den Fahrzeugpositionen können so interessante Kenngrößen wie der Verkehrsfluss oder die Verkehrsdichte ermittelt werden.

1.2 Motivation und Ziele

Im Rahmen dieser Arbeit wird ein Verfahren zur automatischen Erkennung von Fahrspuren in Luftaufnahmen auf Basis von Trajektoriedaten entwickelt. Die Spurerkennung wird in die Anwendung *Vehicle-Tracker* integriert, welche im Rahmen des MEC-View Luftbeobachtungs Projekt erstellt wird. Sie dient der Auswertung von Luftbeobachtungen des Straßenverkehrs. In der *Vehicle-Tracker* Applikation mussten bislang die Fahrspurverläufe in jeder Aufnahme händisch definiert werden. Dieser Prozess ist insbesondere dann aufwendig, wenn die zu untersuchenden Straßenabschnitte beispielsweise mehrspurige Kreuzungen oder Kreisverkehre beinhalten. Das in dieser Arbeit entwickelte Spurerkennungs-Modul soll die manuelle Spur-Definition weitestgehend ersetzen und es so ermöglichen in Zukunft mehr Luftaufnahmen mit weniger Aufwand auszuwerten.

Der Verlauf und die Geometrie der Fahrspuren wird in dieser Thesis anhand der Bewegungsbahnen von Fahrzeugen, den sogenannten Trajektorien, ermittelt. Im Gegensatz zu einer visuellen Detektierung hat das Verfahren den Vorteil, dass Fahrspuren auch in Aufnahmen mit schlechten Lichtverhältnissen oder Verdeckungen der Fahrbahnen und Spurmarkierungen erkannt werden können.

Zum Thema Spurerkennung existieren zwar bereits Veröffentlichungen (siehe Abschnitt 4.2), allerdings können die vorgestellten Methoden meist nur in sehr speziellen Szenarien eingesetzt werden oder die erkannten Spuren entsprechen den realen Fahrspurverläufen nur schlecht. Ziel dieser Arbeit ist es, ein Verfahren zu entwickeln, welches Fahrspuren in möglichst vielen unterschiedlichen Szenarien erkennen kann. Die Spuren sollen außerdem den realen Fahrbahnverläufen so gut wie möglich entsprechen.

1.3 Aufbau dieser Arbeit

Die vorliegende Arbeit ist wie folgt strukturiert:

- Die zum Verständnis der Arbeit und des entwickelten Spurerkennungsalgorithmus benötigten Grundlagen sind in **Kapitel 2 und 3** beschrieben. Kapitel 2 erläutert, wie aus Luftaufnahmen die Trajektorien von Fahrzeugen rekonstruiert und in ein Weltkoordinatensystem überführt werden können. Kapitel 3 stellt die grundlegenden Konzepte der Clusteranalyse vor, welche bei der Umsetzung der Spurerkennung zum Einsatz kommt.
- In **Kapitel 4** werden verwandte Arbeiten, welche sich bereits mit der Thematik der Spurerkennung und der Clusteranalyse von Trajektorien befassen, vorgestellt und untersucht. Zudem werden Defizite der vorhandenen Lösungen und benötigte Neuerungen aufgezeigt.
- In **Kapitel 5** wird das Konzept für die Umsetzung der Spurerkennung vorgestellt. Es werden Anforderungen definiert und das Spurerkennungs-Modul wird in den Gesamtkontext der Applikation *Vehicle-Tracker* eingeordnet.
- Nach der Konzeption wird in **Kapitel 6** erläutert, wie die Spurerkennung in dieser Arbeit umgesetzt wurde. Es werden die verschiedenen Schritte des entwickelten Algorithmus vorgestellt.
- In **Kapitel 7** wird der Spurerkennungsalgorithmus evaluiert. Es wird auf die Stärken und Schwächen der wichtigsten Verarbeitungsschritte des Algorithmus eingegangen. Außerdem werden konkrete Ergebnisse in Form von Screenshots der erkannten Fahrspuren vorgestellt.

- **Kapitel 8** bildet den Schluss dieser Masterarbeit. Hier werden die Ergebnisse der Arbeit nochmals zusammengefasst und es wird ein Ausblick gegeben, in welchen Anwendungsgebieten die Spurerkennung in Zukunft eingesetzt werden kann und welche Verbesserungen an dem entwickelten Verfahren noch vorgenommen werden können.
- Im **Anhang** dieser Arbeit sind Aufnahmen der Straßenabschnitte dargestellt, mit deren Hilfe der Spurerkennungsalgorithmus entwickelt und evaluiert wurde.

2 Rekonstruktion von Fahrzeugtrajektorien aus Luftaufnahmen

In diesem Kapitel wird erläutert, wie aus Luftaufnahmen Trajektorien von Fahrzeugen rekonstruiert werden können.

Definition 1 (Trajektorie). *Eine Trajektorie beschreibt die Bewegungsbahn eines Objektes durch den Raum. In der Regel wird sie als Sequenz von Punkten in einem n -dimensionalen Koordinatensystem dargestellt. Alternative Darstellungen unter Verwendung von Richtungsvektoren oder des zusätzlichen Einbezugs von Geschwindigkeitsinformationen et cetera sind ebenso möglich.*

Trajektorien sind grundsätzlich die wichtigste Informationsquelle bei der Analyse des Fahrverhaltens aus Luftbeobachtungen. Eine Rekonstruktion von Fahrzeugtrajektorien wird im Rahmen dieser Arbeit nicht umgesetzt, allerdings ist es wichtig ein Grundverständnis der hierzu benötigten Methoden und Schritte zu besitzen, um die Trajektoriedaten und die darin enthaltenen Defekte interpretieren zu können.

Nachfolgend wird beschrieben, wie Fahrzeuge in Videoaufnahmen erkannt und verfolgt werden können, um anschließend deren Positionen in einem Weltkoordinatensystem zu bestimmen. Am Ende des Kapitels werden einige Herausforderungen, welche bei der Rekonstruktion der Trajektorien auftreten, aufgezeigt.

2.1 Erkennung und Verfolgung von Fahrzeugen in Videoaufnahmen

Es existieren unterschiedliche Ansätze, welche zur Erkennung und Verfolgung von Fahrzeugen in Videoaufnahmen eingesetzt werden können.

Ein Verfahren, welches gute Ergebnisse liefern kann, aber mit einem nicht unerheblichen manuellen Aufwand verbunden ist, ist das *Supervised-Tracking*. Hierbei werden initial manuell ausgewählte Bildbereiche, sogenannte *Region of Interests* (ROIs), automatisch mithilfe eines erlernten Klassifikators verfolgt. Dieser Klassifikator muss zwischen Fahrzeugen und ihrer Umgebung unterscheiden können [Grabner et al., 2006]. Der Supervised-Tracking Ansatz entspricht, aufgrund der notwendigen manuellen Detektion von Fahrzeugen, nicht mehr dem aktuellen Stand der Technik.

Modernere Verfahren detektieren Fahrzeuge in Videoaufnahmen vollautomatisch und nutzen einen separaten Tracking-Schritt, um anhand der Einzeldetections Trajektorien zu erstellen. Ein solcher zweistufiger Ansatz wird auch in der Anwendung *Vehicle-Tracker* eingesetzt. Er wird nachfolgend in groben Zügen beschrieben.

2.1.1 Fahrzeug-Detektion

In der Detektionsphase werden die Positionen der Fahrzeuge in der Videoaufnahme ermittelt. Üblicherweise wird die Detektion für jedes Frame des Videos ausgeführt. Erkannt werden die Fahrzeuge in der Anwendung *Vehicle-Tracker* mithilfe von Tensorflow¹. Das quelloffene Machine-Learning Framework bietet in seiner *Object Detection API* verschiedene Netzwerk-Architekturen und vortrainierte Modelle an, welche zur Erkennung und Klassifizierung von Objekten eingesetzt werden können [Huang et al., 2018]. Die angebotenen neuronalen Netze sind Weiterentwicklungen von *Convolutional Neural Networks* (CNNs), welche sich gut zur maschinellen Verarbeitung von Bilddaten eignen.

In Abbildung 2.1 ist der Aufbau eines CNN dargestellt. Ein genaues Verständnis der Funktionsweise eines solchen Netzwerks ist im Fall dieser Arbeit nicht notwendig. Grundlegend besteht es allerdings aus zwei Komponenten: Der erste Teil ist für die *Merkmal-Extraktion* verantwortlich, während der zweite Teil der *Klassifizierung* dient. In der ersten Phase extrahiert das Netzwerk aus einem Bild Merkmale, mittels welcher die zu erkennenden Objekte beschrieben werden können. Nach welchen Kriterien in einem Bild gesucht wird, wird während der Trainingsphase des Netzes ermittelt. Anhand der Merkmale werden die Positionen der gesuchten Objekte im Bild bestimmt. Um welches Objekt es sich an einer bestimmten Position handelt, wird anschließend vom sogenannten *Fully-Connected-Layer* ermittelt. [Cornelisse, 2018]

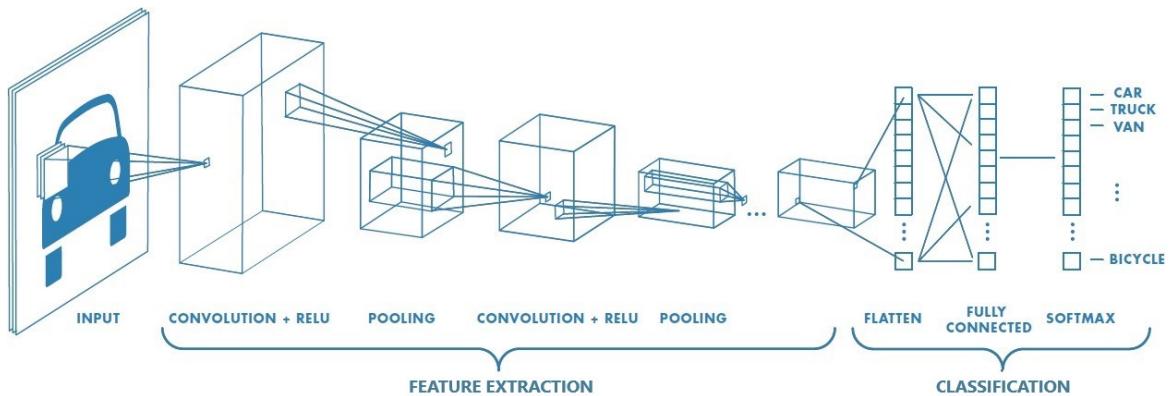


Abbildung 2.1: Aufbau eines CNN [Patel and Pingel, 2017]

1 Tensorflow - <https://www.tensorflow.org/>

Im Fall der Tensorflow Object Detection API werden die Positionen der erkannten Objekte über sogenannte *Bounding-Boxes* definiert. Die Lage und Größe dieser rechteckigen Markierungen im Bild, wird über zwei Pixel-Koordinaten angegeben. [Huang et al., 2018]

2.1.2 Fahrzeugverfolgung

Nachdem in jedem Video-Frame einer Aufnahme die Positionen der Fahrzeuge ermittelt wurden, müssen aus diesen Einzeldetections anschließend Trajektorien erstellt werden. Hierzu müssen alle Positionsinformationen, welche von einem Fahrzeug stammen, einer Bewegungsbahn zugeordnet werden. Eine solche Zuordnung ist nicht trivial, da nie bekannt ist, an welcher Position sich ein Fahrzeug im nächsten Video-Frame befinden wird.

Ein Algorithmus zur Rekonstruktion der Trajektorien aus den Einzeldetections muss die Fahrzeuge im Video verfolgen. Um dies zu erreichen, kann beispielsweise, wie in der Anwendung *Vehicle-Tracker*, ein auf einem Partikel-Filter basierender Tracking-Ansatz verwendet werden. Ein Partikel-Filter, auch bekannt als *sequenzielle Monte-Carlo-Methode*, dient der Schätzung des Zustandes eines dynamischen Systems basierend auf vorherigen Messwerten. Bei der Fahrzeugverfolgung kann mithilfe eines Partikel-Filters ermittelt werden, an welcher Stelle sich ein solches im Video-Frame t , basierend auf dessen vorherigen Positionen, vorraussichtlich befindet [Apeltauer et al., 2015]. Um eine Vorhersage für Frame t einer Detektion aus Frame t zuzuweisen, und so Trajektorien aus diesen zu erstellen, kann der *Ungarische Algorithmus* von Harold W. Kuhn eingesetzt werden, welcher eine optimale Zuweisung berechnet [Szottka and Butenuth, 2011]. Kann eine Vorhersage keiner Detektion zugeordnet werden, so wird eine neue Trajektorie initialisiert.

Mithilfe dieses Verfahrens lassen sich Fahrzeugtrajektorien Frame-für-Frame anhand vorher ermittelten Detektionen rekonstruieren. Messlücken in den Detektionen können unter Verwendung eines Partikel-Trackers außerdem interpoliert werden, solange diese nicht zu groß sind. Die erstellten Trajektorien beschreiben die Bewegungen der Fahrzeuge anschließend in Pixel-Koordinaten.

2.2 Positionsbestimmung in Videoaufnahmen

Nachdem die Positionen der Fahrzeuge in Pixel-Koordinaten bestimmt wurden, müssen diese in 3D Weltkoordinaten umgewandelt werden, um die genauen Fahrzeugpositionen auf der Straße zu erhalten. Dank der Verwendung eines stationären Weltkoordinatensystems mit Einheit Meter, lassen sich zudem reale Entfernung in der Aufnahme ermitteln, was beispielsweise für die Bestimmung der Fahrzeuggeschwindigkeiten sehr wichtig ist.

Um eine Bildkoordinate in eine Weltkoordinate überführen zu können, müssen vorher verschiedene Kameraeigenschaften ermittelt werden. Hierzu ist es wichtig ein grundlegendes

Verständnis von der Funktionsweise einer Kamera zu besitzen. Anhand eines Lochkameramodells lässt sich die Funktionsweise der Bildprojektion erklären. Ein solches Modell ist in Abbildung 2.2 dargestellt.

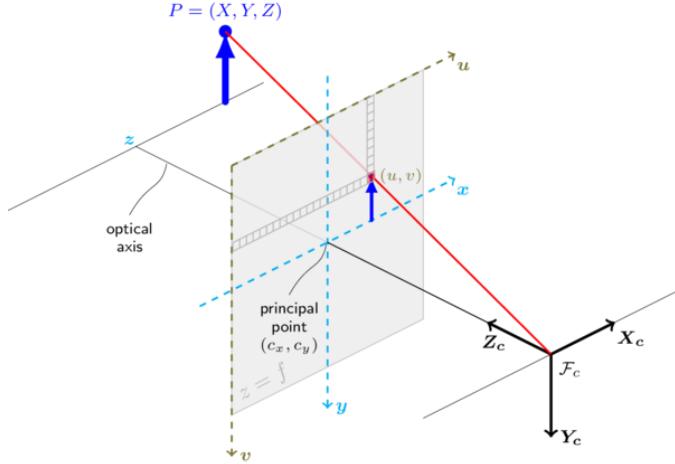


Abbildung 2.2: Projektion eines Punktes P auf die Projektionsfläche einer Lochkamera [OpenCV, 2018]

In einer Lochkamera fällt Licht durch eine kleine Öffnung auf eine Projektionsfläche. Es werden keine Linsen zur Bündelung des Lichtes eingesetzt. Für die Projektion eines Punktes P auf diese Fläche müssen vier Bezugssysteme berücksichtigt werden [Jähne, 2012]:

1. Das **Weltkoordinatensystem** ist ein stationäres Bezugssystem, dessen Ursprung sich an einem beliebigen Punkt im aufgenommenen Raum befindet. Über dieses System werden Weltkoordinaten $P = (X, Y, Z)$ definiert.
2. Das **Kamerakoordinatensystem** hat seinen Ursprung im Punkt F_c , der Öffnung des Kamerasytems. Es definiert Punkte $P = (x_c, y_c, z_c)$ relativ zur Kamera.
3. Das **Projektionskoordinatensystem** hat seinen Ursprung im Punkt $C = (c_x, c_y)$ der Projektionsfläche. Über es werden zweidimensionale Punkte $P' = (x_p, y_p)$ definiert.
4. Der Ursprung des **Bildschirmkoordinatensystems** ist die linke obere Ecke der Projektionsfläche. Über es werden Punkte $P' = (u, v)$ in der Einheit Pixel definiert.

Unter Berücksichtigung dieser Bezugssysteme können die sogenannten *intrinsischen* und *extrinsischen* Kameraparameter bestimmt werden.

Intrinsische Kamera- und Verzeichnungsparameter

Die intrinsischen Kamera- und Verzeichnungsparameter sind abhängig von der Bauart der Kamera und gelten daher für alle Aufnahmen, welche mit der selben Hardwarekonfiguration getätigt werden. Die Parameter c_x und c_y , welche die Bildmitte festlegen, und die horizontale und vertikale Brennweite f_x und f_y definieren die intrinsischen Kameraparameter. Mit ihrer Hilfe lässt sich eine Kameramatrix der Form

$$A = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \quad (2.1)$$

bilden. Die Verzeichnungsparameter sind abhängig von den Linsen, welche in einer Kamera verwendet werden. Diese sorgen für eine radiale und tangentiale Verzeichnung des Bildes. Die Parameter k_1 , k_2 und k_3 definieren die radiale und p_1 und p_2 die tangentiale Verzeichnung. [Meißner, 2007]

Die intrinsischen Kamera- und Verzeichnungsparameter können durch ein Kalibrierungsverfahren bestimmt werden. Computervision Bibliotheken wie OpenCV bieten hierfür Hilfsfunktionen an [OpenCV, 2018].

Extrinsische Kameraparameter

Die extrinsischen Kameraparameter definieren, wie ein Punkt P_w des 3D-Weltkoordinatensystems in einen 3D-Punkt P_c des Kamerakoordinatensystems überführt wird. Die Transformation ist in Gleichung 2.2 beschrieben:

$$P_c = RP_w + t \quad (2.2)$$

R und t sind die extrinsischen Kameraparameter. R ist die sogenannte Rotationsmatrix, welche die Drehung der Kamera um die X, Y und Z-Achse beschreibt. t ist der Translationsvektor, welcher angibt, wo sich der Ursprung des Weltkoordinatensystems relativ zur Öffnung der Kamera befindet. [Jähne, 2012]

Die extrinsischen Parameter einer Aufnahme lassen sich mithilfe der intrinsischen Kamera- und Verzeichnungsparameter und mindestens sechs Weltkoordinaten, welche Bildschirmkoordinaten zugeordnet werden können, bestimmen. Bibliotheken wie OpenCV bieten auch hierfür Funktionen an. Mithilfe der Weltkoordinaten lässt sich zudem auch das Weltkoordinatensystem definieren.

Transformation von Bildschirmpositionen in Weltkoordinaten

Die Transformation einer Weltkoordinate in eine Bildschirmposition ist, ohne Berücksichtigung der Verzeichnung, gegeben durch die Formel 2.3 [OpenCV, 2018]. s ist hier ein konstanter Skalierungsfaktor.

$$s \begin{bmatrix} u & v & 1 \end{bmatrix}^T = A \begin{bmatrix} R & t \end{bmatrix} P_w \quad (2.3)$$

Da bei der Projektion vom Weltkoordinatensystem ins Bildschirmkoordinatensystem eine Dimensionsinformation verloren geht, muss bei der Rücktransformation diese extra bestimmt oder geschätzt werden. Liegt ein Punkt auf der Ebene, welche von der X- und Y-Achse des Weltkoordinatensystems beschrieben wird, kann für dessen Höhe $z = 0$ verwendet werden. Die Position eines Weltpunktes P kann so mithilfe des folgenden Gleichungssystems bestimmt werden:

$$P = \begin{bmatrix} X & Y & 0 \end{bmatrix}^T = R^{-1} \left(sA^{-1} \begin{bmatrix} u & v & 1 \end{bmatrix}^T - t \right) \quad (2.4)$$

In der Anwendung *Vehicle-Tracker* werden auf diese Weise alle Bildschirmkoordinaten der Trajektorien in Weltkoordinaten umgewandelt. Dieser Vorgang wird *MapMatching* genannt.

2.3 Herausforderungen bei der Rekonstruktion von Fahrzeugtrajektorien

Unabhängig vom eingesetzten Verfahren zur Erkennung und Verfolgung von Fahrzeugen in Videoaufnahmen existieren diverse Herausforderungen bei der Rekonstruktion von Trajektorien. Nachfolgend sind häufig auftretende Probleme und deren Auswirkungen beschrieben.

False-Positive und False-Negative Detektionen

Mit *False-Positive Detektionen* sind Objekterkennungen gemeint, welche kein Fahrzeug zeigen. Dieses Problem tritt häufig dann auf, wenn das für die Detektion eingesetzte neuronale Netz nicht ausreichend trainiert wurde. Fälschlicherweise detektierte Objekte können beispielsweise Fußgänger, Fahrradfahrer oder auch Gebäude- und Landschaftsabschnitte sein. In Abbildung 2.3 sind False-Positive Detektionen von Fußgängern und einem Schild auf einem Grünstreifen zu sehen. Aufgrund von False-Positive Detektionen befinden sich in Trajektoriedatensätzen Bewegungsbahnen, welche nicht zu Fahrzeugen gehören, häufig außerhalb der Fahrbahnen verlaufen und meist sehr kurz sind.

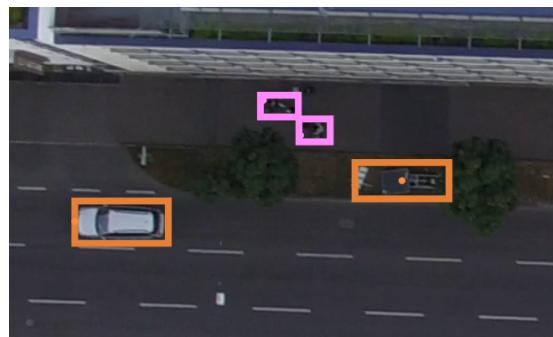


Abbildung 2.3: False-Positive Detektionen von Fahrzeugen in einer Luftaufnahme

Wird ein Fahrzeug in einer Aufnahme nicht erkannt und verfolgt, so handelt es sich dabei um eine *False-Negative Detektion*. Die häufigsten Ursachen für diese Problematik sind schlechte Belichtungsverhältnisse oder eine zu geringe Größe der Fahrzeuge in der Videoaufnahme. In den Trajektoriedaten äußern sich False-Negative Detektionen primär durch das Fehlen von Bewegungsbahnen oder deren zu frühen Abbruch.

Verdeckungen der Fahrbahn

In Luftaufnahmen von Straßenabschnitten sind Teile der Fahrbahnen nicht selten durch beispielsweise Bäume oder Brücken verdeckt. Dies erschwert die Rekonstruktion der Bewegungsbahnen von Fahrzeugen erheblich, da diese beim Unterfahren der Hindernisse nicht in der Aufnahme zu sehen sind. In Abbildung 2.4 ist die Verdeckung einer Fahrbahn durch Baumkronen zu sehen.



Abbildung 2.4: Verdeckung einer Fahrbahn durch Baumkronen

Fahrbahnverdeckungen haben häufig zur Folge, dass die Bewegungsbahnen von Fahrzeugen in den Trajektoriedatensätzen unterbrochen sind. Durch den Einsatz von Verfahren, welche die Position eines Fahrzeugs schätzen, beispielsweise Kalman- oder Partikel-Filter, können Unterbrechungen in Trajektorien zum Teil verhindert werden.

Niedrige Aufnahmewinkel

Auch niedrige Aufnahmewinkel sind eine Herausforderung bei der Rekonstruktion von Fahrzeugtrajektorien. Abbildung 2.5 zeigt die Detektion eines LKW's in einer Luftbeobachtung, welche aus einem niedrigen Aufnahmewinkel erstellt wurde. Problematisch ist hier, dass anhand der Bounding-Box, welche die Position des LKW's im Bild definiert, sich nur schlecht dessen reale Position auf der Straße ermitteln lässt. Die Bounding-Box ragt weit über die Fahrspur hinaus, auf welcher sich der LKW befindet und auch deren Mittelpunkt liegt nicht in der Mitte der Fahrspur. Wenn Fahrzeugpositionen in Bildern mit niedrigem Aufnahmewinkel daher lediglich anhand der Mittelpunkte der Bounding-Boxes ermittelt werden, weichen diese von den realen Positionen immer etwas ab.



Abbildung 2.5: Fahrzeug-Detektion bei niedrigem Aufnahmewinkel

Beim Arbeiten mit Trajektoriedaten muss beachtet werden, dass die oben beschriebenen Effekte auftreten können. Ein Spurerkennungsalgorithmus muss daher auch mit ihnen umgehen können.

3 Clusteranalysen

Die Clusteranalyse (kurz Clustering) ist ein wichtiges Werkzeug aus dem Bereich Data-Mining und Machine-Learning, welches zur Auswertung von Daten unterschiedlichster Art eingesetzt wird. Sie stellt kein konkretes Vorgehen oder einen Algorithmus dar, sondern beschreibt ein allgemeines Problem, welches auf unterschiedlichste Weise gelöst werden kann. Eine Definition ist nachfolgend gegeben:

Definition 2 (Clusteranalyse). *Die Clusteranalyse ist ein Verfahren, um Datenobjekte aufgrund ihrer Eigenschaften und Beziehungen untereinander so zu gruppieren, dass sich die Objekte einer Gruppe möglichst stark ähneln und sich von den Objekten anderer Gruppen möglichst stark unterscheiden. Die auf diese Art entstehenden Objektgruppen werden Cluster genannt.*

Je höher die *Homogenität* in einem Cluster und die *Differenz* zwischen den Clustern, desto besser ist die gewählte Clustering-Methode. Der Einsatz einer Clusteranalyse ist in vielen Anwendungsbereichen und in unterschiedlichen wissenschaftlichen Disziplinen sehr beliebt, um ein Verständnis von Daten zu erhalten und um Muster in solchen zu identifizieren [Tan et al., 2007]. Die Clusteranalyse kommt so beispielsweise in der Bild- [Pappas, 1992] und Dokumentverarbeitung [Hammouda and Kamel, 2004], der IT-Sicherheit [Portnoy et al., 2001] oder auch in Sozialen Netzwerken [Handcock et al., 2007] zum Einsatz.

Die Clusteranalyse hat viel mit dem Problem der Klassifizierung von Daten gemein, insofern sie Datenobjekten Label zuordnet. Im Gegensatz zu *überwachten* Klassifizierungsansätzen, wie dem heute populären überwachten Lernen, leiten Clusteralgorithmen die Label allerdings alleine aus den vorhandenen Daten ab. Es kommen keine Vergleichsobjekte mit bekannten, händisch vergebenen Labels zum Einsatz. Aus diesem Grund wird die Clusteranalyse auch als *unüberwachte Klassifizierung* bezeichnet. [Tan et al., 2007]

Das Konzept eines *Clusters* ist nicht genau definiert. Es existieren daher viele unterschiedliche Konzepte und Algorithmen zur deren Identifikation, welche sich jeweils für andere Anwendungsfälle eignen und verschiedene Eigenschaften besitzen. Neben der Wahl eines passenden Clusteralgorithmus ist auch die Auswahl des verwendeten Distanzmaßes wichtig.

Definition 3 (Distanzmaß). *Ein Distanz- oder Ähnlichkeitsmaß definiert zahlenmäßig wie “ähnlich” beziehungsweise “unähnlich” sich zwei Objekte sind. Auf Basis der ermittelten Distanz beziehungsweise “Ähnlichkeit” werden Cluster gebildet.*

Clustering ist kein selbstdärfiger Prozess, welcher sich in einheitlicher Weise auf unterschiedliche Probleme anwenden lässt. Jedes Problem erfordert die individuelle und sorgfältige Auswahl eines passenden Algorithmus, eines Distanzmaßes und der richtigen Parameter. Die Bestimmung dieser geschieht iterativ und nicht selten nach dem Prinzip des *Trial and Error*. In Abbildung 3.1 ist beispielhaft ein Datensatz (links) mit – für den Menschen intuitiv ersichtlich – 7 unterschiedlichen Clustern (rechts) dargestellt. Nach [Jain, 2010] kann allerdings kein existierender Clustering Algorithmus diese alle erkennen. [Jain et al., 1999; Tan et al., 2007]

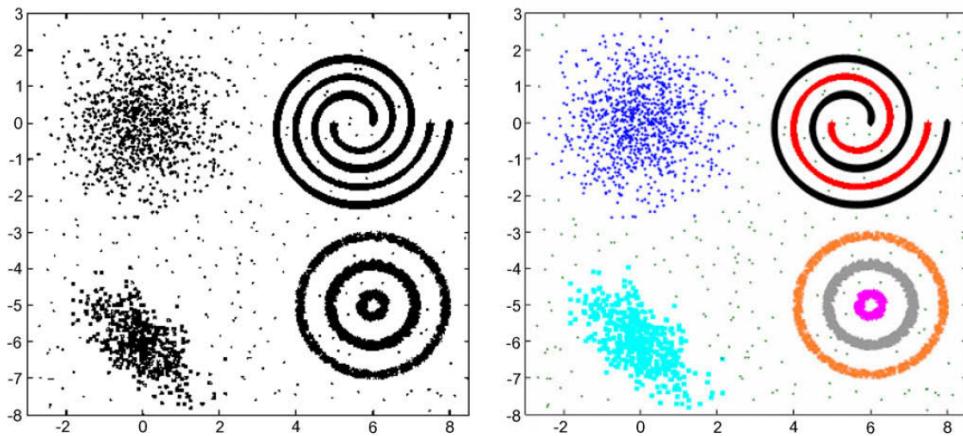


Abbildung 3.1: Rohdaten (links) und erwünschtes Clustering-Ergebnis (rechts) [Jain, 2010]

Aufgrund der Einschränkungen, welche alle Clusteralgorithmen besitzen, muss der Analyst sich vor deren Anwendung intensiv mit den zu verarbeitenden Daten beschäftigen. Er muss ein Verständnis dafür besitzen, welche Struktur die Daten haben, beziehungsweise annehmen können, und nach welchen Mustern zu suchen ist. Besonders wichtiger ist zudem auch die Auswahl der richtigen, also relevanten, Datenmerkmale (“Feature Selection”) und die Wahl deren Repräsentation (“Feature Transformation”). Nach der Selektion und Transformation der Daten müssen diese in einem Vorverarbeitungsschritt von eventuell auftretenden und unerwünschten Effekten befreit werden. Dieser Schritt hat einen maßgeblichen Einfluss auf die Qualität des finalen Clustering-Ergebnisses. Basierend auf vorangegangener Beschreibung und [Jain et al., 1999], lässt sich der grundlegende Ablauf einer Clusteranalyse wie folgt darstellen:

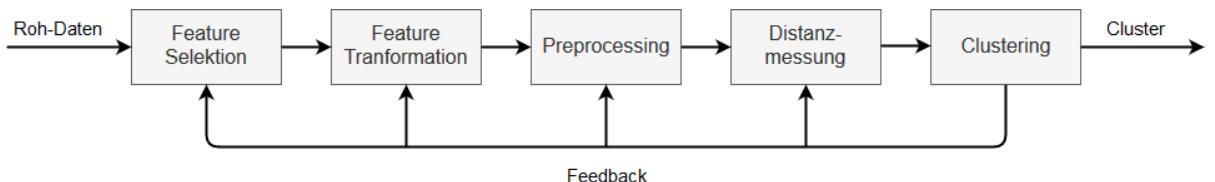


Abbildung 3.2: Schrittweiser Ablauf einer Clusteranalyse

[Jain, 2010] nennt einige weitere Herausforderungen, welche bei der Durchführung einer Clusteranalyse berücksichtigt werden müssen:

1. Daten können Ausreißer enthalten. Wie sollen diese behandelt werden?
2. Die Anzahl der Zielcluster ist üblicherweise nicht bekannt. Wie kann sie im voraus bestimmt werden, wenn die Analyse es erfordert?
3. Wie können gefundenen Cluster validiert werden?

3.1 Cluster-Sets und Cluster

Cluster-Sets, das heißt die Gesamtheit aller durch eine Analyse gefundenen Cluster, und einzelnen Cluster selbst, können in verschiedene Kategorien unterteilt werden beziehungsweise unterschiedliche Eigenschaften besitzen. Nachfolgend sind die wichtigsten, basierend auf [Tan et al., 2007], [Jain et al., 1999] und [Jain, 2010], aufgeführt.

3.1.1 Eigenschaften von Cluster-Sets

Bei Cluster-Sets kann grundsätzlich zwischen folgenden Kategorien unterschieden werden.

Hierarchisch vs. Partitioniert Von *hierarchischen* Cluster-Sets wird gesprochen, wenn die einzelnen Cluster verschachtelt sind und dadurch eine Baum-Struktur bilden. Cluster sind hingegen *partitioniert*, wenn keine Überlagerungen zwischen ihnen existieren.

Exklusiv vs. Überlappend vs. Fuzzy *Exklusive* Cluster-Sets liegen vor, wenn jedem Datenwert ein oder kein Zielcluster zugeordnet wird. Im Gegensatz hierzu können bei *überlappenden* Cluster-Sets Objekte einer oder mehrerer Gruppen angehören. Bei sogenannten *Fuzzy* oder *Soft* Cluster-Sets, gehört ein Datenobjekt einem Cluster mit einer bestimmten Wahrscheinlichkeit oder Gewichtung an. Algorithmen, welche Daten eine Wahrscheinlichkeit für die Zugehörigkeit zu einem Cluster zuweisen, werden *probabilistische* Clusteralgorithmen genannt.

Komplett vs. Partielle Von *kompletten* Cluster-Sets wird gesprochen, wenn jedes Element der Eingangsdaten einem Cluster zugeordnet wird. Bei *partiellen* Sets ist dies nicht der Fall. Hier kann ein bestimmter Anteil an Datenwerten als Ausreißer markiert werden, welche keine Gruppe besitzen.

3.1.2 Eigenschaften von Clustern

Da, wie oben erwähnt, das Konzept eines Clusters nicht klar definiert ist, können auch diese unterschiedliche Eigenschaften besitzen. Die wichtigsten Cluster-Arten sind nachfolgend erläutert.

Klar separierte Cluster In einem *klar separierten* Cluster besitzt jedes Datenobjekt einen geringeren Abstand zu allen anderen Objekten der Gruppe, also zu Elementen außerhalb des Clusters. Dargestellt ist dies in Abbildung 3.3 a). Diese idealistische Definition eines Clusters ist nur dann erfüllt, wenn die in den Daten enthaltenen Cluster einen großen Abstand voneinander haben. In der Realität ist dies selten der Fall.

Prototyp-basierte Cluster Von einem *Prototyp-basierten* Cluster wird gesprochen, wenn alle Elemente einer Gruppe einen geringeren Abstand zu einem Prototyp oder Referenzwert des Clusters besitzen, als zu denen anderer Gruppierungen (siehe Abb. 3.3 b)). Ein solcher Prototyp ist üblicherweise der Mittelwert der Datenelemente eines Clusters (*Centroid*).

Graphen-basierte Cluster Die Definition eines *Graphen-basierten* Clusters kann immer dann verwendet werden, wenn Daten als vernetzter Graph dargestellt werden. In einem solchen sind die Elemente Knoten und die Kanten repräsentieren Beziehungen zwischen ihnen. Ein Cluster in einem solchen Graphen ist definiert als Menge von Knoten, welche untereinander verbunden sind, jedoch keine Verbindungen zu Elementen außerhalb des Clusters haben. Dargestellt ist dies in Abbildung 3.3 c).

Dichte-basierte Cluster *Dichte-basierte* Cluster sind definiert als Regionen mit einer hohen Dichte an Objekten, welche von Regionen umgeben sind, welche eine geringe Objektdichte besitzen (siehe Abb. 3.3 d)). Elemente, welche in einer solchen Region mit geringer Dichte liegen, werden als Ausreißer interpretiert. Bereiche mit hoher Objektdichte werden üblicherweise gefunden, indem die Nachbarschaften von Elementen untersucht werden.

Konzeptionelle Cluster Eine sehr allgemeine Definition eines Clusters ist die der *konzep-
tionellen* Gruppen. Hiermit ist gemeint, dass die Elemente eines Clusters eine gemeinsame Eigenschaft besitzen. Dies schließt alle oben genannten Cluster-Arten mit ein, lässt sich allerdings beliebig erweitern. So sind beispielsweise in Abbildung 3.3 e) konzeptionelle Cluster dargestellt, die die Form zweier Kreise und eines Rechtecks haben. Um solche Muster erkennen zu können, benötigt ein Algorithmus ein spezielles “Verständnis” eines Clusters.

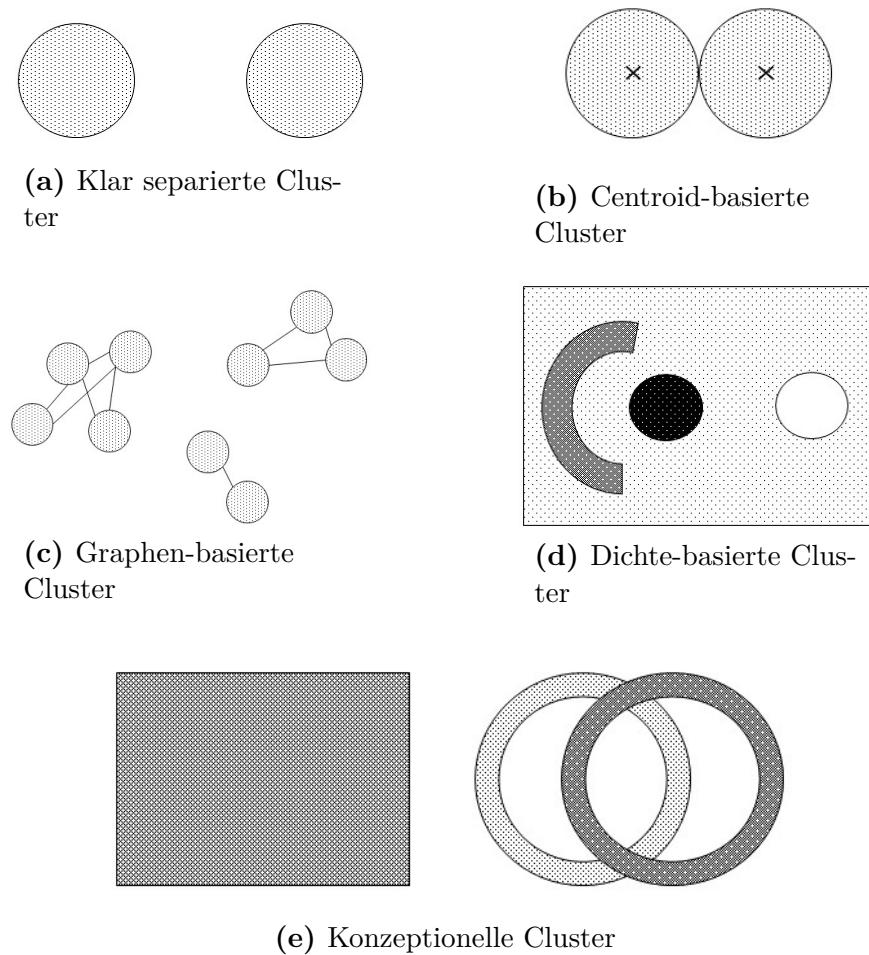


Abbildung 3.3: Visualisierung verschiedener Clusterarten (basierend auf [Tan et al., 2007])

3.2 Clusteralgorithmen

Um mit den oben beschriebenen unterschiedlichen Cluster-Sets und Cluster Definitionen umgehen zu können, existieren verschiedene Clustering-Modelle. Einige wichtige Clustering-Ansätze sind Vernetzungsmodelle, Prototyp-Modelle, Verteilungsmodelle und Dichtemodelle [Tan et al., 2007; Saurav Kaushik, 2016]. Für jede Kategorie existieren unterschiedliche Algorithmen. Im Folgenden werden diese Modelle und jeweils exemplarisch ein Algorithmus vorgestellt.

3.2.1 Vernetzungsmodelle

Vernetzungsmodelle werden auch häufig *hierarchische Cluster-Modelle* genannt. Sie beruhen auf der Annahme, dass Elemente, welche nahe beieinander liegen, eine höhere Gemeinsamkeit besitzen als solche, welche weiter voneinander entfernt sind. Zur Bestimmung der Nähe zwischen Elementen benötigen Vernetzungsmodelle, wie auch andere Cluster-Modelle, eine Verständnis von Distanz. Dieses wird über ein *Distanzmaß* definiert. Zusätzlich ist ein *Link-Kriterium* notwendig, welches bestimmt, wie genau die Entfernung zwischen zwei Clustern ermittelt wird. Übliche Link-Kriterien sind *Minimum-Linkage*, welches die minimale Distanz zwischen den Objekten der Cluster als Distanz verwendet, oder *Maximum-Linkage* beziehungsweise *Average-Linkage*. [Jain et al., 1999; George Seif, 2018]

Grundsätzlich teilen sich hierarchische Clusteralgorithmen in zwei Gruppen auf: *Agglomerative* (Bottom-Up) und *Divisive* (Top-Down) Algorithmen. Agglomerative Ansätze weisen zu Beginn des Clustervorgangs jedem Datenelement eine eigene Gruppe zu und vereinen diese anschließend. Bei divisiven Ansätzen werden hingegen zu Beginn alle Elemente in einem Cluster zusammengefasst und diese in den nachfolgenden Schritten geteilt. [Saurav Kaushik, 2016]

Als Beispiel wird anschließend der *agglomerative-hierarchische Clusteralgorithmus* genauer vorgestellt. Seine Arbeitsweise lässt sich sehr gut anhand sogenannter Dendrogramme oder geschachtelter Cluster-Diagramme darstellen (siehe Abbildung 3.4).

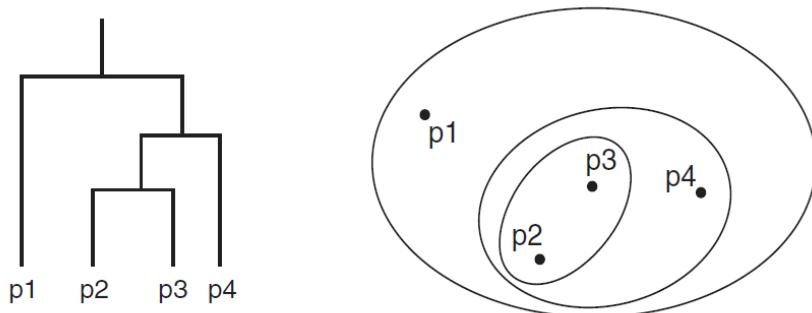


Abbildung 3.4: Agglomeratives Clustering dargestellt als Dendrogramm (links) und geschachteltes Cluster-Diagramm (rechts) [Tan et al., 2007]

Im ersten Schritt des Algorithmus werden alle Datenpunkte als separate Cluster markiert. Diesen Schritt repräsentieren die Blätter des Dendrogramms. Anschließend muss ein Distanzmaß und ein Link-Kriterium gewählt werden. Das am häufigsten verwendete Distanzmaß ist sicherlich der euklidsche Abstand, welcher die Distanz zwischen zwei Punkten oder Vektoren im n -dimensionalen Raum bestimmt. Er ist definiert durch Formel 3.1.

$$dist(p,q) = \|q - p\|_2 = \sqrt{\sum_{i=1}^n (q_i - p_i)^2} \quad (3.1)$$

Wird als Link-Kriterium beispielsweise *Minimum-Linkage* gewählt, ist dieses definiert als:

$$link(P,Q) = \min\{dist(p,q) \mid p \in P, q \in Q\} \quad (3.2)$$

Hierbei entsprechen P und Q zwei Clustern, welche die Elemente $p \in P$ und $q \in Q$ enthalten. Auf Basis des gewählten Link-Kriteriums kann nun eine Distanz-Matrix für die einzelnen Cluster erstellt werden. Die zwei Cluster mit minimalem Abstand voneinander werden anschließend zusammengeführt und die vorherigen Schritte werden wiederholt, bis nur noch ein Cluster (Wurzel des Dendrogramms) beziehungsweise die gewünschte Clusteranzahl übrig ist. [George Seif, 2018; Tan et al., 2007]

Bei den meisten Varianten des agglomerativen Clusterings muss der Nutzer die Anzahl der Zielcluster im vorraus festlegen, was problematisch ist, da diese meist nicht bekannt ist. Umgangen werden kann dies nur, indem ein Link-Kriterium gewählt wird, das ab einer bestimmten Distanz zwischen den Clustern diese nicht weiter fusioniert [George Seif, 2018].

Die Zeitkomplexität des agglomerativen Clusterings beträgt bestenfalls $O(n^2 \log n)$ weshalb die Menge der Daten, welche mit ihm verarbeitet werden können, erheblich begrenzt ist [Tan et al., 2007].

3.2.2 Prototyp-Modelle

Prototyp-basierte Clustering-Modelle betrachten im Gegensatz zu hierarchischen Modellen nicht die Distanz zwischen Clustern, sondern die Entfernung von Objekten zu Referenzpunkten, den *Prototypen*. Die am häufigsten verwendeten Prototypen sind *Centroids*, welche den Mittelpunkt eines Clusters darstellen. *Medoids*, welche teilweise auch genutzt werden, repräsentieren hingegen den Median eines Clusters. [Tan et al., 2007]

Ein Beispiel für einen Centroid-Clusteralgorithmus ist *k-Means*. Dieser ist aufgrund seines Alters, seiner Einfachheit und der vielen Weiterentwicklungen wohl der bekannteste Clusteralgorithmus überhaupt.

Das Ziel von k-Means ist es, für eine n-dimensionale Punktmenge $X = \{x_1 \dots x_n\}$ ein Cluster-Set $C = \{c_1 \dots c_k\}$ zu finden, welches die Summe der quadratischen Abweichung (Gleichung 3.3) zwischen allein Punkten in einem Cluster und deren Mittelwerte μ_k (Centroids) minimiert.

$$J(c_k) = \sum_{k=1}^K \sum_{x_i \in c_k} \|x_i - \mu_k\|^2 \quad (3.3)$$

Eine Lösung für dieses Problem zu finden, ist NP-Schwer. Aus diesem Grund ist k-Means ein approximativer Ansatz, welcher nicht garantieren kann, ein globales Minimum zu finden [Jain, 2010]. Die Funktionsweise des Algorithmus ist in Abbildung 3.5 dargestellt. Die Kreuze entsprechen hierbei den Centroids, welche sich in jeder Iterationen in Richtung der Clustermittelpunkte verschieben.

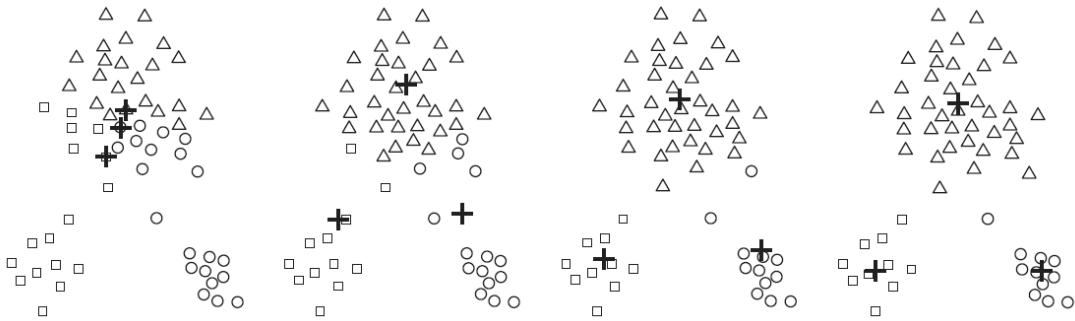


Abbildung 3.5: Funktionsweise k-Means Clusteralgorithmus über mehrere Iterationen [Tan et al., 2007]

Ausgehend von der Punktmenge X und der gesuchten Cluster-Anzahl k , werden im ersten Schritt k zufällig positionierte Centroids μ_k definiert. Anschließend wird für alle Punkte x_i der nächstgelegene Centroid μ_j gesucht.

$$j = \arg \min(\text{dist}(x_i, \mu_j)) \quad (3.4)$$

x_i wird daraufhin Mitglied in Cluster C_j . Als Distanzmaß (dist) kann hier wieder der euklidische Abstand (Gleichung 3.1) verwendet werden oder aber auch beliebige andere Maße. Nachdem alle Punkte x_i einem Cluster zugewiesen wurden, werden die Centroid Positionen neu bestimmt. Hierzu wird der Durchschnitt aller Punkte eines Clusters berechnet:

$$c_j = \frac{1}{n} \sum_{x_j \in C_j} x_j \quad (3.5)$$

Diese zwei Schritte werden mehrfach wiederholt, bis das Ergebnis konvergiert, das heißt die Zuweisungen sich nur noch geringfügig ändern. [Jain, 2010]

Der größte Nachteil des k-Means Algorithmus ist, dass auch bei ihm die Anzahl der Zielcluster spezifiziert werden muss. Des Weiteren ist sein Ergebnis aufgrund der zufälligen Initialisierung der Centroids nicht deterministisch. Ein Vorteil von k-Means ist hingegen, dass seine Zeitkomplexität bei $O(n)$ liegt. [Tan et al., 2007]

Um die genannten Nachteile, zumindest in Teilen, umgehen zu können, existieren diverse Weiterentwicklungen des k-Mean Algorithmus. So stammen beispielsweise von [Hamerly et al., 2004] und [Pelleg et al., 2000] die Algorithmen *g-Means* beziehungsweise *x-Means*, welche die Clusteranzahl k auf Basis mehrerer k-Means Durchläufe und statistischer Kennzahlen bestimmen.

3.2.3 Verteilungsmodelle

Verteilungs-Clustering-Modelle basieren auf der Verwendung von statistischen Wahrscheinlichkeitsverteilungen wie beispielsweise der Gauß-Verteilung. Cluster werden darüber definiert, wie wahrscheinlich es ist, dass Objekte der selben Verteilung angehören. Problematisch ist die Verwendung dieser Clustering-Methodik, da sie anfällig für das Problem des „*Overfitting*“ ist, wenn die Komplexität der verwendeten Modelle nicht beschränkt wird. Zudem ist die Annahme, dass vielen realen Datensätzen ein statistisches Verteilungsmodell zugrundeliegt, gefährlich. Ist diese These jedoch berechtigt, dann haben die Modelle den Vorteil, dass sie neben der Zuweisung von Objekten zu Clustern auch Korrelationen zwischen einzelnen Attributen aufzeigen können. [Anders Drachen, 2014]

Nachfolgend wird der bekannteste Vertreter der Verteilungs-Clusteralgorithmen vorgestellt: das *Expectation–maximization* (EM) Verfahren unter Verwendung sogenannter *Gaussian-Mixture-Models* (GMM). Die Funktionsweise des EM-Algorithmus hat grundsätzlich viel gemein mit der des k-Mean Algorithmus. Es wird ebenfalls mit einer festen Anzahl zufällig initialisierter Modelle gestartet, welche anschließend über mehrere Iterationen hinweg an die Daten angepasst werden. Im Gegensatz zu k-Means, sind die gewählten Modelle hingegen Gauß-Verteilungen, welche zwei Parameter besitzen: ihren Mittelwert und die Standardabweichung. Das Vorgehen des EM-Algorithmus ist nachfolgend, basierend auf [George Seif, 2018], beschrieben und in Abbildung 3.6 grafisch dargestellt.

1. Wahl der Clusteranzahl k und Initialisierung der Gauß-Modelle für die entsprechenden Cluster.
2. Berechnung der Wahrscheinlichkeit, dass ein Datenpunkt zu einem Cluster gehört. Je näher ein Datenpunkt dem Zentrum einer Gauß-Verteilung ist, desto höher die Wahrscheinlichkeit für dessen Zugehörigkeit.
3. Basierend auf den Wahrscheinlichkeiten werden die Parameter der Verteilungen neu berechnet. Hierzu wird die gewichtete Summe der Datenpunkt-Positionen errechnet. Die Gewichte entsprechen dabei den Wahrscheinlichkeiten, dass ein Element zu einem Cluster gehört. Hierdurch werden die Gauß-Modelle automatisch den in den Daten enthaltenen Clustern angepasst.
4. Wiederholung der Schritte 2) und 3), bis das Clustering-Ergebnis konvergiert.

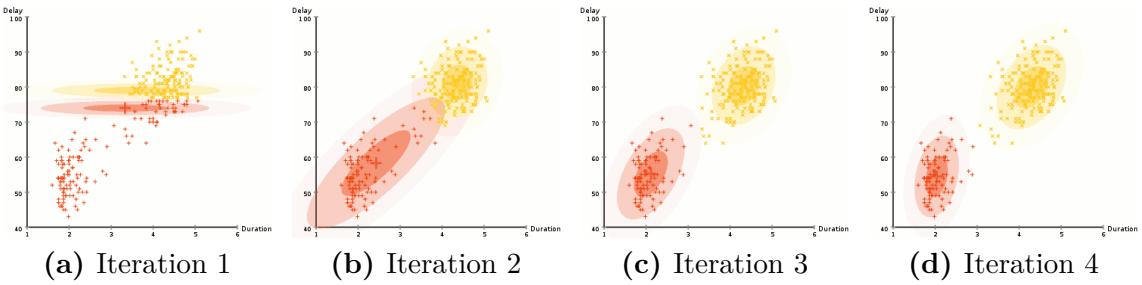


Abbildung 3.6: Funktionsweise des EM-Clusteralgorithmus über mehrere Iterationen [George Seif, 2018]

Ziel des EM-Algorithmus ist es, die Parameter der Gauß-Modelle so zu optimieren, dass diese die Verteilung der Daten bestmöglich beschreiben. Am Ende des Clusterings besitzt jeder Datenwert die Zugehörigkeits-Wahrscheinlichkeiten für die einzelnen Cluster. Ein Element wird jenem Cluster zugeordnet, für welches es die höchste Wahrscheinlichkeit besitzt.

3.2.4 Dichtemodelle

Dichte-basierte Cluster sind, wie oben beschrieben, definiert als Regionen hoher Objektdichte, welche von Bereichen geringer Dichte umgeben sind. Dichte-Clustering-Modelle suchen nach eben solchen Regionen. Großer Vorteil der Algorithmen dieser Klasse ist, dass sie Cluster beliebiger Formen identifizieren können, nicht auf die Vorgabe einer Clusteranzahl angewiesen sind und mit Ausreißern umgehen können. [Tan et al., 2007]

Als Vertreter der Dichte-basierten Ansätze wird nachfolgend der *DBSCAN* Algorithmus (*Density-Based Spatial Clustering of Applications with Noise*), wie in [Gao, 2012] beschrieben, vorgestellt. Er verwendet als Maß für die Dichte einer Region die sogenannte ϵ -Nachbarschaft N_ϵ . Diese selektiert für ein Objekt p alle Objekte, welche innerhalb des Radius ϵ um dieses liegen:

$$N_\epsilon(p) = \{q \mid dist(p,q) \leq \epsilon\} \quad (3.6)$$

Eine ϵ -Nachbarschaft besitzt eine hohe Dichte, wenn in ihr mindestens $MinPts$ Objekte liegen.

Basierend auf der Definition von N_ϵ , werden die in einem Datensatz vorhandenen Elemente in drei Klassen unterteilt. Sie sind entweder *Kern-*, *Rand-* oder *Ausreißer-* Objekte. Ein Kernobjekt hat mindestens $MinPts$ andere Punkte in N_ϵ . Randobjekte besitzen weniger als $MinPts$ in N_ϵ , liegen aber in der Nachbarschaft eines Kernobjektes. Ausreißerobjekte sind weder Kern- noch Randobjekte.

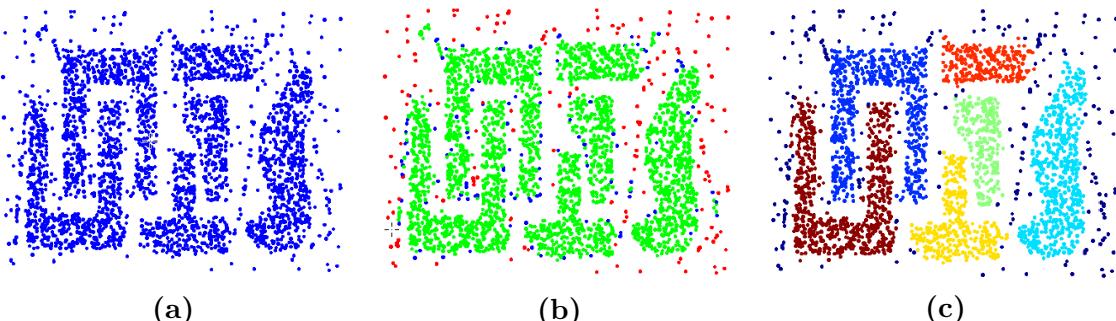


Abbildung 3.7: Schritte des DBSCAN Algorithmus, a) Rohdaten, b) Klassifizierung in Kern- (grün), Rand- (blau) und Ausreißer- (rot) Punkte, c) Clustering Ergebnis [Gao, 2012]

Auf Basis der drei Objektklassen lässt sich das Prinzip der Dichte-basierten *Erreichbarkeit* definieren. Ein Objekt q ist von p *direkt* erreichbar, wenn p ein Kernobjekt ist und q in dessen N_ϵ liegt. In Abbildung 3.8 gilt dies beispielsweise für p und p_2 . Zwei Elemente sind *indirekt* erreichbar, wenn sie über eine Reihe von Zwischenschritten indirekt verbunden sind (transitiv). Dies ist in Abbildung 3.8 für q und p der Fall.

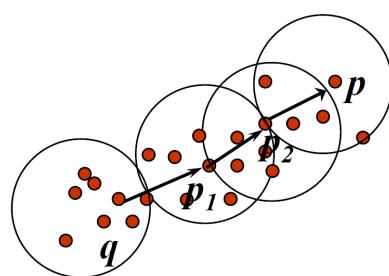


Abbildung 3.8: Konzept der Dichte-basierten Erreichbarkeit in DBSCAN [Gao, 2012]

Der DBSCAN Algorithmus kann, basierend auf den obigen Definitionen, wie folgt beschrieben werden:

1. Unterteilung der Objekte in die drei Objektklassen (vgl. Abb. 3.7 b)).
 2. Aussortierung der Ausreißer-Objekte.
 3. Wahl eines nicht zugewiesenen Kernobjektes.
 4. Erstellung eines neuen Clusters für das Kernobjekt und alle von ihm ausgehend direkt und indirekt erreichbaren Objekte.
 5. Wiederholung der Schritte 3) und 4), bis alle Kern- und Randobjekte einem Cluster zugewiesen sind. (vgl. Abb. 3.7 c))

DBSCAN besitzt die oben erwähnten Vorteile Dichte-basierter Clusteralgorithmen. Dank einer Zeitkomplexität von $O(n \log n)$, kann er außerdem auch auf große Datensätze angewendet werden [Tan et al., 2007]. Nachteil des Ansatzes ist, dass er schlecht mit Clustern umgehen kann, welche unterschiedliche Dichten besitzen.

3.3 Distanzmaße zum Vergleich von Fahrzeugtrajektorien

Bei der Clusteranalyse ist neben der Wahl des passenden Clusteralgorithmus insbesondere die Entscheidung, welches Distanzmaß verwendet wird, ausschlaggebend. Im obigen Abschnitt wurde bereits die euklidische Distanz (Gleichung 3.1) als ein mögliches Distanzmaß vorgestellt. Dieses kann jedoch nur zur Bestimmung der Distanz zwischen n -dimensionalen Punkten im euklidischen Raum verwendet werden. Dasselbe gilt für andere einfache Maße wie die Manhatten-Distanz oder die Pearson-Distanz.

Um Fahrzeugtrajektorien korrekt gruppieren zu können, ist ein Distanzmaß notwendig, welches, je nach Anforderungen, die unterschiedlichen Aspekte der Trajektorien vergleicht. Häufig werden die Eigenschaften Lage, Form und Länge hierzu herangezogen. In der Literatur werden diverse Maße zum Vergleich von Trajektorien vorgestellt. Diese besitzen alle unterschiedliche Eigenschaften, Vor- und Nachteile.

Nachfolgend werden exemplarisch drei Distanzmaße vorgestellt, anhand welcher ersichtlich ist, welche Abwägungen bei der Wahl des Maßes gemacht werden müssen. In allen drei Fällen werden die Trajektorien als Reihen zweidimensionaler Punkte mit Länge n interpretiert: $t_i = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$. Der n -te Punkt einer Trajektorie ist gegeben über $t_i(n)$ und deren Punkt-Länge über $\text{len}(t_i)$. Die Menge der zu vergleichenden Trajektorien ist $T = \{t_1, t_2, \dots, t_m\}$. Abbildung 3.9 zeigt beispielhaft eine Auswahl von Trajektorien mit unterschiedlichen Bewegungsmustern.

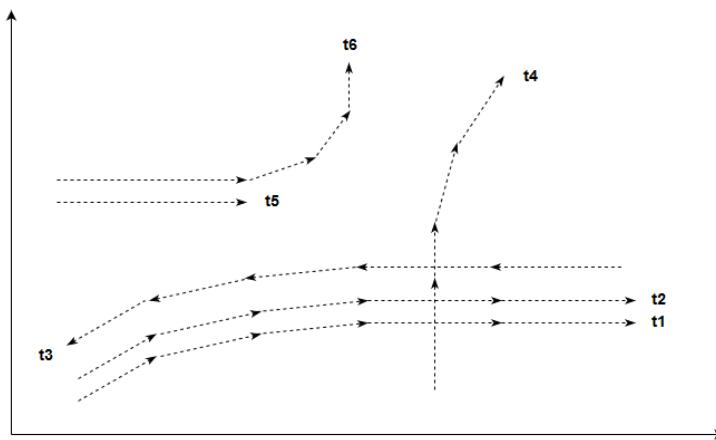


Abbildung 3.9: Trajektorien im zwei-dimensionalen Raum

3.3.1 HU-Distanz

Die HU-Distanz wurde erstmals in der Arbeit “*Similarity based vehicle trajectory clustering and anomaly detection*” von [Hu et al., 2005] vorgestellt. Es ist ein sehr einfaches Distanzmaß, welches auf der mittleren euklidischen Distanz zwischen zwei Trajektorien basiert. Berechnet wird die HU-Distanz für zwei Trajektorien t_1 und t_2 wie folgt:

$$D_{HU}(t_1, t_2) = \frac{1}{N} \sum_{n=1}^N dist(t_1(n), t_2(n)) \quad (3.7)$$

$$\text{wobei } N = \min(\text{len}(t_1), \text{len}(t_2)) \quad (3.8)$$

Aus dieser Formel lassen sich sowohl die Vor- als auch Nachteile der HU-Distanz ableiten. Der klare Vorteile der HU-Distanz ist deren Einfachheit und die Effizienz von $O(n)$. Nachteil ist hingegen, dass das Distanzmaß nur gut funktioniert, wenn die Trajektorien bestimmte Kriterien erfüllen. So sollten Trajektorien, welche einem Cluster angehören, auch immer möglichst auf der selben Höhe beginnen, damit deren mittlerer Abstand nicht, aufgrund einer Verschiebung, erhöht wird. Außerdem ist es notwendig, die Abstände zwischen den Punkten der Trajektorien auf die selbe Länge zu bringen, damit beim paarweisen Vergleich immer Elemente verglichen werden, welche gleichweit vom Start der Trajektorien entfernt sind.

Diese Eigenschaften der Bewegungsbahnen müssen über einen Vorverarbeitungsschritt geschaffen werden. Problematisch bei der Verwendung der HU-Distanz ist außerdem, dass beim Vergleich zweier Trajektorien immer nur die ersten N Punkte (s. Gleichung 3.8) betrachtet werden. Dies kann dazu führen, dass zwei Trajektorien, welche anfangs fast identisch verlaufen und sich später voneinander entfernen, trotzdem einen hohen Ähnlichkeitswert besitzen (vergleiche t_5 und t_6 in Abbildung 3.9).

Die HU-Distanz kann aufgrund der genannten Einschränken nur in speziellen Fällen oder nach starker Vorverarbeitung der Trajektorien angewandt werden. Sie liefert ansonsten schlechte Clustering Ergebnisse.

3.3.2 Hausdorff-Distanz

Die Hausdorff-Distanz ist ein komplexeres Maß zur Bestimmung der Ähnlichkeit zwischen zwei Trajektorien. Sie misst grundsätzlich den Abstand zwischen zwei nicht-leeren, ungeordneten Teilmengen A und B und ist für Trajektorien definiert über die Gleichungen [Atev et al., 2010]:

$$D_{HD}(t_1, t_2) = \max(h(t_1, t_2), h(t_2, t_1)) \quad (3.9)$$

$$h(t_1, t_2) = \max_{i \in t_1} \min_{j \in t_2} dist(i, j) \quad (3.10)$$

$h(t_1, t_2)$ wird als gerichtete Hausdorff-Distanz von t_1 nach t_2 bezeichnet. Sie findet die maximale Distanz einer Trajektorie zum nächsten Punkt einer anderen Trajektorie [Huttenlocher et al., 1993]. Da h gerichtet ist, gilt $h(t_1, t_2) \neq h(t_2, t_1)$. Aus diesem Grund wird die Hausdorff-Distanz zwischen zwei Trajektorien mittels D_{HD} bestimmt. $dist$ kann ein beliebiges Maß für die Distanz zweier Punkte sein, wie beispielsweise die euklidische Distanz. Grundsätzlich lässt sich über die Hausdorff-Distanz die Form zweier Trajektorien vergleichen. Diese sind ähnlich, wenn jeder Punkt einer Trajektorie einen nahegelegenen Punkt in der Vergleichsbahn besitzt.

Vorteil der Hausdorff-Distanz im Vergleich zur HU-Distanz ist, dass diese immer vollständige Trajektorien vergleicht und nicht nur Teile. Außerdem ist bei ihrer Verwendung keine Vorverarbeitung in Form von Resampling et cetera notwendig. Problematisch ist das Distanzmaß hingegen, da es mit ungeordneten Sets arbeitet und somit im Fall von Trajektorien deren Orientierung nicht beachtet. Zwei parallele aber in entgegengesetzte Richtungen laufende Trajektorien, wie beispielsweise die Trajektorien t_2 und t_3 in Abbildung 3.9, würden nach Hausdorff eine hohe Ähnlichkeit besitzen. Zudem kann das Distanzmaß schlecht mit Ausreißern umgehen, da bereits ein einzelner Ausreißer, bei ansonsten identischen Trajektorien, zu einer beliebig kleinen Ähnlichkeit führen kann. Von Nachteil ist auch, dass die Zeitkomplexität der Hausdorff-Distanz bei $O(n m)$ liegt.

3.3.3 Longest-Common-Subsequence

Das *Longest-Common-Subsequence* (LCSS) Distanzmaß basiert auf dem allgemeinen Problem der Findung einer längsten gemeinsamen Subsequenz zwischen zwei Sequenzen. Da Trajektorien, nach obiger Definition, lediglich Punktsequenzen sind, lässt sich das Verfahren sehr gut auf sie anwenden. Aufgrund von Erweiterungen des Basis-Algorithmus, besitzt das LCSS Distanzmaß einige besondere Eigenschaften. Der Algorithmus für Trajektorien ist grundsätzlich wie folgt definiert [Vlachos et al., 2002]:

$$LCSS_{\epsilon,\delta}(t_1, t_2) = \begin{cases} 0 & \text{if } t_1 \text{ or } t_2 \in \emptyset \\ 1 + LCSS_{\epsilon,\delta}(t'_1, t'_2) & \text{if } dist(t_1(n), t_2(m)) < \epsilon \\ & \wedge |n - m| \leq \delta \\ \max(LCSS_{\epsilon,\delta}(t'_1, t_2), LCSS_{\epsilon,\delta}(t_1, t'_2)) & \text{otherwise} \end{cases} \quad (3.11)$$

Hierbei gilt $t'_i = \{t_i(0), \dots, t_i(n-1)\}$. Die Parameter ϵ und δ bestimmen das Vergleichsverhalten des Algorithmus. Über ϵ wird definiert, wieweit zwei Punkte maximal voneinander entfernt liegen können, um immer noch als "übereinstimmend" zu gelten. δ bestimmt hingegen, wieweit in beide zeitliche Richtungen gesucht wird, um einen übereinstimmenden Punkt zu finden. Da die obige LCSS Funktion nur ein diskretes Zählmaß definiert, ist das eigentliche LCSS-Distanz üblicherweise gegeben als [Vlachos et al., 2002]:

$$D_{LCSS}(\delta, \epsilon, t_1, t_2) = 1 - \frac{LCSS_{\delta, \epsilon}(t_1, t_2)}{\min(\text{len}(t_1), \text{len}(t_2))} \quad (3.12)$$

Vorteil der LCSS Ähnlichkeitdefinition ist, dass sie mit kompletten Trajektorien arbeitet und robust gegenüber Ausreißern ist, da nicht für alle Punkte Übereinstimmungen in den Trajektorien gefunden werden müssen. Über ϵ und δ kann die “Strenge” des Algorithmus geregelt werden. Zudem berücksichtigt das LCSS Maß die Orientierung der Trajektorien. Die rekursive Definition des LCSS Algorithmus aus Gleichung 3.11 lässt sich mittels dynamischer Programmierung und *Memoisation* mit Zeitkomplexität $O(n m)$ berechnen.

3.3.4 Wahl eines Distanzmaßes

Anhand der drei ausgewählten und oben exemplarisch beschriebenen Distanzmaße ist bereits ersichtlich, dass die Wahl eines passenden Maßes nicht trivial ist. Es muss die Qualität und Form der Daten berücksichtigt werden. Außerdem muss abgewogen werden, in wieweit es möglich beziehungsweise gewünscht ist, die Daten vorzuverarbeiten.

Das primäre Auswahlkriterium ist natürlich die situationsabhängige Definition von “Distanz”: Sind sich Trajektorien ähnlich, wenn sie lediglich die selbe Form haben und ansonsten an beliebigen Stellen im Raum liegen? Sind sie sich ähnlich, wenn sie die selbe Form haben und im Raum nahe beieinander liegen? Ist ihre Orientierung relevant? Dies sind wichtige Fragen, welche vor der Wahl eines Distanzmaßes geklärt werden müssen. Da die Maße als Distanzfunktionen bei der Clusteranalyse verwendet werden, ist ihr Verhalten ausschlaggebend für den Erfolg der Gruppierung von Trajektorien.

4 Verwandte Arbeiten

Das folgende Kapitel gibt eine Überblick über verwandte wissenschaftliche Arbeiten, welche sich bereits mit der Analyse von Trajektoriedaten und der Erkennung von Fahrspuren beschäftigen. Zu Beginn werden Arbeiten vorgestellt, welche sich mit der Clusteranalyse von Trajektorien befassen. Anschließend wird betrachtet, wie in der Literatur die Erkennung von Fahrspuren auf Basis von Trajektorien bislang umgesetzt wird. Am Ende des Kapitels werden Defizite der existierenden Lösungen aufgezeigt und es wird analysiert, welche spezifischen Neuerungen für die Umsetzung dieser Arbeit nötig sind.

4.1 Clusteranalyse von Trajektorien

Aufgrund der vielen Erkenntnisse welche aus Trajektoriedaten gewonnen werden können, ist ihre Auswertung schon seit geraumer Zeit Gegenstand wissenschaftlicher Untersuchungen. Nachfolgende Arbeiten beschäftigen sich mit der Clusteranalyse von Trajektorien. Die Auswahl zeigt prototypisch, wie unterschiedlich die Anwendungsszenarien und Ziele bei solchen Analysen sind.

Similarity based vehicle trajectory clustering and anomaly detection

Eine Arbeit, welche ein sehr typisches Anwendungszenario behandelt, stammt von [Hu et al., 2005]. Die Autoren beschreiben in dieser Veröffentlichung ein Verfahren zur Clusteranalyse von Fahrzeugtrajektorien. Ziel dieser ist es, auf Basis der entdeckten Spur-Cluster, anormale Verkehrsmanöver in Live-Aufnahmen von Straßenabschnitten detektieren zu können. Solche Manöver sind beispielsweise “Fahren abseits der üblichen Bahnen” oder “zu schnelles/langsames Fahren”. Die Fahrzeugtrajektorien sind in dieser Arbeit als Sequenzen zweidimensionaler Punkte definiert. Um sie zu gruppieren, setzen Hu et al. auf klassische Clusterverfahren und die Verwendung eines einfachen, metrischen Distanzmaßes. Dieses Maß, bekannt als HU-Distanz (siehe Abschnitt 3.3.1), vergleicht Trajektorien über den mittleren Abstand zwischen Punktpaaren. Da dies nur zuverlässig möglich ist, wenn die Trajektorien einige Bedingungen erfüllen, müssen die Autoren diese vorverarbeiten. Sie vereinheitlichen daher die Abstände der Punkte einer Trajektorie und erweitern sie in Richtung der Szenen-Grenzen.

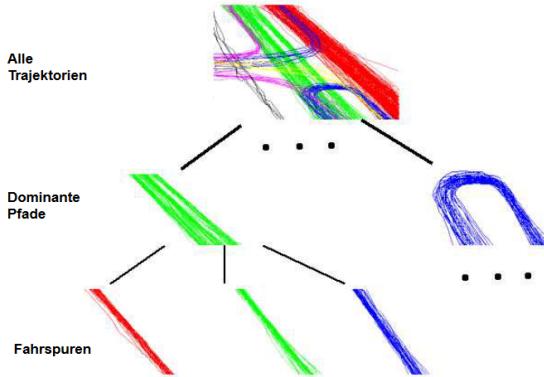


Abbildung 4.1: Zweistufiger Clustering-Vorgang von Hu et al., Identifikation von dominanten Pfaden und Fahrspuren [Hu et al., 2005]

Unter Verwendung des definierten Distanzmaßes werden die Trajektorien in einem zweistufigen Verfahren verarbeitet. In den zwei Phasen werden, wie in Abbildung 4.1 dargestellt, zuerst dominante Fahrpfade extrahiert. Diese werden anschließend weiter in einzelne Fahrspuren untergliedert. Die Autoren vergleichen den *Spectral-Clustering* Algorithmus [Ng et al., 2002] mit einem *Fuzzy-k-Means* Verfahren [Xie and Beni, 1991]. Die Untersuchungen zeigen, dass der Spectral-Clustering Ansatz nicht nur bessere Ergebnisse liefert, sondern dieser über mehrere Durchläufe hinweg auch stabil sind, wohingegen die Resultate des Fuzzy-Ansatzes variieren.

Multi Feature Path Modeling for Video Surveillance

Eine weitere Arbeit, welche das Ziel hat anormale Bewegungsmuster auf Basis von Trajektorien zu entdecken, stammt von [Junejo et al., 2004]. In diesem Fall geht es den Autoren allerdings nicht um das Finden von Fahrzeug-Fahrspuren, sondern um die Extraktion von Laufpfaden von Fußgängern. Die Bewegungsbahnen der Passanten werden aus Aufnahmen stationärer Überwachungskameras gewonnen und als zwei-dimensionale Punktreihen repräsentiert. Zum Vergleich der Trajektorien, verwenden die Autoren die Hausdorff-Distanz als Distanzmaß. Die üblicherweise negativen Eigenschaften dieses Vergleichkriteriums (siehe Abschnitt 3.3.2), konkret die Missachtung der Orientierung, sind bei diesem Anwendungsfall kein Nachteil, sondern gewünscht. Da Fußgänger auf einem Weg in entgegengesetzte Richtungen gehen können, muss die Orientierung ihrer Trajektorien ignoriert werden. Auf Basis der Hausdorff-Distanz erstellen Junejo et al. einen vollständigen Graphen, in welchem die Knoten Trajektorien und die gewichteten Kanten den Distanzen zwischen Trajektorien entsprechen. Sie zerlegen diesen Graphen mit Hilfe eines rekursiven *min-cut*-Graphen-Algorithmus, welcher sich an der Arbeit von [Boykov and Kolmogorov, 2004] orientiert, und erhalten so die Cluster für die extrahierten Fußgänger-Trajektorien.

Clustering of Vehicle Trajectories

In [Atev et al., 2010] ist das Ziel der Autoren, ein Verfahren zu finden, mit welchem Fahrzeugtrajektorien bestmöglich gruppiert werden können, ohne diese im Voraus anpassen zu müssen. Sie vergleichen hierzu die Performance von drei unterschiedlichen Distanzmaßen unter Verwendung von zwei Clusteralgorithmen. Primäres Augenmerk legen die Autoren auf ein von ihnen bereits in [Atev et al., 2006] entwickeltes Distanzmaß, welches auf der Hausdorff-Distanz basiert und sowohl die Orientierung von Trajektorien berücksichtigt als auch robust gegenüber Ausreißern ist. Dieses neue Maß ist für zwei Trajektorien P und Q wie folgt definiert:

$$h_{\alpha, N, C}(P, Q) = \text{ord}_{p \in P}^{\alpha} \left\{ \min_{q \in N_Q(C_{P, Q}(p))} d(p, q) \right\} \quad (4.1)$$

Hierbei entspricht $C_{P, Q}$ einem Mapping $P \rightarrow Q$, welches einem Punkt $p \in P$ einen entsprechenden Punkt $q \in Q$ zuweist, welcher die selbe relative Position in Q besitzt wie p in P . N_Q definiert ein Subset von Q als Nachbarschaft des Punktes q . Zusammen definieren N_Q und $C_{P, Q}$ eine Struktur, in welcher der Vergleich der Trajektorien stattfindet. Dieses Vorgehen wird in Abbildung 4.2 visualisiert. Der Operator $\text{ord}_{p \in P}^{\alpha} f(p)$ selektiert jenen Wert aus $f(p)$, welcher größer ist als α -Prozent der Werte.

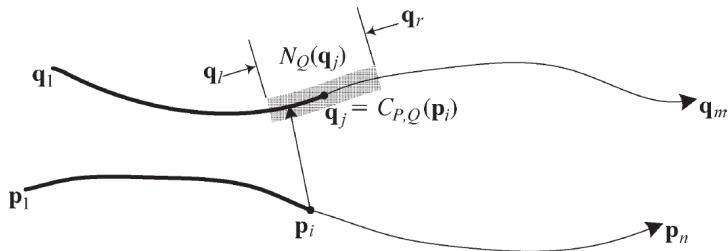


Abbildung 4.2: Funktionsweise der modifizierten Hausdorff-Distanz [Atev et al., 2010]

Dank dieser Modifizierungen eignet sich das Distanzmaß für den Vergleich von Trajektorien: $C_{P, Q}$ sorgt für den Einbezug der Orientierung und über die Nachbarschaft N_Q und $\text{ord}_{p \in P}^{\alpha} f(p)$ kann der Einfluss von Ausreißern minimiert werden.

Das Distanzmaß vergleichen Atev et al. unter Verwendung eines Spectral und eines Agglomerativen Clusteralgorithmus mit der *Longest-Common-Subsequence* (LCSS) und der *Dynamic-Time-Warping*-Distanz (DTW). Die Ergebnisse der Untersuchungen für vier verschiedene Datensätze zeigen, dass die beste Clustering-Performance mit Hilfe der modifizierten Hausdorff-Distanz und des Spectral-Clusterings erreicht wird.

Dass das von Atev et al. vorgeschlagene Distanzmaß gute Clusterergebnisse produziert, wurde auch von [Morris and Trivedi, 2009] bestätigt. In ihrer Untersuchung waren allerdings die Ergebnisse, welche mithilfe des LCSS Maßes erreicht wurden, ebenso gut oder teilweise besser.

Clustering of trajectories based on Hausdorff Distance

Eine weitere interessante Arbeit zur Clusteranalyse von Trajektorien stammt von [Chen et al., 2011]. Die Autoren haben das Ziel, Muster in den Bewegungsbahnen von Hurrikans, welche im Zeitraum von 1850 bis 2010 über den Atlantik zogen, zu erkennen. Sie verwenden hierzu einen angepassten DBSCAN Clusteralgorithmus und das Hausdorff-Distanzmaß. Um die Missachtung der Orientierung kompensieren zu können, und zudem auch Ähnlichkeiten in Sub-Trajektorien zu erkennen, wählen die Autoren eine etwas andere Darstellung der Trajektorien. Sie definieren eine Bewegungsbahn als eine Folge sogenannter „Flow-Vektoren“, welche neben Positions- auch Richtungsinformationen enthalten. Ein solcher Vektor ist definiert über:

$$f_i = (x_i, y_i, dx_i, dy_i) \quad (4.2)$$

wobei gilt:

$$dx_i = (x_{i+1} - x_i) / \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2} \quad (4.3)$$

$$dy_i = (y_{i+1} - y_i) / \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2} \quad (4.4)$$

Die Distanz zwischen zwei *Flow-Vektoren* ist ihr euklidscher Abstand. Auf diese Weise wird bei der Berechnung der Hausdorff-Distanz (siehe Abschnitt 3.3.2) auch die Richtung der Trajektorien berücksichtigt. Um ähnliche Sub-Trajektorien entdecken zu können, teilen Chen et al. die Trajektorien an den Positionen „charakteristischer“ Vektoren. Diese beschreiben Richtungsänderungen in einer Bewegungsbahn und werden identifiziert über die Abweichungen in den Richtungskomponenten zweier aufeinanderfolgender Flow-Vektoren. Veranschaulicht ist dies in Abbildung 4.3.

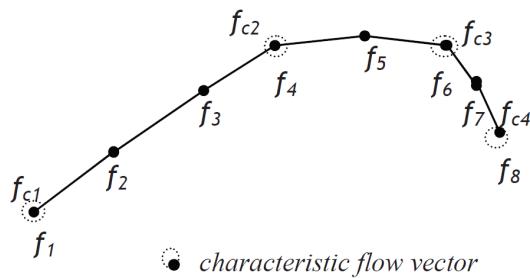


Abbildung 4.3: Zerlegung einer Trajektorie in Sub-Trajektorien anhand von „charakteristischen Flow-Vektoren“ [Chen et al., 2011]

Die auf diese Weise ermittelten Sub-Trajektorien werden von den Autoren mittels eines DBSCAN Algorithmus gruppiert. Sie können so die üblichen Bewegungsbahnen von Hurrikans über dem Atlantik bestimmen.

Discovering Similar Multidimensional Trajectories

Die Arbeit [Vlachos et al., 2002] thematisiert nicht direkt die Clusteranalyse von Trajektorien sondern beschäftigt sich mit dem Vergleich von Bewegungsbahnen im drei-dimensionalen Raum. Konkret ist ihr Ziel, Trajektorien vergleichen zu können, welche etwa die Handbewegungen beim Ausführen von Zeichensprache beschreiben. Hierzu definieren die Autoren erstmals die Grundversion des LCSS Distanzmaßes, welches in vielen Arbeiten, unter anderem in [Atev et al., 2006], [Buzan et al., 2004] und [Chen et al., 2005] zum Einsatz kommt. Auf dessen Basis erstellen sie ein Distanzmaß, welche es ermöglicht formgleiche aber im Raum verschobene Trajektorien zu finden. Die Grundversion der LCSS-Distanz und ein darauf basierendes, einfaches Distanzmaß ist, nach Vlachos et al., bereits in Abschnitt 3.3.3 vorgestellt worden. Dieses Maß erweitern die Autoren zudem wie folgt:

$$D2_{LCSS}(\delta, \epsilon, A, B) = 1 - \max_{f_{c,d} \in F} D_{LCSS}(\delta, \epsilon, A, f_{c,d}(B)) \quad (4.5)$$

Hierbei ist F eine Menge von Translations-Funktionen, welche die Trajektorien entlang der Achsen verschieben. Sie besitzen die Form

$$f_{c,d}(A) = ((a_{x,1} + c, a_{y,1} + d), \dots, (a_{x,n} + c, a_{y,n} + d)) \quad (4.6)$$

Abbildung 4.4 veranschaulicht die Funktionsweise des Distanzmaßes. Sein Einsatz eignet sich immer dann, wenn Trajektorien mit ähnlicher Form gefunden werden sollen, welche zudem eine gewisse räumliche Verschiebung aufweisen können. Diese kann über die Größe von F gesteuert werden.

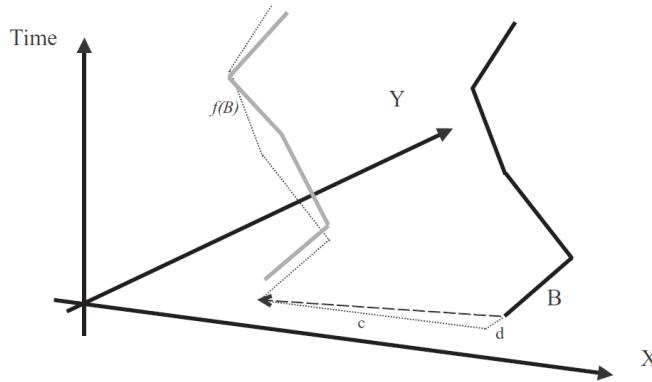


Abbildung 4.4: Verschiebung einer Trajektorie im Raum [Vlachos et al., 2002]

Lane Detection in Video-Based Intelligent Transportation Monitoring via Fast Extracting and Clustering of Vehicle Motion Trajectories

[Ren et al., 2014] stellen in ihrer Arbeit ein Vorgehen zur Clusteranalyse von Trajektorien vor, welches auf der *Rough-Set-Theorie* beruht. Sie extrahieren Fahrzeugpositionen aus Aufnahmen stationärer Überwachungskameras und stellen diese, wie die meisten Autoren, als Sequenzen zweidimensionaler Punkte dar. Ihr Ziel ist es anschließend, anhand einer Gruppierung der Fahrzeugtrajektorien die Spurmittellinien der Fahrbahnen zu bestimmen. Da ein nicht unerheblicher Anteil der Trajektorien Spurwechselvorgänge enthält, welche eine Extraktion der Mittellinien erschweren, verwenden Ren et al. einen iterativen *Rough-k-Means* Algorithmus zur Gruppierung der Trajektorien. Hierbei wird jedes Cluster über eine obere und untere Approximation beschrieben. Die untere Approximation enthält dabei die Trajektorien, welche eindeutig einer Spur zugeordnet werden können. Die obere Näherung hingegen auch jene, welche Spurwechsel et cetera beschreiben. Bei der Berechnung der Spurmittten, werden die Trajektorien der unteren Approximation höher gewichtet, als die der oberen. Ein sehr ähnlicher Cluster-Ansatz wurde bereits in [Lingras et al., 2004] vorgestellt. Die initialen Mittellinien bestimmen die Autoren anhand einer *Aktivitäts-* oder *Heat-Map*, welche sie während der Extraktion der Fahrzeugpositionen erstellen. Die Clusteranzahl k muss händisch definiert werden.

Als Maß für die Distanz zwischen einer Trajektorie A_x und einer Spurmitte c_i verwenden Ren et al. die Hausdorff-Distanz $h(A_x, c_i)$. Für eine Trajektorie wird somit die nächste Mittellinie wie folgt gefunden:

$$h(A_x, c_m) = \min_{i=1 \dots k} h(A_x, c_i) \quad (4.7)$$

Hieraus ergibt sich die nachfolgende Definition für die Zuordnung der Bewegungsbahnen zu den Cluster-Näherungen:

$$\begin{cases} A_x \in \overline{C_m} \wedge A_x \in \overline{C_j} & \text{if } j \neq m \wedge \frac{h(A_x, c_j)}{h(A_x, c_m)} \leq \lambda \\ A_x \in \underline{C_m} & \text{otherwise} \end{cases} \quad (4.8)$$

Für den Grenzwert λ gilt $1 \leq \lambda \leq 1.5$. $\overline{C_m}$ und $\underline{C_m}$ entsprechen der oberen und unteren Näherung des m -ten Clusters und es gilt $\underline{C_m} \subseteq \overline{C_m}$. Nachdem in jeder Iteration des Cluster-Vorgangs die Näherungen auf diese Weise bestimmt wurden, werden die neuen Mittellinien anhand Gleichung 4.9 errechnet.

$$c_i = \begin{cases} \frac{w_l \sum_{A_x \in \underline{C_i}} A_x}{|\underline{C_i}|} + \frac{(1-w_l) \sum_{A_x \in (\overline{C_i} - \underline{C_i})} A_x}{|\overline{C_i} - \underline{C_i}|} & \text{if } \overline{C_i} \neq \underline{C_i} \\ \frac{\sum_{A_x \in \underline{C_i}} A_x}{|\underline{C_i}|} & \text{otherwise} \end{cases} \quad (4.9)$$

Als Gewichtungen w_l verwenden Ren et al. Werte im Bereich $[0.5, 1]$. $|\cdot|$ entspricht hier der Kardinalität einer Menge.

Unter Verwendung dieser Clustering-Methode ist es den Autoren möglich, auch bei einer hohen Anzahl von Ausreißern und Spurwechselvorgängen, stabile Spurmittellinien zu bestimmen. Ergebnisse, welche dies zeigen, sind in Abbildung 4.5 dargestellt.

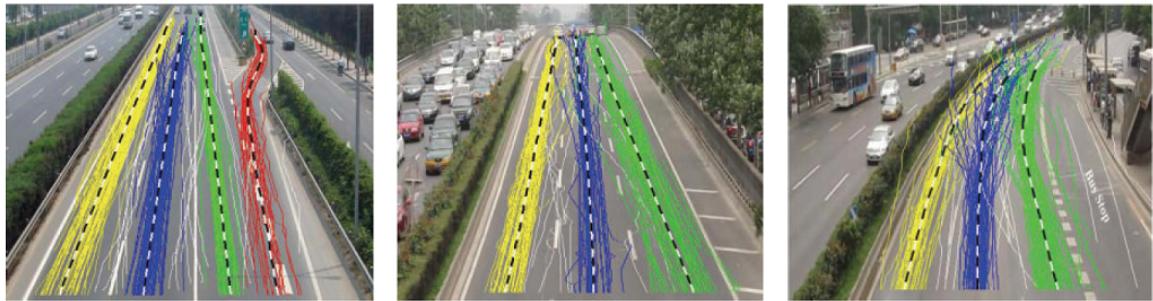


Abbildung 4.5: Ergebnisse Spurmittellinien-Erkennung auf unterschiedlichen Straßenabschnitten [Ren et al., 2014]

4.2 Erkennung und Definition von Fahrspuren

Ziel dieser Arbeit ist es, Fahrspuren zuverlässig in Videoaufnahmen erkennen zu können. Dieser Abschnitt geht daher auf Veröffentlichungen mit ähnlichen Zielen ein.

Die meisten Veröffentlichungen in diesem Bereich lösen das Problem, indem sie nach visuellen Merkmalen, primär Spurtrennlinien, in Videoaufnahmen suchen. Die Aufnahmen werden dabei entweder von stationären Kameras, von bemannten oder unbemannten Luftfahrzeugen oder einem Fahrzeug selbst erstellt. Zur Extraktion der Merkmale werden üblicherweise Methoden aus den Gebieten des maschinellen Sehens (CV) oder maschinellen Lernens (ML) verwendet. Arbeiten, welche CV-basierte Ansätze verfolgen, stammen beispielsweise von [Lai and Yung, 2000], [McCall and Trivedi, 2006] oder [Aly, 2008]. ML-gestützte Arbeiten wurden dahingegen unter anderem von [Kim, 2008], [Gopalan et al., 2012] oder [Neven et al., 2018] veröffentlicht. Ein häufiges Einsatzgebiet für die visuelle Spurerkennung über eine im Fahrzeug verbaute Kamera, sind Spurhalte- oder Spurwechsel-Assistenten.

Da visuelle Ansätze, wie bereits zu Beginn der Arbeit erläutert, aufgrund von Verdeckungen oder Änderungen in der Belichtung problematisch sind, werden nachfolgend ausschließlich Arbeiten vorgestellt, welche Fahrspuren aus Trajektoriedaten extrahieren. Hierbei setzten die meisten als ersten Schritt auf eine Clusteranalyse von Trajektorien. In der Repräsentation und Extraktion der Fahrspuren variieren die Ansätze hingegen.

A System for Learning Statistical Motion Patterns

Die Arbeit [Weiming et al., 2006] basiert auf dem bereits früher veröffentlichten Artikel [Hu et al., 2005] der selben Autoren, welcher in Abschnitt 4.1 beschrieben wurde. In dieser Publikation gehen Hu et al. genauer darauf ein, wie sie auf Basis der Ergebnisse der Clusteranalyse, statistische Informationen über die Fahrbahnen berechnen. Hierzu wird für jedes Cluster zuerst eine Referenztrajektorie T_r bestimmt. Dies ist jene Bewegungsbahn, bei welcher die Summe der Distanzen zu allen anderen Trajektorien des Clusters minimal ist. Das verwendete Distanzmaß ist hierbei das selbe, welches auch bei der Clusteranalyse zum Einsatz kam. Die Autoren berechnen anschließend für jede Trajektorie-Gruppe eine Kette Gausscher-Wahrscheinlichkeits-Verteilungen $\{\varphi_1, \varphi_2, \dots, \varphi_l\}$, wobei l die Anzahl der Punkte der Referenztrajektorie ist. Für jedes φ_i wird der Mittelwert und die Kovarianz, basierend auf den Trajektorie-Punkten, welche dem i -ten Punkt von T_r am nächsten liegen, berechnet. Anhand der Kovarianz-Werte erstellen die Autoren Hüllen für die Fahrbahnen. Ergebnisse dieses Vorgehens sind in Abbildung 4.6 dargestellt.

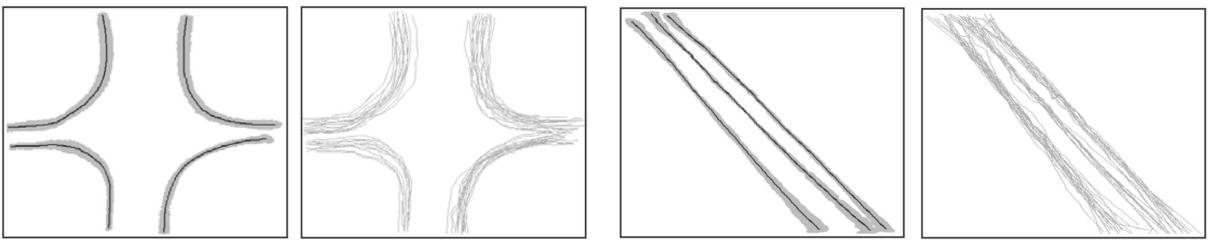


Abbildung 4.6: Trajektorien und ermittelte Spurhüllen in [Weiming et al., 2006]

Anzumerken ist, dass die extrahierten Spurhüllen nicht die tatsächliche Form, insbesondere die Breite, einer Fahrspur wiederspiegeln. Sie sind deutlich schmäler.

Learning Semantic Scene Models From Observing Activity in Visual Surveillance

In [Makris and Ellis, 2005] extrahieren die Autoren übliche Bewegungsbahnen von Fußgängern aus stationären Videoaufnahmen. Sie verwenden hierzu keine klassische Clusteranalyse, sondern ein iteratives und adaptives Online Verfahren, welches neue Bewegungstrajektorien automatisch bestehenden Routen zuordnet oder neue initialisiert, falls zu hohe Abweichungen zwischen der Trajektorie und den existierenden Bahnen bestehen. Routen definieren Makris et al. hierbei als eine Sequenz von Knoten, welche folgende Merkmale besitzen:

- 2D-Mittelpunkt
- Gewichtung (Anzahl der Trajektorien im Bereich des Knoten)

- Zwei Hüllpunkte (Maximale- beziehungsweise Standardabweichung der Trajektorien der Route im Bereich des Knoten)

Abbildung 4.6 a) veranschaulicht die Definition einer Route. Um aus einfachen Bewegungsbahnen Routen zu erstellen, verwenden die Autoren das nachfolgend beschriebene Verfahren, welches dem agglomerativen Cluster-Ansatz ähnelt.

1. Die erste Trajektorie initialisiert die erste Route.
2. Neue Trajektorien werden mit bestehenden Bahnen abgeglichen und
 - a) bei Übereinstimmung wird Route aktualisiert, oder
 - b) bei keiner Übereinstimmung wird neue Route erzeugt.
3. Aktualisierte Routen werden auf definierten Knotenabstand r resampled.
4. Alle Routen werden miteinander verglichen und
 - a) bei einer Überlagerung der Routen werden diese fusioniert.

Als Vergleichsmaß für die Trajektorien und Routen, verwenden Makris et al. die maximale Distanz zwischen einer Trajektorie und einer Routen-Hülle. Diese Distanz muss sich unterhalb eines bestimmten Grenzwertes befinden, damit eine Trajektorie einer Route zugeordnet wird. Geschieht dies, dann werden alle Hüll- und Mittelpunkte neu berechnet. Ein Ergebnis des Verfahrens ist in Abbildung 4.7 b) dargestellt.

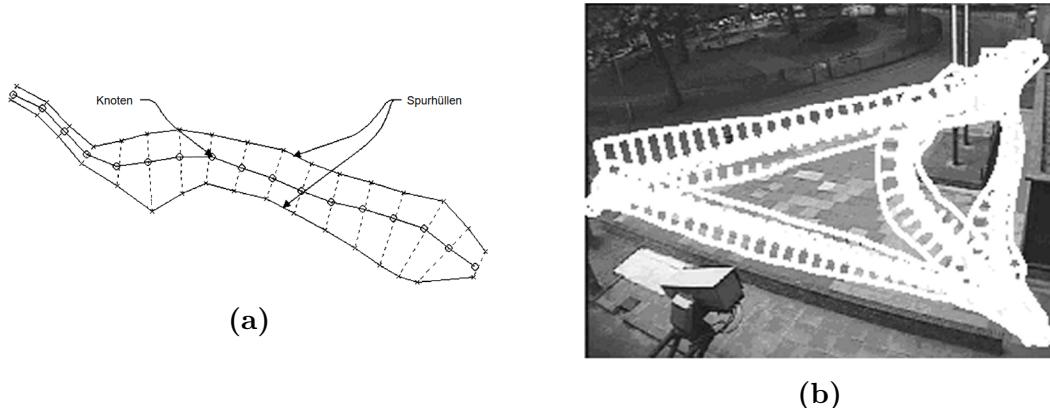


Abbildung 4.7: a) Aufbau einer Route, b) Ergebnisse der Routen-Erkennung [Makris and Ellis, 2005]

Trajectory Learning for Activity Understanding: Unsupervised, Multilevel, and Long-Term Adaptive Approach

In [Morris and Trivedi, 2011] stellen die Autoren ein dreistufiges Framework zur Auswertung von Fahrzeugtrajektorien vor. Ziel des Frameworks ist es, die Bewegungsmuster von Objekten mittels eines erlernten Vokabulars beschreiben zu können sowie Aktivitäten vorhersagen und Anomalien erkennen zu können. In einem ersten Schritt werden daher sogenannte *Points of Interests* (POI) identifiziert. Die von Morris et al. untersuchten POI's sind die Eintritts-, Austritts- und Stop-Zonen innerhalb einer Szene. Nach deren Bestimmung identifiziert das vorgestellte Framework übliche Bewegungsmuster in den Trajektorien und definiert auf deren Basis anschließend Pfade.

Sich häufig wiederholende Bewegungsmuster werden von den Autoren über eine Clusteranalyse ermittelt. Zum Vergleich der Trajektorien kommt das in Abschnitt 3.3.3 vorgestellte LCSS Distanzmaß zum Einsatz und als Clusteralgorithmus das Spectral-Clustering. Morris et al. verwenden statt des im Spectral-Clustering üblicherweise eingesetzten k-Mean-Algorithmus, einen Fuzzy-C-Mean Ansatz, welcher für jede Trajektorie einen Zugehörigkeitswert $u_{ik} \in [0, 1]$ zum Cluster k bestimmt. Anhand der Zugehörigkeiten der Bewegungsbahnen zu den Clustern werden Referenztrajektorien bestimmt. Diese ergeben sich für jedes Cluster als gewichteter Durchschnitt aller Trajektorien. Als Gewichte werden die Werte u_{ik} verwendet. Die so erstellten Referenz-Linien sind in Abbildung 4.8 a) zu sehen.

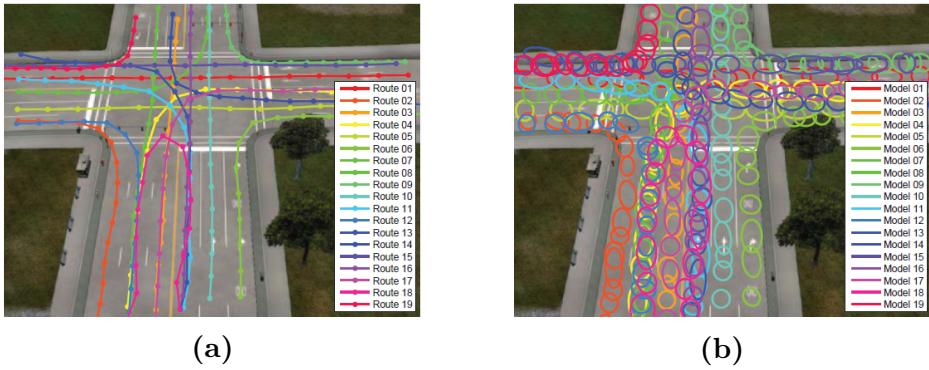


Abbildung 4.8: a) Referenztrajektorien, b) Pfade basierend auf HMMs [Morris and Trivedi, 2011]

Basierend auf den Clustern definieren Morris et al. außerdem Pfade, welche die räumliche und zeitliche Dynamik der Fahrzeuge an einer bestimmten Stelle abbilden. Sie verwenden hierzu Hidden-Markov-Modelle (HMM), welche sie mittels der Baum-Welch-Methode trainieren. Die Ergebnisse dieses Ansatzes sind in Abbildung 4.8 b) dargestellt. Die Ellipsen repräsentieren die HMM's, welche angeben, wie die erwartete Bewegung eines Fahrzeugs in einem bestimmten Bereich aussieht. Die in [Morris and Trivedi, 2011] bestimmten Pfade

ermöglichen es, diverse Aussagen über das Verhalten der Fahrzeuge zu treffen. Sie repräsentieren allerdings nicht die realen Spur-Geometrien eines Straßenabschnittes.

Automatic Traffic Surveillance System for Vehicle Tracking and Classification

[Hsieh et al., 2006] stellen in ihrer Arbeit ein System zur Extraktion von Fahrzeugpositionen aus Aufnahmen stationärer Verkehrskameras vor. Auf diesen aufbauend definieren sie einen Algorithmus, mit dessen Hilfe es möglich ist, Spurmittel- und Begrenzungs-Linien zu entdecken. Hierzu erzeugen Hsieh et al. ein Histogramm $H_{vehicle}(x,y)$, welches die Häufigkeit abbildet, das sich Fahrzeuge über eine bestimmte Pixel-Position (x, y) bewegen. Ein solches ist in Abbildung 4.9 a) dargestellt. Die Autoren gehen davon aus, dass die Fahrzeugpositionen sich mehrheitlich in der Mitte einer Spur befinden und ein Histogramm, welches für eine Fahrbahn mit L_n Spuren erstellt wurde, L_n Maxima in jeder Zeile besitzt, welche die Spurmitten darstellen. Sie isolieren daher die Maxima in $H_{vehicle}$ als Mittellinien. Es sei anschließend $C_{L_k}^j$ die k -te Spurmittellinie in Zeile j des Histogramms. Daraus berechnen Hsieh et al. die Spurbegrenzungslinien. Alle innen liegenden Begrenzungen ergeben sich aus Gleichung 4.10. DL_k^j entspricht hierbei einem Punkt in der j -ten Reihe der k -ten Begrenzung.

$$DL_k^j = \frac{1}{2}(C_{L_{k-1}}^j + C_{L_k}^j) \quad (4.10)$$

Die Breite $w_{L_k}^j$ der k -ten Fahrspur ergibt sich zudem wie folgt:

$$w_{L_k}^j = |C_{L_k}^j - C_{L_{k-1}}^j| \quad (4.11)$$

Die Positionen der äußeren Spurbegrenzungen einer Fahrbahn ergeben sich für die j -te Zeile des Histogramms aus den Gleichungen 4.12 und 4.13.

$$(x_{DL_0^j}, j) = (x_{DL_1^j - w_{L_0}^j}, j) \quad (4.12)$$

$$(x_{DL_{N_L}^j}, j) = (x_{DL_{N_{L-1}}^j + w_{L_0}^j}, j) \quad (4.13)$$

Ein Beispiel für die Ergebnisse der Spurerkennung von Hsieh et al. ist in Abbildung 4.9 b) dargestellt. Das Verfahren funktioniert gut, wenn alle Fahrspuren nebeneinander und parallel zueinander liegen. Die Dimensionen sich kreuzender Fahrspuren können mit dem Verfahren beispielsweise allerdings nicht bestimmt werden.



Abbildung 4.9: a) Fahrzeugpositions Histogramm, b) Spurmittellinien und Spurbegrenzungslinien [Hsieh et al., 2006]

4.3 Defizite vorhandener Lösungen und benötigte Neuerungen

Es existiert eine große Anzahl von Arbeiten, welche sich mit der Clusteranalyse von Trajektoriedaten befasst. Die in Abschnitt 4.1 vorgestellten Veröffentlichungen stellen nur eine kleine Auswahl dar. Die Arbeiten entwickeln Lösungen in verschiedenen Anwendungsbereichen wie der Verkehrs-, Wetter und Verhaltensanalyse und suchen daher in den Trajektoriedaten nach unterschiedlichsten Mustern. Die geforderte Genauigkeit der Clustering-Ergebnisse unterscheidet sich je nach Anwendungsfall ebenfalls stark. Im Rahmen dieser Masterarbeit muss ein Verfahren identifiziert und entwickelt werden, welches Fahrspur-Cluster in Trajektoriedaten zuverlässig identifizieren kann. Die Fahrspuren können hierbei unterschiedlichste Geometrien aufweisen.

Ein Defizit vieler vorhandener Arbeiten ist, dass diese meist mit wenigen unterschiedlichen Trajektoriedatensätzen arbeiten und die verwendeten Daten selten Defekte wie Unterbrechungen, Ausreißer oder inkorrekte Positionsinformationen aufweisen, welche allerdings durch Fehler in der Fahrzeugverfolgung entstehen können. In einigen Arbeit wird teilweise nur mit generierten Trajektoriedaten gearbeitet. Da in der vorliegenden Thesis davon ausgegangen werden muss, dass all diese Probleme auftreten können, muss ein zuverlässiges Verfahren zur Bereinigung von Trajektoriedaten entwickelt werden. Ohne einen solchen Vorverarbeitungsschritt, wäre ein akkurate Clustering nicht möglich.

Deutlich weniger Veröffentlichungen gibt es zum Thema der Identifikation von Fahrspuren. Zwar existieren einige Arbeiten, welche Fahrspuren auf Basis von Trajektorien ermitteln, diese entsprechen aber in den allermeisten Fällen nicht den realen Verläufen der Fahrbahnen. Häufig werden Fahrspuren anhand statistischer Verfahren, wie in [Weiming et al., 2006] oder in [Teng et al., 2015] beschrieben, ermittelt. [Hsieh et al., 2006] ermitteln in ihrer Arbeit Spur-Begrenzungslinien, allerdings nur für kurze, parallele Fahrspuren eines Autobahnabschnittes. Auch die von [Liu and Wang, 2010], [Sochor, 2014] und [Chen and Ellis, 2013] veröffentlichten Verfahren eignen sich nur zur Identifikation von parallelen Fahrspur-Geometrien, welche von statischen Kameras aufgenommen werden.

Ziel dieser Arbeit ist es, Fahrspuren in unterschiedlichen Straßentopologien identifizieren zu können. Die erkannten Spuren müssen außerdem den realen Abmaßen der Spuren auf der Straße bestmöglich entsprechen, damit diese zuverlässig in Verkehrsanalysen eingesetzt werden können. Da dies von keiner existierenden Arbeit geboten wird, muss das Verfahren hierzu selbst entwickelt werden. Es muss zudem eine Lösung zur Partitionierung von Fahrspuren entwickelt werden, da sich Spuren in dieser Arbeit nicht über längere Bereiche hinweg überlagern dürfen.

5 Konzeption des Spurerkennungs-Moduls

In diesem Kapitel wird das zu entwickelnde Teilmodul „*Spurerkennung*“ der Anwendung *Vehicle-Tracker* konzipiert. Hierzu wird zuerst dessen Rolle und Position im Gesamtkontext der Anwendung betrachtet. Anschließend werden die Anforderungen und ein grober Entwurf des Moduls vorgestellt.

5.1 Überblick über das Gesamtsystem

Das Modul *Spurerkennung* dient der Erreichung der in Abschnitt 1.2 definierten Ziele. Erstellt wird es im Rahmen des MEC-View Teilprojektes *Luftbeobachtung* als Teilmodul der Anwendung *Vehicle-Tracker*. Abbildung 5.1 gibt einen Überblick über das System. Es werden hierbei jene Module beziehungsweise Schritte vorgestellt, welche mit der Spurerkennung in Zusammenhang stehen.

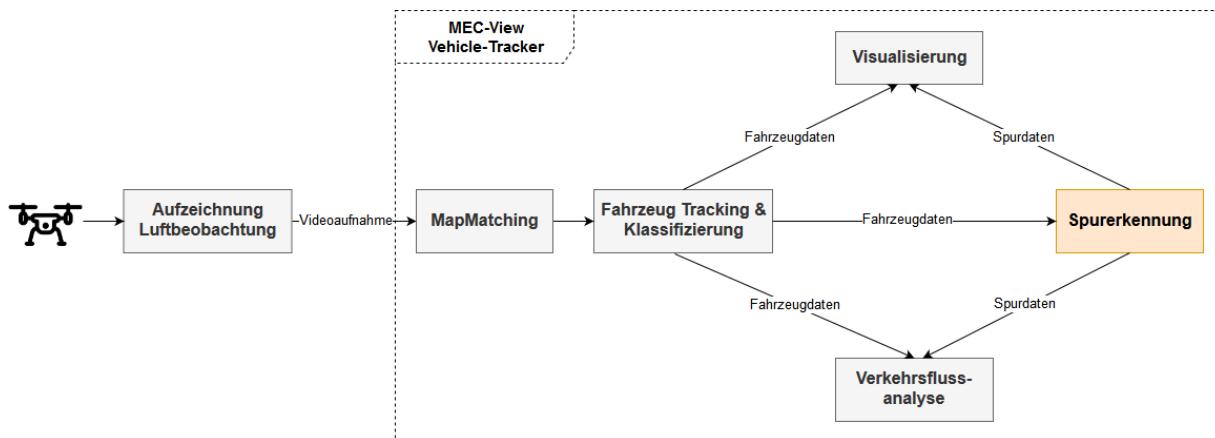


Abbildung 5.1: Kontext des Moduls Spurerkennung

Die mithilfe von Drohnen erstellten Videoaufnahmen können in der MEC-View *Vehicle-Tracker* Applikation verarbeitet und analysiert werden. In einem ersten Schritt namens „*MapMatching*“ wird für eine Aufnahme ein Weltkoordinatensystem in Metern definiert. Anschließend werden die Positionen der Fahrzeuge bestimmt. Diese ersten zwei Schritte sind in Kapitel 2 genauer beschrieben. Die Fahrzeuginformationen, insbesondere die Positionsinformationen, dienen dem *Spurerkennung*-Modul als Eingabe. Aus ihnen extrahierte

Spurdaten können anschließend in der Anwendung visualisiert werden oder in Kombination mit den Fahrzeuginformationen zur Analyse des Verkehrsflusses eingesetzt werden.

5.2 Anforderungen an die Spurerkennung

In diesem Abschnitt werden die wichtigsten funktionalen und nicht funktionalen Anforderungen an das Modul Spurerkennung festgehalten.

5.2.1 Funktionale Anforderungen

Anforderung 1000 (Top-Level) Das *Spurerkennungs-Modul* soll es ermöglichen, mithilfe der Anwendung *Vehicle-Tracker*, automatisch Fahrspuren in Luftaufnahmen anhand von Trajektoriedaten zu erkennen.

Anforderung 2000 Das Modul soll die Erkennung von Fahrspuren in den folgenden Straßentopologien unterstützen:

- Gerade Fahrbahnen (Landstraßen, Autobahnen, et cetera)
- Kreuzungen
- Kreisverkehre
- Sich öffnende oder schließende Spuren (z.B. Be- oder Entschleunigungsstreifen)

Anforderung 2100 Das Modul soll unabhängig vom Aufnahmewinkel der Kamera Fahrspuren zuverlässig aus Videoaufnahmen ableiten können.

Anforderung 2200 Das Modul soll Fahrspuren bei Überlagerungen sinnvoll partitionieren können.

Anforderung 2300 Die von dem Modul ermittelten Fahrspuren sollen so genau wie möglich mit den realen Fahrspurverläufen auf der Straße übereinstimmen.

Anforderung 2400 Das Modul soll die Enden benachbarter und paralleler Fahrspuren aneinander angleichen.

Anforderung 2500 Das Modul soll es ermöglichen, die aus den Trajektorien abgeleiteten Fahrspuren in der Anwendung *Vehicle-Tracker* zu visualisieren.

5.2.2 Nicht funktionale Anforderungen

Anforderung 3000 Das *Spurerkennungs*-Modul muss möglichst robust mit Ausreißern und Defekten in den Trajektorien umgehen können.

Anforderung 3100 Die Performance des Spurerkennung-Vorgangs ist nicht von höchster Priorität. Eine Erkennung soll allerdings dennoch maximal wenige Minuten dauern.

5.3 Entwurf des Moduls

In diesem Abschnitt wird, basierend auf den Erkenntnissen der Literaturrecherche und den Anforderungen, ein grober Entwurf des *Spurerkennung*-Moduls vorgestellt.

Das Modul enthält einen Algorithmus, welcher aus Fahrzeugtrajektorien Fahrspuren ableitet. Die Grundfunktionsweise dieses Algorithmus ist in Abbildung 5.2 in Form eines Aktivitätsdiagrams dargestellt.

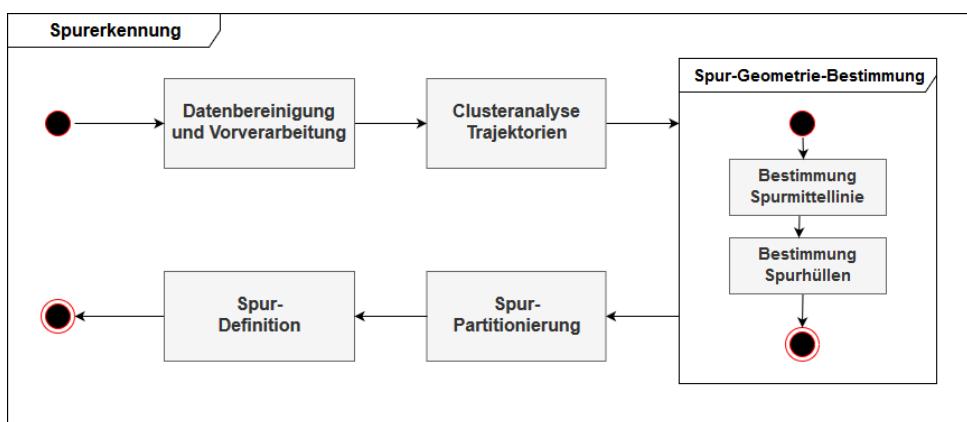


Abbildung 5.2: Basis-Ablauf des Spurerkennungsalgorithmus

Die einzelnen Schritte des Algorithmus werden im *Spurerkennungs*-Modul als einzelne Komponenten implementiert. Die *Vehicle-Tracker* Applikation ist in Java und Scala implementiert. Ihre Benutzeroberfläche basiert auf JavaFX. Das in dieser Arbeit erstellte Modul wird komplett mit Scala umgesetzt.

6 Realisierung der Fahrspurerkennung

In diesem Kapitel wird die Realisierung des Spurerkennungsalgorithmus thematisiert. Es wird zuerst darauf eingegangen, wie die Trajektoriedaten im Algorithmus repräsentiert und, vor der Clusteranalyse, vorverarbeitet werden. Anschließend wird beschrieben, wie in den Trajektoriedatensätzen Cluster identifiziert werden, welche den Verlauf von Fahrspuren beschreiben. Den Schluss des Kapitels bildet die Vorstellung des Vorgehens zur Bestimmung der Spur-Geometrien.

6.1 Repräsentation und Vorverarbeitung der Trajektoriedaten

Nachfolgend wird beschrieben, welche Repräsentation für die Trajektoriedaten in dieser Arbeit gewählt wurde und welche Vorverarbeitungsschritte die Trajektorien vor der Clusteranalyse durchlaufen.

6.1.1 Trajektorie-Repräsentation

Die Ergebnisse der Fahrzeugverfolgung (siehe Abschnitt 2) werden in der Anwendung *Vehicle-Tracker* in Form sogenannter *TrackedObjects* gespeichert. Ein solches Objekt repräsentiert eine zusammenhängende, nicht unterbrochene Verfolgung eines Fahrzeugs. Wird eine Verfolgung, beispielsweise aufgrund einer Überdeckungen, unterbrochen, so existieren für ein Kraftfahrzeug mehrere Objekte, welche sich nicht einander zuordnen lassen. Die wichtigsten Informationen, die ein *TrackedObject* beinhaltet, sind eine eindeutige ID, die Frame-Positionen des Starts und Endes der Verfolgung und die Objekt-Klasse des Fahrzeugs. Es wird zwischen den vier Klassen „Auto“, „Lastwagen“, „Transporter“ und „Zweirad“ unterschieden. Für jedes verfolgte Objekt können die zugehörigen Positions-, Geschwindigkeits-, Beschleunigungs- und Größen-Informationen abgerufen werden. Diese werden für jedes Video-Frame, welches zwischen dem Start- und End-Frame des Objektes liegt, bestimmt.

Da für die Ableitung von Fahrspuren aus Trajektorien lediglich die positionsbezogenen Eigenschaften der Fahrzeuge relevant sind, werden Bewegungsbahnen in dieser Arbeit nur über jene definiert. Geschwindigkeit, Beschleunigung und Größe der Fahrzeuge werden in der Clusteranalyse nicht berücksichtigt.

Zur Erzeugung der Trajektorien werden die “Front-Positionen” der verfolgten Objekte verwendet. Diese markieren den vordersten Punkt eines Fahrzeugs in einem bestimmten Video-Frame und befinden sich immer auf dessen Bounding-Box. Idealerweise liegt die Front-Position auf der Stoßstange eines Fahrzeugs. In Abbildung 6.1 sind beispielhaft zwei verfolgte Objekte dargestellt. Die Front-Positionen werden durch die runden Markern angezeigt.



Abbildung 6.1: Erkannte Fahrzeuge und deren Front-Positionen

Der Vorteil, welcher sich durch die Verwendung der Front-Positionen ergibt, ist, dass diese auch bei niedrigen Aufnahmewinkeln nicht zu weit vom Mittelpunkt der Fahrspur, auf welchem sich das Fahrzeug befindet, entfernt liegen. Dies ermöglicht eine bessere Bestimmung der Fahrspuren bei niedrigen Aufnahmewinkeln.

Abbildung 6.2 zeigt den Aufbau einer Trajektorie im Modul *Spurerkennung*.

Trajectory
<pre>+ id: Int + objectClass: String + positions: Vector[Point] + pointLength: Int + distanceToStart: Vector[Double] + realLength: Double + clusterLabel: Option[Int]</pre>

Abbildung 6.2: Aufbau Trajektorie-Klasse

Die Felder *id* und *objectClass* werden aus dem, der Trajektorie zugrundeliegenden, *TrackableObject* übernommen. Die Positionen eines Fahrzeugs werden in Form von 2D Weltkoordinaten (siehe Abschnitt 2) in *positions* gespeichert und die Anzahl der Koordinaten zusätzlich in *pointLength*. Die Sequenz *distToStart* enthält für jeden Punkt der Bewegungsbahn dessen Distanz zum Start der Trajektorie in Metern. Die Werte ergeben sich aus Formel 6.1, wobei p_n dem n -ten Punkt in der Trajektorie entspricht und *dist* der euklidischen Distanz zwischen zwei Punkten.

$$distToStart(p_n) = \begin{cases} 0 & \text{if } n = 0 \\ dist(p_n, p_{n-1}) + distToStart(p_{n-1}) & \text{otherwise} \end{cases} \quad (6.1)$$

Aus $distToStart$ ergibt sich zudem die Gesamtlänge einer Trajektorie, welche extra gespeichert wird. Das Feld $clusterLabel$ ordnet jede Trajektorie nach der Clusteranalyse einem bestimmten Cluster zu. Zuvor enthält es keinen Wert.

Zur Untersuchung der Qualität der Fahrzeugtrajektorien ist es hilfreich diese zu visualisieren. Abbildung 6.3 b) zeigt beispielsweise 1240 Trajektorien, welche aus einer Aufnahme des Stuttgarter Neckartors extrahiert wurden. In Abbildung 6.3 a) ist ein Video-Frame der entsprechenden Aufnahme zu sehen.

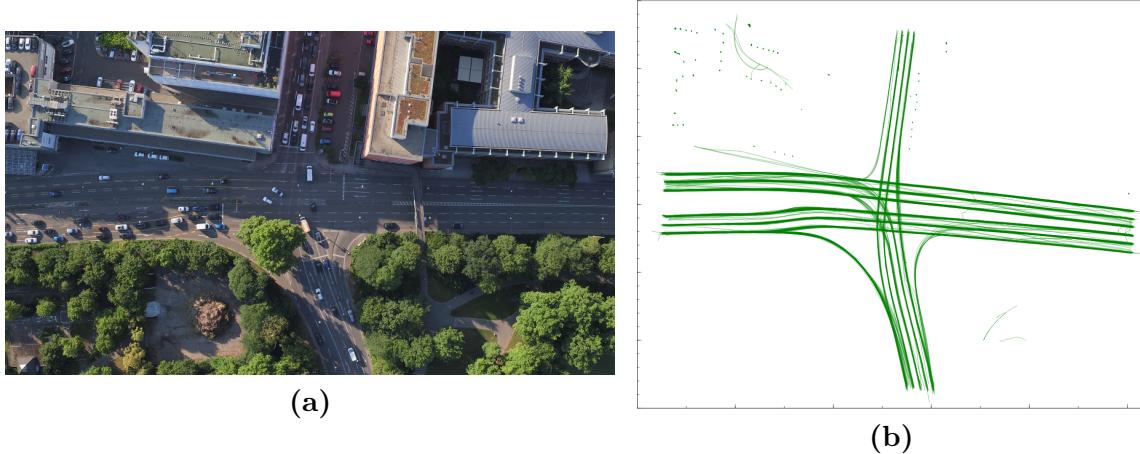


Abbildung 6.3: Aufnahme Stuttgarter Neckartor a) und rekonstruierte Trajektorien b)

In Abbildung 6.3 b) sind die verschiedenen Bewegungsbahnen der Fahrzeuge für den menschlichen Betrachter bereits klar erkennbar. Es fallen allerdings auch die Trajektorien der stehenden oder sich auf Parkplätzen bewegenden Autos im oberen Bereich der Aufnahme ins Auge. Diese dürfen nicht in die Clusteranalyse mit einbezogen werden, da sie keine Bewegung auf einer Fahrbahn beschreiben. Bei genauerer Untersuchung der Trajektorien zeigen sich weitere Probleme, welche das Clustering negativ beeinflussen würden. Zwei sind in Abbildung 6.4 dargestellt. Teil a) zeigt, wie Fahrzeuge Punktwolken beim Stillstand vor Lichtsignalanlagen bilden. Teil b) der Abbildung veranschaulicht, dass in bestimmten Bereichen sehr viele Trajektorie-Unterbrechungen existieren. In diesen Bereichen werden die Fahrbahnen üblicherweise von Bäumen, Brücken et cetera überlagert, wodurch die Fahrzeugverfolgung unterbrochen wird (siehe Abschnitt 2.3).

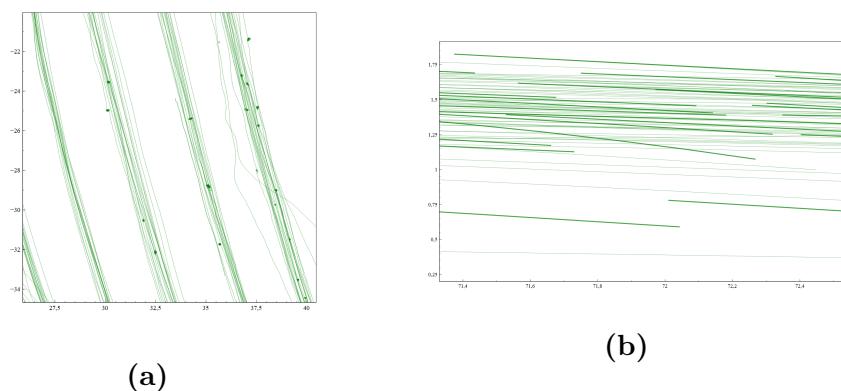


Abbildung 6.4: Defekte in Trajektorien - Punktewolken vor Lichtsignalanlagen a), Unterbrechungen aufgrund von Fahrbahnverdeckung b)

Um von diesen und weiteren Effekten bei der Clusteranalyse nicht beeinflusst zu werden, durchlaufen die “Roh-Trajektorien” einen Vorverarbeitungsschritt. Dieser wird im nächsten Abschnitt beschrieben.

6.1.2 Vorverarbeitung der Trajektorien

Primäres Ziel der Vorverarbeitung ist es, Ausreißer aus der Trajektorie-Menge zu entfernen, welche das Ergebnis der Clusteranalyse negativ beeinflussen würden. Die Qualität der Rohdaten hängt von der Qualität des verwendeten Verfahrens zur Rekonstruktion von Fahrzeugtrajektorien ab. Welche Probleme hierbei auftreten und wie sich diese auf die Trajektoriedaten auswirken, wurde bereits in Abschnitt 2.3 beschrieben.

Idealerweise sollen nach der Vorverarbeitung nur jene Trajektorien weiterverarbeitet werden, welche eine ununterbrochene Bewegung eines Fahrzeugs auf einem bestimmten Straßenabschnitt beschreiben. Anhand dieser Trajektorien kann anschließend die Geometrie der realen Fahrspuren ermittelt werden.

In folgender Auflistung sind die drei wichtigsten Vorverarbeitungsschritte aufgeführt:

1. Resampling von Trajektorien auf minimale Punktdistanz,
 2. Entfernung zu kurzer Trajektorien und
 3. Entfernung unterbrochener Trajektorien

Die einzelnen Schritte und ihre Hintergründe werden anschließend noch genauer erläutert.

Resampling von Trajektorien auf minimale Punktdistanz

Der erste Vorverarbeitungsschritt reduziert die Anzahl der Koordinaten, welche eine Bewegungsbahn beschreiben, erheblich. Es gehen dabei jedoch keine wichtigen Informationen verloren. Insbesondere dann, wenn sich Fahrzeuge mit niedrigen Geschwindigkeiten bewegen oder teilweise vor Ampeln et cetera halten, bestehen die Roh-Trajektorien aus sehr vielen Punkten, welche beinahe identische Positionsinformationen darstellen, das heist nur sehr geringe Abstände voneinander haben. Für die Beschreibung einer Bewegungsbahn ist diese hohe Punktdichte nicht notwendig und sogar kontraproduktiv, da sie die Performance der nachfolgenden Schritte negativ beeinflusst.

Aus diesen Gründen werden im ersten Vorverarbeitungsschritt Trajektorien *resampled*, so dass die Distanz aufeinanderfolgender Punkte mindestens 1.5 m beträgt. Der hierzu verwendete Algorithmus ist in Listing 6.1 dargestellt. Er verwirft alle aufeinanderfolgende Punkte, welche von einem Referenzpunkt weniger als den geforderten Abstand haben.

```

1 algorithm resampleTrajectory:
2   input: lastRefPoint, newTrajPoints, oldTrajPoints
3   output: resampled trajectory points
4
5   while oldTrajPoints is not empty do:
6     nextPoint := Head(oldTrajPoints)
7     remPoints := Tail(oldTrajPoints)
8
9     if dist(lastRefPoint, nextPoint) < 1.5:
10       resampleTrajectory(lastRefPoint, newTrajPoints, remPoints)
11     else:
12       resampleTrajectory(nextPoint, newTrajPoint ++ nextPoint, remPoints)
13     end
14   end
15
16   return newTrajPoints

```

Listing 6.1: Pseudocode Trajektorie Resampling

Nach Anwendung des Algorithmus ist im Fall der Neckartor Aufnahme die durchschnittliche Punktlänge der Trajektorien von 1094 Koordinaten auf 65 gesunken. Die realen Längen der Bewegungsbahnen bleiben hingegen nahezu identisch. Die Punktwolken, welche stehende Fahrzeuge erzeugen, werden mittels dieses Schritts ebenfalls entfernt (siehe Abb. 6.5 b)).

Entfernung von zu kurzen Trajektorien

Der zweite Verarbeitungsschritt entfernt viele Trajektorien von beispielsweise stehenden Fahrzeugen oder kurz auftretenden Tracking-Fehlern. Hierzu wird die Länge aller Trajektorien überprüft und jene entfernt, welche unter einem bestimmten Grenzwert liegen. Die hierzu verwendete boolesche Überprüfung ist in Gleichung 6.2 gegeben. Als Standardwert für $minLength$ wurde experimentell $20m$ bestimmt, da dies für alle Testaufnahmen

gute Ergebnisse lieferte. Bei Bedarf kann der Anwender den Parameter beim Start des Spurerkennungs-Jobs in der Oberfläche anpassen.

$$isShortTrajectory(t) = \begin{cases} 1 & \text{if } t.realLength < minLength \\ 0 & \text{otherwise} \end{cases} \quad (6.2)$$

Das Ergebnis der ersten beiden Vorverarbeitungsschritte ist in Abbildung 6.5 dargestellt. Die Trajektorien stehender Fahrzeuge, sowie die Punktewolken vor Lichtsignalanlagen und weitere Defekte aufgrund kleiner Tracking-Fehler wurden entfernt.

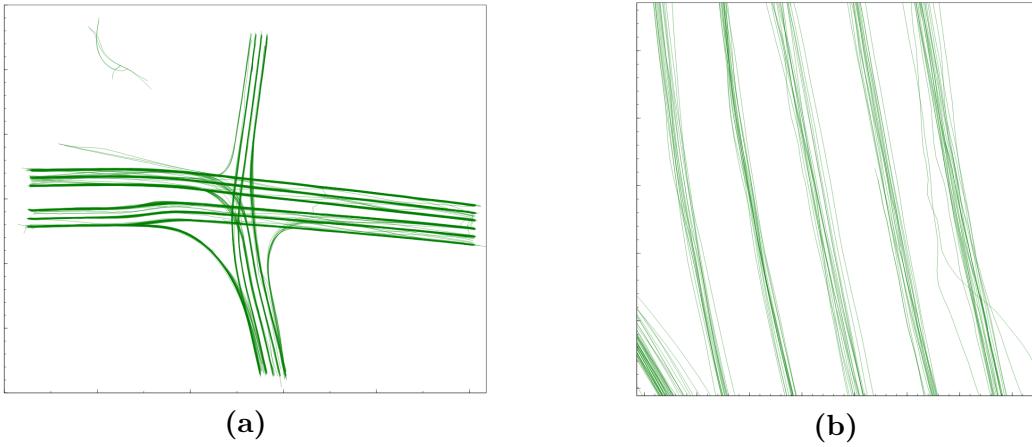


Abbildung 6.5: Ergebnisse der zwei ersten Vorverarbeitungsschritte - Übersicht (keine stehenden Trajektorien) a), Detailansicht (keine Punktewolken) b)

Entfernung unterbrochener Trajektorien

Nachdem durch die ersten beiden Vorverarbeitungsschritte bereits viele Defekte entfernt wurden, müssen nun noch unterbrochene Verfolgungen ausgefiltert werden, da diese das Ergebnis der Clusteranalyse negativ beeinflussen.

Der erste verwendete Ansatz zur Entfernung von unterbrochenen Trajektorien beruhte auf der Annahme, dass komplettete Trajektorien immer im Bereich der Szenenränder beginnen und enden. Daher wurden alle Trajektorien, welche diese Bedingung nicht erfüllen, entfernt. Es ist jedoch auch möglich, dass ununterbrochene Trajektorien in der Mitte einer Aufnahme beginnen, wenn die verfolgten Fahrzeuge in diesem Bereich beispielsweise aus einem Tunnel hervorkommen. Unter Anwendung des obigen Ansatzes würden diese Trajektorien fälschlichweise entfernt. Daher wurde ein alternatives Vorgehen implementiert.

Das im Algorithmus eingesetzte Verfahren basiert auf einer anderen Definition von unterbrochenen Trajektorien: Bewegungsbahnen gelten dann als unterbrochen, wenn sich auf

Höhe ihrer Starts oder Enden mehrere Trajektorien befinden, welche auf der entsprechenden Höhe nicht starten oder enden. Ist dies der Fall, dann gilt die untersuchte Bewegungsbahn als unterbrochen. Die angrenzenden Trajektorien sind potenziell vollständig, das heißt ununterbrochen. Abbildung 6.6 veranschaulicht dieses Konzept.

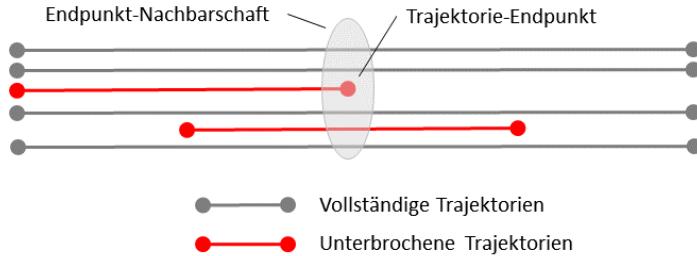


Abbildung 6.6: Konzept Identifikation von unterbrochenen Trajektorien

Der Algorithmus zur Entfernung unterbrochener Trajektorien nutzt die oben gegebene Definition. Er untersucht von allen Trajektorien die Nachbarschaften der Start- und Endpunkte. Befinden sich in den Nachbarschaften mindestens 25% der Punkte nicht am Rand der entsprechenden Trajektorien, so wird die untersuchte Bewegungsbahn als unterbrochen gewertet und entfernt. Dieses Vorgehen beruht auf der Annahme, dass für eine Fahrspur neben unterbrochenen auch ununterbrochene Trajektorien vorliegen, welche eine vollständige Bewegung auf der Spur beschreiben, was üblicherweise der Fall ist.

Nach Ausführung dieses Filter-Schrittes, besteht die Menge der übrigen Trajektorien nur noch aus ununterbrochenen Bewegungsbahnen, welche Bewegungen von Fahrzeugen auf einem bestimmten Straßenabschnitt beschreiben.

6.2 Clusteranalyse der Trajektorien

Nachdem im vorherigen Abschnitt beschrieben wurde, wie die Roh-Trajektorien vorverarbeitet werden, folgt nun eine Erläuterung zweier Verfahren zur Clusteranalyse von Trajektorien, deren Einsatz im Rahmen der Arbeit genauer untersucht wurde.

6.2.1 Ansatz Spectral-Clustering und modifizierte Hausdorff-Distanz

Als erster Ansatz für die Clusteranalyse wurde das von [Atev et al., 2010] vorgestellte Verfahren untersucht. Es wurde gewählt, da es sowohl in der Arbeit von Atev et al. selbst, wie auch in [Morris and Trivedi, 2009], gute Ergebnisse bei der Clusteranalyse lieferte. Das Verfahren nutzt die in [Atev et al., 2006] vorgestellte modifizierte Hausdorff-Distanz und den Spectral-Clustering-Algorithmus. Die Grundlagen des Distanzmaßes wurden bereits in Abschnitt 4.1 beschrieben. Nachfolgend wird noch etwas genauer vorgestellt, wie die

modifizierte Hausdorff-Distanz berechnet wird. Anschließend wird auf den eingesetzten Clusteralgorithmus und die erzielten Ergebnisse eingegangen.

Das Verfahren

Grundlegend war die modifizierte Hausdorff-Distanz nach Atev et al., wie in Gleichung 4.1 bereits definiert, gegeben als:

$$h_{\alpha,N,C}(P, Q) = \underset{p \in P}{ord} \left\{ \min_{q \in N_Q(C_{P,Q}(p))} d(p, q) \right\}$$

Um die Distanz zwischen zwei Trajektorien P und Q zu bestimmen, müssen zuerst die minimalen Distanzen zwischen allen Punkten $p \in P$ und deren Nachbarschaften $N_Q(C_{P,Q}(p))$ in Q bestimmt werden. Eine Nachbarschaft in Q um den Punkt q_0 ist in Abhängigkeit des Parameters w definiert als:

$$N_Q(q_0) = \{q \in Q \mid |\pi_Q(q_0) - \pi_Q(q)| \leq w/2\} \quad (6.3)$$

$\pi_Q(q)$ entspricht hierbei der relativen Position von q in Q , welche in Gleichung 6.4 definiert ist. $|Q_j|$ steht für die Länge einer Trajektorie bis zum Punkt j und $|Q|$ für die Gesamtlänge einer Bewegungsbahn. Diese Längeninformationen sind beide in der verwendeten Trajektorie-Definition aus Abbildung 6.2 enthalten.

$$\pi_Q(q_j) = \frac{|Q_j|}{|Q|} \quad (6.4)$$

Die Nachbarschaften werden um den Referenzpunkt $q \in Q$ gebildet, welcher die selbe relative Position in Q besitzt wie p in P . Der Index dieses Punktes ergibt sich aus dem Mapping $C_{P,Q}$ wie folgt:

$$C_{P,Q}(p) = \arg \min_{q \in Q} |\pi_P(p) - \pi_Q(q)| \quad (6.5)$$

Zur Berechnung der Distanzen $d(p,q)$ zwischen p und allen Punkten $q \in N_Q(C_{P,Q}(p))$, wird die euklidische Distanz verwendet. Wurden auf diese Weise alle minimalen Distanzen zwischen Punkten und ihren Nachbarschaften in der Vergleichs-Trajektorie bestimmt, so wird aus ihnen der finale Distanzwert bestimmt. Der Operator $ord_{p \in P}^\alpha$ wählt hierfür jene Distanz, welche größer ist als α -Prozent aller Werte. Mit Hilfe dieses Distanzmaßes wird eine Distanz-Matrix D konstruiert, welche die Distanzen aller Trajektorie-Kombinationen speichert.

Um die modifizierte Hausdorff Distanz im Spectral-Clustering Verfahren einzusetzen zu können, muss ein zusätzliches Affinitätsmaß verwendet werden. Dieses definieren Atev et al. als:

$$k(P,Q) = \exp\left(-\frac{h_{\alpha,N,C}(P,Q) h_{\alpha,N,C}(Q,P)}{2\sigma(P)\sigma(Q)}\right) \quad (6.6)$$

$\sigma(P)$ und $\sigma(Q)$ entsprechen hier Schätzungen für die Streuung der Distanzwerte einer Trajektorie zu allen anderen Trajektorien. Sie ergeben sich aus der Distanz-Matrix D .

Der in dieser Arbeit und von Atev et al. verwendete Spectral-Clusteralgorithmus folgt grundsätzlich der Standard-Definition von [Ng et al., 2002]. Für eine feste Clusteranzahl k kann er wie folgt zusammengefasst werden:

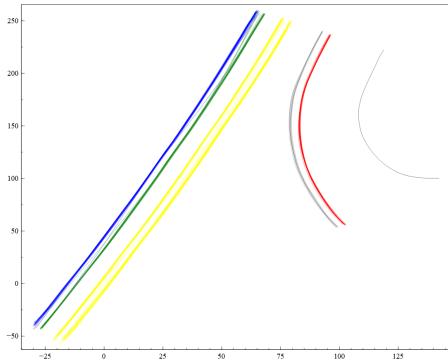
1. Erstellen einer Affinitätsmatrix $A \in \mathbb{R}^{n \times n}$ basierend auf dem Affinitätsmaß, wobei $A_{ii} = 0$
2. Definieren einer Diagonalenmatrix D , deren Elemente an der Stelle (i,i) der Summe der i -ten Zeile von A entsprechen. Basierend auf D wird die Matrix $L = D^{-1/2}AD^{-1/2}$ erstellt.
3. Durchführen einer Eigenwert Dekomposition auf L , um die k größten Eigenvektoren $\{x_1, x_2, \dots, x_k\}$ zu finden.
4. Erstellen einer Matrix $X = [x_1, x_2, \dots, x_k]$ durch spaltenweises Zusammenführen der Eigenvektoren und Normalisierung der Zeilen auf die Länge 1.
5. Gruppierung der Zeilen von Matrix X in k -Cluster unter Zuhilfenahme von k-Means et cetera. Jede Zeile wird als Datenpunkt interpretiert.

Ein großer Nachteil des Spectral-Clustering-Ansatzes ist es, dass bei seiner Verwendung üblicherweise die Clusteranzahl k bereits im vorraus bekannt und angegeben sein muss. Aus diesem Grund verwenden Atev et al. ein Schätzmaß für k , welches darauf abzielt, die Verzerrung des in Schritt 5) eingesetzten k-Means Algorithmus zu minimieren. Hierzu wird die k-Means Clusteranalyse mit mehreren k 's zwischen den Grenzen $kMin$ und $kMax$ durchgeführt und anschließend jeweils ein Verzerrungs-Maß ρ_k berechnet, welches angibt, wie gut die gefundenen Centroids die Datenpunkte beschreiben. Für k wird daher jener Wert gewählt, welcher das kleinste ρ_k erzeugt. Diese Methode zur Schätzung der Clusteranzahl wurde auch in der vorliegenden Arbeit angewandt. Die auf diese Weise mithilfe des Verfahrens von Atev et al. identifizierten Cluster-Sets sind partitioniert, exklusiv und komplett (siehe Abschnitt 3.1.1).

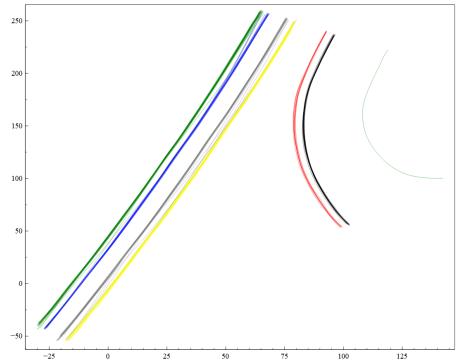
Auswertung des Verfahrens

Nachdem das Verfahren, wie in [Atev et al., 2006] und [Ng et al., 2002] beschrieben, implementiert wurde, wurde eine Evaluation durchgeführt. Die Clustering-Performance des Ansatzes wurde hierzu initial anhand von zwei Trajektoriedatensätzen untersucht.

Die Ergebnisse der Clusteranalyse für den einfacheren Datensatz sind in Abbildung 6.7 dargestellt. An diesem Beispiel lassen sich die Probleme bereits identifizieren. Für die Analyse wurden die Parameter $\alpha = 0.85$ und $w = 1.0$ verwendet. Zur Bestimmung von σ kamen die Grenzwerte $stdMin = 0.5$ und $stdMax = 10.0$ zum Einsatz. Diese haben sich in unterschiedlichen Versuchen als am besten geeignet erwiesen. Trotzdem ist in Abbildung 6.7 a) zu erkennen, dass nicht alle Fahrspuren einem extra Cluster zugewiesen wurden.



(a) mit Schätzung Clusteranzahl



(b) mit fester Clusteranzahl

Abbildung 6.7: Ergebnisse Clusteranalyse Ansatz Atev et al. - fehlerhaftes Clusterergebnis in a), gewünschtes Ergebnis in b)

Ein erstes Problem des Verfahrens sind die vielen Parameter und Grenzwerte, welche vom Anwender bestimmt werden müssen und nicht alle intuitiv verständlich sind. Neben den oben aufgeführten Parametern, gibt es noch weitere, welche bei der Bestimmung der Clusteranzahl und der Berechnung des Affinitätsmaßes zum Einsatz kommen. Eine Optimierung der Parameter und somit der erzielten Ergebnisse wäre sicherlich möglich gewesen, hierauf wurde aber aufgrund anderer existierender Schwierigkeiten verzichtet.

Problematisch ist das Vorgehen auch, da der Spectral-Clusteringalgorithmus nicht mit Ausreißern umgehen kann, welche trotz der Vorverarbeitung der Trajektorien immer noch in geringer Anzahl in den Datensätzen vorhanden seien können. In Abbildung 6.7 a) und b) ist beispielsweise die einzelne Fahrspur im oberen, rechten Bereich einem Spur-Cluster zugeordnet, was nicht korrekt ist. Diese falsche Zuordnung der Ausreißer, würde die Bestimmung der Spur-Geometrien im nächsten Schritt des Algorithmus aus Abschnitt 5.2 erschweren.

Die schlechten Clustering-Ergebnisse des Ansatzes sind primär Folge der nicht zuverlässig funktionierenden Schätzung der Clusteranzahl k . Im Fall des Datensatzes aus Abbildung 6.7, wird $k = 5$ statt korrekterweise $k = 6$ geschätzt. Hieraus ergibt sich, dass in Abbildung 6.7 a) zwischen zwei Fahrspuren nicht richtig unterschieden wird. In Teil b) wurde die Clusteranzahl händisch spezifiziert, was in einer korrekten Gruppierung der Fahrspuren resultierte.

Ausschlaggenend dafür, dass der Ansatz von Atev et al. nicht weiter verfolgt und optimiert wurde, war schlussendlich jedoch die Performance der Clusteranalyse. Für den Trajektoriedatensatz aus Abbildung 6.7, welcher nach der Vorverarbeitung nur 132 Bewegungsbahnen beinhaltet, benötigt die Clusteranalyse bereits über 90 Sekunden. Für einen Datensatz mit über 400 Trajektorien, beträgt die Verarbeitungsdauer über 8 Minuten. Die schlechte Performance lässt sich auf das aufwendige Distanz- und Affinitätsmaß, aber auch auf die mehrfache Durchführung des k-Means Algorithmus zurückführen.

Aufgrund der oben angeführten Problematiken, welche auch bei der Anwendung des Verfahrens auf andere Datensätze auftraten, wurde entschieden, dass der Ansatz nicht weiter verfolgt werden soll. Es wurde ein Ansatz gesucht, welcher mit den beschriebenen Herausforderungen besser umgehen kann.

6.2.2 Ansatz DBSCAN und LCSS

Nachdem das in Abschnitt 6.2.1 beschriebene Verfahren in den Untersuchungen schlechte Ergebnisse lieferte, wurde nach neuen Ansätzen gesucht. Kriterien für diese waren primär, dass sie mit Ausreißern sinnvoll umgehen können, weniger Parametrisierung benötigen beziehungsweise diese intuitiver ist, und sie eine bessere Performance besitzen. Aufgrund dieser Anforderungen wurde untersucht, inwiefern sich der DBSCAN-Clusteralgorithmus in Kombination mit dem LCSS-Distanzmaß für die Clusteranalyse von Trajektoriedaten eignet.

Vorteil des dichte-basierten DBSCAN-Algorithmus, dessen Funktionsweise bereits in Abschnitt 3.2.4 erläutert wurde, ist, dass er Ausreißer erkennt und die Anzahl der Zielcluster selbstständig bestimmen kann. Die auf diese Weise identifizierten Cluster-Sets sind also, ebenso wie bei Atev et al., partitioniert und exklusiv, sind aber außerdem partielle (siehe Abschnitt 3.1.1). Das LCSS Distanzmaß, grundlegend in Abschnitt 3.3.3 beschrieben, ähnelt der modifizierten Hausdorff-Distanz, lässt sich allerdings performanter implementieren und besitzt eine intuitivere Parametrisierung. Es lieferte in den Arbeiten [Morris and Trivedi, 2011] und [Chen et al., 2014] gute Clustering-Ergebnisse.

Das Verfahren

Die Grundgleichung des LCSS Distanzmaßes wurde, basierend auf [Vlachos et al., 2002], bereits in Gleichung 3.11 definiert und ist nachfolgend nochmals dargestellt.

$$LCSS_{\epsilon,\delta}(t_1, t_2) = \begin{cases} 0 & \text{if } t_1 \text{ or } t_2 \in \emptyset \\ 1 + LCSS_{\epsilon,\delta}(t'_1, t'_2) & \text{if } dist(t_1(n), t_2(m)) < \epsilon \\ & \wedge |n - m| \leq \delta \\ max(LCSS_{\epsilon,\delta}(t'_1, t'_2), LCSS_{\epsilon,\delta}(t_1, t'_2)) & \text{otherwise} \end{cases}$$

Mit ihrer Hilfe lässt sich bestimmen, wie groß die längste, übereinstimmende Subsequenz zweier Trajektorien t_1 und t_2 ist. Damit Punkte zweier Trajektorien als übereinstimmend gewertet werden, dürfen sie höchstens die Distanz ϵ zueinander haben und ihre Position in den Bewegungsbahnen sich höchstens um δ unterscheiden. Wenn das Zählmaß, wie oben dargestellt, rekursiv implementiert wird, liegt die Zeitkomplexität des Algorithmus bei $O(2^n)$, was für den Vergleich einer größeren Anzahl von Trajektorien nicht geeignet ist. Die Performance kann auf $O(m n)$ verbessert werden, indem das Maß mit Hilfe von dynamischer Programmierung und *Memoization* umgesetzt wird. Der sich so ergebende Algorithmus ist in Listing 6.2 aufgeführt.

```

1 algorithm LCSS:
2   input: trajectory: t1, trajectory: t2, epsilon, deltaFac
3   output: LCSS distance between t1 and t2
4
5   t1Len := point-length t1
6   t2Len := point-length t2
7   delta := deltaFac * min(t1Len, t2Len)
8   LCS := 2D array with dims. (t1Len+1, t2Len+1)
9
10  for i <- 1 to t1Len do:
11    for j <- 1 to t2Len do:
12      if dist(t1(i-1), t2(j-1)) < epsilon && |i-j| < delta then:
13        LCS(i)(j) = LCS(i-1)(j-1) + 1
14      else
15        LCS(i)(j) = max(LCS(i-1)(j), LCS(i)(j-1))
16      end
17    end
18  end
19
20  return LCS(t1Len)(t2Len)

```

Listing 6.2: Pseudocode LCSS Bestimmung

Der Parameter δ wurde in dieser Implementierung nicht, wie meist üblich, fest definiert, sondern er ergibt sich als ein Teil der Länge der kurzeren Trajektorie (siehe Listing 6.2 Zeile 7). Als Distanzfunktion für das LCSS Zählmaß, wird in dieser Arbeit das von [Vlachos et al., 2002] definierte Maß verwendet:

$$D_{LCSS}(\delta, \epsilon, t_1, t_2) = 1 - \frac{LCSS_{\delta,\epsilon}(t_1, t_2)}{\min(\len(t_1), \len(t_2))}$$

Auf die in Abschnitt 4.1 vorgestellte Erweiterung des Distanzmaßes wurde verzichtet, da es nicht erwünscht ist, formähnliche aber im Raum verschobene Trajektorien, einem Cluster zuzuordnen.

Der DBSCAN Clusteralgorithmus wurde in diesem Fall nicht selbst implementiert. Es wurde die Implementierung der *Statistical Machine Intelligence and Learning Engine*¹ (*Smile*-) Bibliothek verwendet. Der dort angebotene DBSCAN Algorithmus kann beliebige Datenobjekte, unter Verwendung eines vom Anwender definierten Distanzmaßes, gruppieren. Zusätzlich muss lediglich die Größe der gewünschten ϵ -Nachbarschaft und $MinPts$ definiert werden (siehe Abschnitt 3.2.4).

Auswertung des Verfahrens

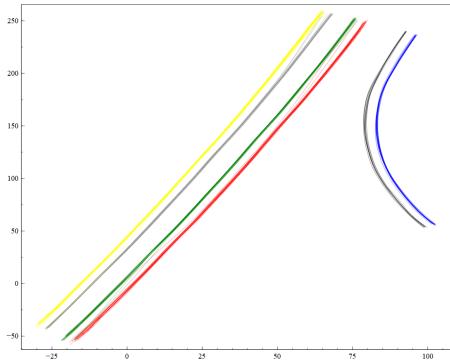
In Abbildung 6.8 sind die Clustering-Ergebnisse des beschriebenen Verfahrens dargestellt. Diese Resultate ergeben sich unter Verwendung der nachfolgenden Parameter, welche auch in den meisten anderen Datensätzen gute Ergebnisse liefern und daher als Standardparameter festgelegt wurden:

$$\begin{aligned}\epsilon_{DBSCAN} &= 0.3 \\ minPts_{DBSCAN} &= 5 \\ \epsilon_{LCSS} &= 1.5 \\ \delta_{LCSS} &= 0.1\end{aligned}$$

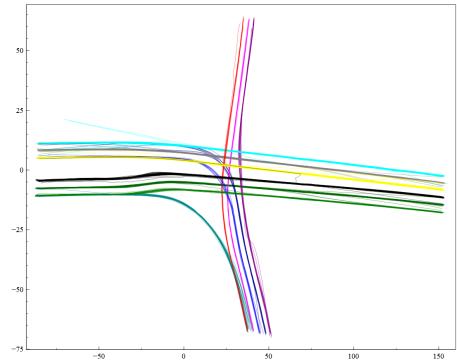
Die Bedeutung der Parameter und Werte ist in diesem Fall leicht und intuitiv verständlich: Punkte zweier Trajektorien dürfen maximal $1.5m$ voneinander entfernt sein und ihre Position sich um maximal $\delta_{LCSS} * minTraLength$ unterscheiden. Sind diese Bedingungen erfüllt, gelten zwei Trajektorie-Punkte als übereinstimmend. Ein Cluster muss zudem aus mindestens fünf Bewegungsbahnen bestehen und die Differenzen der Trajektorie-Distanzen im Cluster untereinander, dürfen nicht größer als 0.3 sein. Für ϵ_{DBSCAN} gilt grundsätzlich: Je stärker sich Fahrspuren überlagern, umso kleiner muss der gewählte Wert sein, da ein kleiner Wert für eine striktere Gruppierung der Trajektorien sorgt. Allerdings sorgt ein kleinerer Wert auch dafür, dass mehr Trajektorien als Ausreißer klassifiziert werden.

Die Ergebnisse aus Abbildung 6.8 a) und b) zeigen, dass bei Verwendung dieses Verfahrens zwischen allen Fahrspuren korrekt unterschieden wird und die einzelnen Trajektorien richtig gruppiert werden. Zudem funktioniert die Bestimmung der Clusteranzahl zuverlässig. Auch die Performance der Clusteranalyse konnte unter Verwendung des DBSCAN Algorithmus und der LCSS-Distanz verbessert werden. Die benötigte Zeit für den Datensatz *Esslingen* sank auf circa 6 Sekunden und die des *Neckartor*-Datensatzes auf etwa 30 Sekunden. Für den vorliegenden Anwendungsfall eignet sich der Ansatz daher gut.

¹ Smile Bibliothek: <https://haifengl.github.io/smile/index.html>



(a) Datensatz Esslingen



(b) Datensatz Neckartor

Abbildung 6.8: Ergebnisse Clusteranalyse Ansatz DBSCAN und LCSS-Distanz - korrekte Unterteilung der Trajektorien in Spur-Cluster in a) und b)

Der DBSCAN Algorithmus markiert atypische Trajektorien als Ausreißer, was den Vorteil hat, dass diese nichtmehr anderen Spurclustern zugeordnet werden. Problematisch ist allerdings, dass Bewegungsbahnen welche Abbiegevorgänge beschreiben und in unterschiedliche Spuren einbiegen, teilweise auch als Ausreißer klassifiziert werden. In Abbildung 6.8 b) fehlen so beispielsweise die Trajektorien der zwei Abbiegespuren im oberen linken und unteren rechten Bereich (vergleiche Abbildung 6.3 a)). Um diese weiterhin erkennen zu können, wurde ein extra Verarbeitungsschritt eingeführt, welcher in Abschnitt 6.2.3 beschrieben wird.

Grundsätzlich überzeugten die Ergebnisse der Clusteranalyse. Die nachfolgend beschriebenen Schritte der Spurerkennung basieren daher auf den Ergebnissen der hier vorgestellten Clustering-Methode.

6.2.3 Erkennung von Abbiegespuren

In Abschnitt 6.2.2 wurde bereits erwähnt, dass, unter Verwendung des gewählten Clustering-Verfahrens, einige Bewegungsbahnen als Ausreißer klassifiziert werden, dies eigentlich jedoch nicht sind. Diese fälschlicherweise aussortierten Trajektorien beschreiben für gewöhnlich Abbiegevorgänge. Problematisch an diesen Trajektorien ist, aus Sicht der Clusteranalyse, dass sie üblicherweise auf einer gemeinsamen Spur – der Abbiegespur – beginnen, sich dann jedoch aufteilen und auf mehrere Fahrspuren verteilen. Die Trajektorien haben aus diesem Grund, trotz anfänglich identischem Verlauf, zu hohe Distanzen zueinander, um als ein Cluster identifiziert zu werden. Hinzu kommt, dass die Anzahl der Fahrzeuge, welche eine Abbiegespur benutzen, häufig nicht hoch genug ist, damit auf Basis einer Abbiege-Variante ein Cluster geformt werden kann. In Abbildung 6.9 a) und b) sind beispielhaft eine Abbiegespur der Neckartor-Kreuzung und die dazugehörigen Trajektorien abgebildet.

Anhand der Straßentopologie und der Trajektorien wird deutlich, dass sich die Fahrzeuge nach dem Abbiegen auf drei Fahrstreifen verteilen.

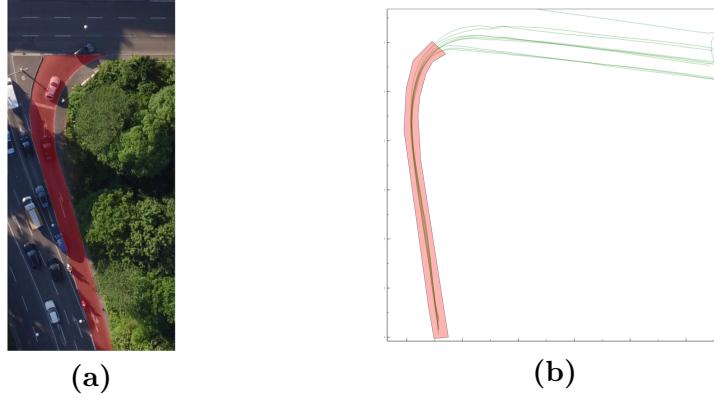


Abbildung 6.9: Abbiegespur der Neckartor-Kreuzung a), zugehörige Trajektorien b)

Ziel des nachfolgend beschriebenen Verarbeitungsschrittes ist es, Trajektorien, welche Abbiegevorgänge beschreiben, zu entsprechenden Clustern zusammenzufassen. Anhand dieser kann anschließend die Geometrie der Spuren, wie für alle anderen Fahrspuren auch, bestimmt werden. Die Cluster sollen hierbei allerdings nicht aus den kompletten Trajektorien gebildet werden, sondern lediglich aus den Teilen, welche anfänglich identisch verlaufen. Dies ist konzeptionell in Abbildung 6.9 b) dargestellt. Notwendig ist dies, da die Trajektorien nach dem Auseinanderlaufen sehr unterschiedliche Bahnen beschreiben und daher keine eindeutigen Spur-Geometrien bestimmt werden können.

Um die oben beschriebenen Spurcluster zu finden, werden ausschließlich die Trajektorien untersucht, welche während der Clusteranalyse als Ausreißer markiert wurden. In einem ersten Schritt wird nach möglichen Trajektorie-Nachbarschaften gesucht. Hierzu wird für jede Trajektorie t der Abstand zwischen deren Start und allen anderen Trajektorie-Starts bestimmt. Liegen mehr als fünf Trajektorie-Anfänge in einem Radius $laneEps = 1.5m$ um den Start von t , so bilden die Trajektorien eine Nachbarschaft. Dass die so gefundenen Trajektorien auch tatsächlich den Verlauf einer Abbiegespur beschreiben und nicht direkt auseinander laufen, wird anschließend geprüft.

Für eine Trajektorie-Nachbarschaft N wird zunächst eine Referenz Bewegungsbahn $refT$ bestimmt, welche den minimalen mittleren Abstand zu allen anderen Trajektorien besitzt:

$$refT_N = N(\arg \min_{t \in N} \left(\frac{1}{|N|} \sum_{tt' \in \{N \setminus t\}} D_{LCSS}(t, tt') \right)) \quad (6.7)$$

Die Referenztrajektorie beschreibt die Nachbarschaft. Im Fall der Trajektorien aus Abbildung 6.9 b) ist es beispielsweise eine Bahn, welche auf die mittlere Fahrspur abbiegt.

Nachdem $refT$ bestimmt wurde, wird die Trajektorie punktweise durchwandert. Es werden die Bereiche um jeden Punkt überprüft, um so festzustellen, wo die Trajektorien der Nachbarschaft auseinanderlaufen. Der hierzu eingesetzte Algorithmus ist in Listing 6.3 vereinfacht beschrieben.

```

1 algorithm findSplitPoint:
2   input: neighborhood: N, reference-trajectory: refT
3   output: point where trajectories of neighborhood split up
4
5   for each point in refT do
6     regionAroundP := create circular region around point with r = laneEps
7     neighborsInReg := count intersections of trajectories with regionAroundP
8
9     if neighborsInReg <= 0.75 * |N| && idx(point) > 0.33 * refT.pointLength then
10       return point
11     end
12   end
13
14  return None

```

Listing 6.3: Pseudocode Split-Punkt Bestimmung

Zur Bestimmung der Regionen um einen Punkt und der Schnittpunkte der Trajektorien mit diesem Bereich, wird die JTS Topology Suite¹ (JTS) eingesetzt. Der Split-Punkt einer Nachbarschaft ist jener Punkt, in dessen Umfeld die Anzahl der Trajektorien erstmals unter 75% fällt. Er ist zudem nur gültig, wenn er nicht im ersten Drittel der Referenztrajektorien liegt.

Nachdem der Split-Punkt einer Nachbarschaft gefunden wurde, werden alle in ihr beinhalteten Bewegungsbahnen an jenem Trajektorie-Punkt geteilt, der dem Split-Punkt am nächsten ist. Die so neu erstellten Trajektorien bilden ein neues Cluster. In Abbildung 6.10 sind alle Spurcluster dargestellt, welche nach diesem Schritt existieren. Die zwei Cluster der Abbiegespuren, welche in Abbildung 6.8 b) noch fehlten, sind nun auch vorhanden.

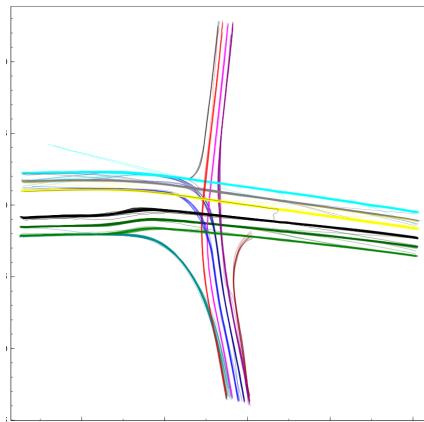


Abbildung 6.10: Ergebnis Clusteranalyse inklusive Abbiegespur-Cluster

1 JTS Topology Suite: <https://locationtech.github.io/jts/>

Mithilfe der oben vorgestellten Verfahren können Trajektorie-Cluster entdeckt werden, welche die einzelnen Fahrspuren in einer Aufnahme beschreiben. Im nachfolgenden Abschnitt wird noch ein zusätzliches Verfahren vorgestellt, mit dessen Hilfe sich die Clusteranalyse automatisch parametrisieren lässt.

6.2.4 Automatische Parametrisierung der Clusteranalyse

Das oben beschriebene Clustering-Verfahren erkennt, unter Verwendung der in Abschnitt 6.2.2 definierten Standardparameter, Spur-Cluster in den meisten Trajektoriedatensätzen zuverlässig. Das Verfahren mit Standardparametrisierung stößt allerdings an seine Grenzen, wenn sich die Trajektorien unterschiedlicher Fahrspuren in einem Datensatz über eine größere Strecke hinweg stark überlagern. Dies ist beispielsweise im Datensatz *Düsseldorf* der Fall, dessen Trajektorien in Abbildung 6.11 a) dargestellt sind. Es ist erkennbar, dass die zwei oben liegenden Fahrspuren sich nach circa 400 Metern auf vier Fahrspuren aufteilen. Herausfordernd für die Clusteranalyse ist zudem, dass der Datensatz sehr viele Bewegungsbahnen beinhaltet, welche Spurwechselvorgänge beschreiben. Das Ergebnis der Clusteranalyse unter Verwendung der Standardparameter für den *Düsseldorf* Datensatz ist in Abbildung 6.11 b) dargestellt.

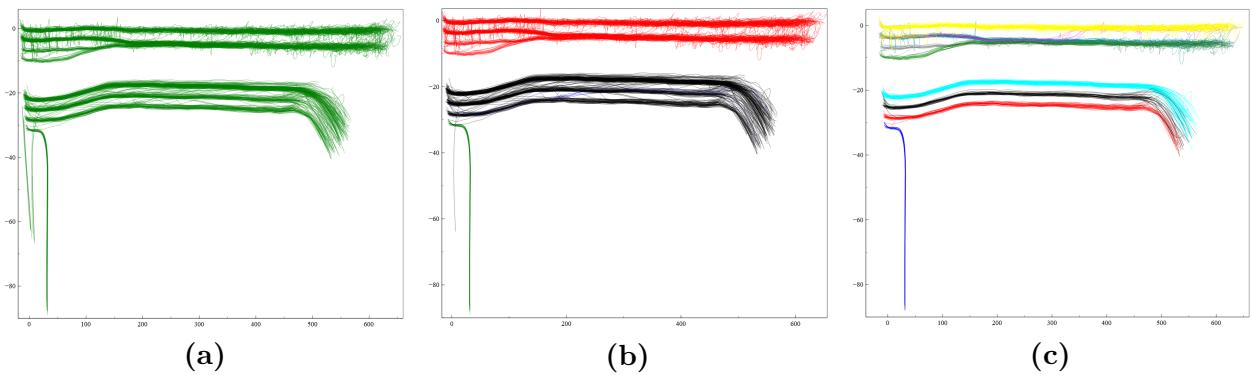


Abbildung 6.11: a) Roh-Trajektorien des Datensatzes *Düsseldorf*, b) Ergebnis der Clusteranalyse unter Verwendung der Standardparameter ($\epsilon_{DBSCAN} = 0.3$), c) Erwünschtes Clustering-Ergebnis unter Verwendung $\epsilon_{DBSCAN} = 0.1$

Es ist erkennbar, dass das Clustering-Verfahren die einzelnen Fahrspuren nicht korrekt identifizieren kann. Das gewünschte Ergebnis wird allerdings erzielt, wenn der Standardwert für den Parameter ϵ_{DBSCAN} von 0.3 auf 0.1 reduziert wird. Um das Verhalten der Clusteranalyse in dieser Hinsicht steuern zu können, wurde dem Nutzer die Möglichkeit gegeben, ϵ_{DBSCAN} beim Start der Spurerkennung anzupassen. Da das manuelle Setzen des Wertes allerdings Expertenwissen voraussetzt, wurde zudem ein Verfahren entwickelt, welches ϵ_{DBSCAN} automatisch anpasst, wenn die identifizierten Spur-Cluster beziehungsweise Fahrspuren nicht mit den realen Spuren übereinstimmen.

Das Verfahren nutzt die Spur-Geometrien, welche auf Basis der identifizierten Spur-Cluster ermittelt werden (siehe Abschnitt 6.3). Mithilfe der Geometrien, welche sich jeweils aus einem Trajektorie-Cluster ableiten, und den Trajektorien des Clusters, lassen sich sogenannte *Weg-Zeit-Diagramme* erstellen, welche die Bewegungen der Fahrzeuge auf einer Fahrspur abbilden. Beschreibt eine ermittelte Spur-Geometrie eine reale Fahrspur korrekt, dann schneiden sich die Trajektorien in dem entsprechenden Weg-Zeit-Diagramm nicht, da die Fahrzeuge auf der Spur hintereinander herfahren und sich nicht überholen können. Ein entsprechendes Diagramm ist in Abbildung 6.12 a) zu sehen. Beschreibt eine Spur-Geometrie hingegen, aufgrund einer fehlerhaften Clusteranalyse, mehrere reale Fahrspuren und ist daher zu breit, dann existieren in dem dafür erstellten Weg-Zeit-Diagramm Überschneidungen von Trajektorien, da die Fahrzeuge sich auf den realen Fahrspuren überholen können. Ein solches Diagramm ist in Abbildung 6.12 b) dargestellt.

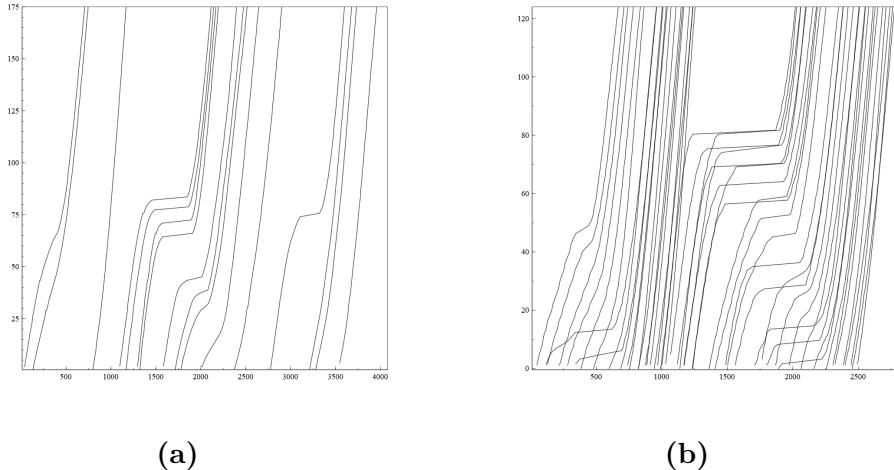


Abbildung 6.12: a) Weg-Zeit-Diagramm ohne Trajektorie-Überschneidungen, b) Weg-Zeit-Diagramm mit Trajektorie-Überschneidungen

Der Algorithmus zur Anpassung des Clustering-Parameters ϵ_{DBSCAN} nutzt die oben beschriebene Eigenschaft der Weg-Zeit-Diagramme, um zu erkennen, ob die ermittelten Spur-Geometrien mit den realen Fahrspuren übereinstimmen, oder ob diese weiter untergliedert werden müssen. Der Ablauf des Verfahrens kann grob wie folgt beschrieben werden:

1. Durchführung der Spurerkennung.
2. Erstellung von Weg-Zeit-Trajektorien auf Basis der Spur-Geometrien.
3. Bestimmung der Anzahl der Überschneidungen in den Weg-Zeit-Trajektorien:
 - a) bei Überschreitung des Grenzwertes ρ : Zurück zu 1) und Anpassung von ϵ_{DBSCAN} , sonst
 - b) Verwendung der ermittelten Spur-Geometrien.

Der Wert für ϵ_{DBSCAN} wird in diesem iterativen Verfahren nicht sukzessive reduziert oder erhöht, sondern es werden verschiedene, vordefinierte Werte getestet, welche in unterschiedlichen Situationen gute Ergebnisse liefern. Unter Verwendung des Verfahrens werden beispielsweise auch im Fall des *Düsseldorf* Datensatzes die erwarteten Spur-Cluster identifiziert, welche in Abbildung 6.11 c) zu sehen sind.

Dank der Parameteranpassung kann das Verhalten der Clusteranalyse automatisch geändert werden, wenn die Ergebnisse nicht die erwartete Qualität besitzen. Dem Nutzer wird dadurch eine eventuell notwendige manuelle Parametrisierung abgenommen.

6.3 Spur-Geometrie Bestimmung

Nachfolgend wird beschrieben, wie aus den identifizierten Trajektorie-Clustern Geometriee-Informationen der Fahrspuren abgeleitet werden. Eine Spur-Geometrie besteht grundlegend aus einer Mittellinie und zwei Hülllinien, welche die Breite der Spur festlegen. Bestimmt werden die Geometrien primär in drei Schritten:

- Bestimmung der Spur-Mittellinien,
- Bestimmung der Spurhüllen und
- Partitionierung sich überlagernder Spuren.

Hinzu kommen weitere Zwischenschritte. Die wichtigsten werden ebenfalls nachfolgend beschrieben.

6.3.1 Ausfilterung von Spurwechselvorgängen

Bevor mithilfe der im vorherigen Schritt gewonnenen Trajektorie-Cluster Mittellinien von Fahrspuren bestimmt werden können, müssen diese nochmals vorverarbeitet werden. Die einzelnen Cluster enthalten teilweise Bewegungsbahnen, welche Spurwechselvorgänge oder andere Abweichungen von einer Fahrspur beschreiben. Diese Trajektorien müssen, so weit wie möglich, entfernt werden, da sie die anschließende Geometrie-Bestimmung negativ beeinflussen. Die Trajektorien eines Clusters sollten möglichst eindeutig einer realen Fahrspur zuzuordnen sein. In Abbildung 6.13 sind beispielhaft zwei Cluster dargestellt, welche eine Vielzahl an Spurwechselvorgängen enthalten.

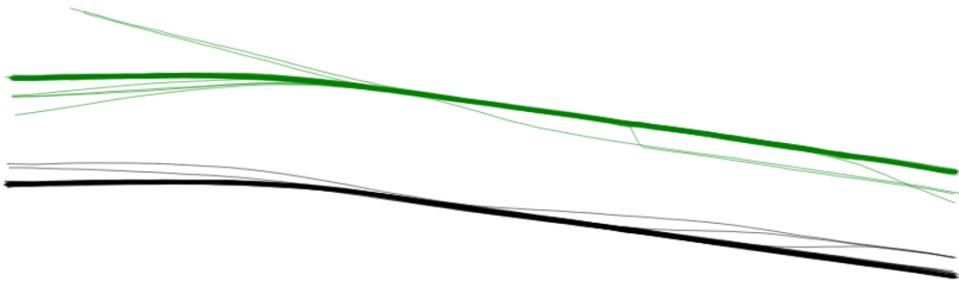


Abbildung 6.13: Trajektorie-Cluster mit Spurwechselvorgängen

Die Grundidee, welche der Ausfilterung der Abweichungen zugrunde liegt, ist, jene Trajektorien aus einem Cluster zu entfernen, welche eine überdurchschnittlich hohe mittlere Distanz zu allen anderen Trajektorien des Clusters besitzen. Als Distanzmaß wird erneut die LCSS-Distanz verwendet. Ein ähnlicher, Distanz-basierter Ausreißer-Detektionsansatz wird in [Mirge et al., 2017] vorgestellt. Der in dieser Arbeit verwendete Algorithmus ist in Listing 6.4 beschrieben.

```

1 algorithm filterCluster:
2   input: unfiltered trajectories of cluster: trajsIn
3   output: filtered trajectories of cluster
4
5   meanTrajectoryDistances :=
6     for each traj in trajsIn do
7       yield mean LCSS distance of traj to all other trajectories of trajsIn
8     end
9
10  clusterCmpVal := select median of meanTrajectoryDistances as comparison value
11
12  resultTrajs :=
13    for each traj in trajsIn do
14      if meanDist of traj < 1.5 * clusterCmpVal then
15        yield traj
16      end
17    end
18
19  return resultTrajs

```

Listing 6.4: Pseudocode Cluster Post-Processing

Das gewählte Verfahren ist einfach, eignet sich aber gut, um das gewünschte Ziel zu erreichen. Die in Abbildung 6.14 dargestellten Ergebnisse zeigen dies. Aus den in Abbildung 6.13 enthaltenen Clustern wurden alle Trajektorien mit Spurwechselvorgängen oder Abweichungen entfernt. Die Effektivität konnte auch durch die Anwendung auf andere Datensätze bestätigt werden. Wenn in einem Cluster viele Trajektorien Abweichungen von einer Spur besitzen, ist es möglich, dass der Algorithmus diese nicht vollständig entfernt. Bei einer geringen Anzahl von Abweichungen oder Ausreißer arbeitet er allerdings zuverlässig.

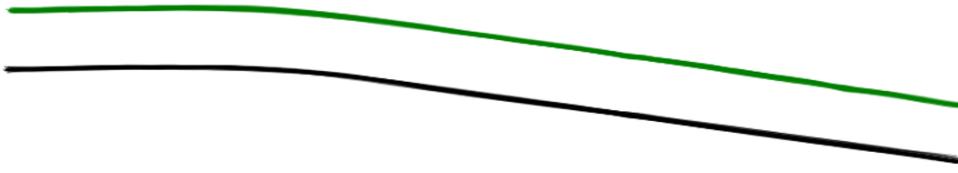


Abbildung 6.14: Bereinigte Trajektorie-Cluster ohne Spurwechselvorgänge

Zu beachten ist, dass die Zeitkomplexität des Verfahrens bei großen Trajektorie-Clustern nicht unerheblich ist. Dies ist auf die Komplexität des LCSS Distanzmaßes zurückzuführen. Bei der Untersuchung alternativer Vorgehensweise wurde allerdings klar, dass es grundlegend schwer ist, das Problem der Ausreißer-Erkennung performant zu lösen. In [Meng et al., 2018] werden hierzu diverse Distanz- und Dichte-basierte Arbeiten vorgestellt und verglichen. Da diese alle allerdings nicht weniger komplex sind und häufig die verfolgten Ziele über die hier geforderten hinausgehen, wurde entschieden den oben beschriebenen Ansatz zu verwenden. Durch die Parallelisierung der Berechnung der mittleren Abstände konnte die Performance des Ansatzes außerdem nochmals deutlich gesteigert werden.

6.3.2 Bestimmung der Spurmittellinien

Nachdem die Trajektorie-Cluster nun weitestgehend von Fahrspurwechseln und anderen Abweichungen bereinigt wurden, beschreiben die verbleibenden Bewegungsbahnen eines Clusters eine Fahrspur. Anhand dieser Trajektorien können daher nun die Mittellinie der Spuren bestimmt werden.

Die gesuchten Mittellinien verlaufen durch die Mitte der entsprechenden Trajektorie-Cluster. Die einzelnen Bewegungsbahnen besitzen jeweils leichte Abweichungen von dieser „*Ideallinie*“. Als Spurmittellinie – wie von [Hu et al., 2005] vorgeschlagen – jene Trajektorie zu wählen, welche die kleinste Summe der Distanzen zu allen anderen Trajektorien eines Clusters besitzt, ist nicht praktikabel, da die so gefundenen Trajektorie nicht über ihre komplett Länge in der Mitte des Clusters verlaufen muss und auch nicht zwangsläufig so lang ist, wie die anderen Trajektorien des Clusters. Auf eine Bestimmung der Mittellinie mittels linearer oder polynomialer Regression, wie beispielsweise in [Chen et al., 2014] oder [Mélo et al., 2006] angewandt, wurde ebenfalls verzichtet. Der Grund hierfür ist, dass einerseits die Komplexität und Form der Fahrbahnverläufe nicht bekannt ist und andererseits das Erlernen der Spurrepräsentationen auf diese Weise sehr aufwendig ist.

Der in dieser Arbeit entwickelte Ansatz zur Bestimmung der Mittellinien macht sich die von Atev et al. vorgestellte Notation einer relativen Position innerhalb einer Trajektorie zu nutze, welche in Gleichung 6.4 und 6.5 gegeben ist. Die Koordinaten der Spurlinien ergeben sich aus den Mittelwerten von Trajektorie-Punkten, welche sich alle an der selben relativen Position befinden. Vorteil der Verwendung der relativen Positionen ist, dass Punkte auf Trajektorien mit einer Position p_r auch dann auf der selben Höhe liegen, wenn

die Bahnen aufgrund von Oszillationen um die Spurmitte unterschiedliche Längen haben. Der verwendete Algorithmus ist nachfolgend beschrieben.

```

1 algorithm calculateCenterline:
2   input:  trajectories of cluster: trajsIn
3   output: centerline of lane
4
5   meanTrajLength := calculate mean point length of trajectories
6   relPositions := define range with relative positions of size meanTrajLength
7       and step-size (1 / meanTrajLength)
8
9   centerline :=
10    for each relP in relPositions do
11      pointsAtRelPos := get points at relP for each traj in trajsIn
12      yield mean of all points in pointsAtRelPos
13    end
14
15  return centerline

```

Listing 6.5: Pseudocode Mittellinien-Bestimmung

Da die Form und der Verlauf von Trajektorien eines Clusters sich nur wenig unterscheiden, liefert dieses Vorgehen gute Ergebnisse. In Abbildung 6.15 a) ist beispielhaft dargestellt, wie eine Mittellinien innerhalb eines Trajektorie-Clusters verläuft. In 6.15 b) sind alle Spurmittellinien in der Neckartor-Kreuzung abgebildet, welche auf die oben beschriebene Weise bestimmt wurden.



Abbildung 6.15: Spurmittellinie in einem Trajektorie-Cluster a), Spurmittellinien Neckartor-Kreuzung b)

Das beschriebene Verfahren kann, im Gegensatz zu den meisten Ansätzen welche in den verwandten Arbeiten zum Einsatz kommen, Spurmittellinien für unterschiedlichste Spurverläufe ermitteln. Diese werden, da es sich bei ihnen ebenfalls um Sequenzen von 2D-Koordinaten handelt, im Algorithmus über Trajektorie-Objekte repräsentiert (siehe Abbildung 6.2).

6.3.3 Angleichung benachbarter Spurenden

Bevor für jede Spurmittellinie eine Hülle definiert wird, werden benachbarte Spurenden aneinander angeglichen. Diese sollen immer auf der selben Höhe beginnen beziehungsweise enden, um die Positionen von Fahrzeugen auf benachbarten Spuren bei der Verkehrsanalyse besser vergleichen zu können.

Benachbarte Fahrspuren können einen deutlich sichtbaren Versatz an ihren Anfängen und Enden besitzen, was beispielsweise in Abbildung 6.17 a) dargestellt ist. Diese Unterschiede entstehen primär, da Fahrzeuge am Rand der Aufnahme verschieden schnell erkannt werden und so deren Trajektorien unterschiedlich früh beginnen. Für das Angleichen der Spurenden sind grundlegend drei Schritte notwendig: Finden von benachbarten Enden, Bestimmung der längsten Spur im Bereich der Enden und schließlich das Angleichen aller Spuren auf die Höhe der vorher bestimmten “äußersten” Mittellinie.

Gruppen benachbarter Spurenden werden auf rekursive Weise gefunden. Es wird eine Spur gewählt und im Bereich ihres Starts beziehungsweise Endes nach unmittelbaren Nachbarn gesucht. Das hierzu verwendete Verfahren ist in Abschnitt 6.3.4 beschrieben. Für jede der so gefundenen Nachbarspuren wird wiederum nach deren Nachbarn gesucht. Auf diese Weise ergibt sich eine Spur-Gruppe.

Da das Weltkoordinatensystem in den verwendeten Aufnahmen keine feste Orientierung und keinen fixen Ursprung besitzt, kann die in einer Spur-Gruppe am weitesten außen liegende Spur nicht identifiziert werden, indem die Koordinaten der Start- oder Endpunkte der Spuren verglichen werden. Bestimmt wird die “äußerste” Mittellinie daher, indem durch jeden Endpunkt der Spuren einer Gruppe eine orthogonale Gerade gelegt wird. Die Spur deren zugehörige Gerade die wenigsten Schnittpunkte mit anderen Spur-Mittellinien besitzt, liegt am weitesten außen. Abbildung 6.16 veranschaulicht das Vorgehen.

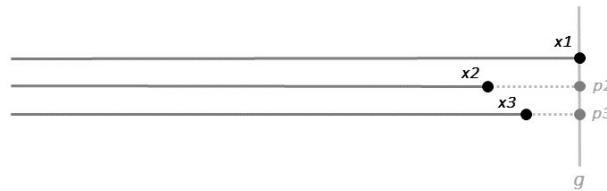


Abbildung 6.16: Konzept Spurenden-Angleichung

Die so bestimmte Gerade g ist zudem gleichzeitig die Linie, auf welche die anderen Spur-Endpunkte projiziert werden. Hierzu wird eine Orthogonalprojektion der Endpunkte auf die Gerade g durchgeführt, welche in Gleichung 6.8 definiert ist. \vec{r}_0 entspricht hierbei einem Stützvektor auf der Geraden g und \vec{u} dem Richtungsvektor.

$$P_g(\vec{x}) = \vec{r}_0 + \frac{(\vec{x} - \vec{r}_0) \cdot \vec{u}}{\vec{u} \cdot \vec{u}} \vec{u} \quad (6.8)$$

Das Ergebnis der Spurenden-Angleichung ist in Abbildung 6.17 b) dargestellt.

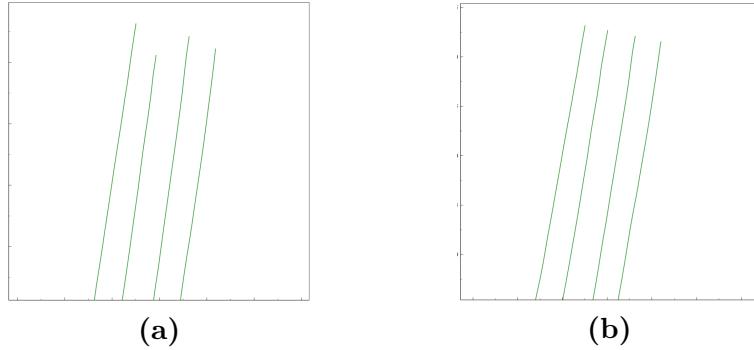


Abbildung 6.17: Fahrspur-Mittellinien ohne Angleichung a) und Ergebnis mit Angleichung b)

Nachdem die Enden der Spurmittellinien aneinander angeglichen wurden, werden anschließend die Spurhüllen definiert.

6.3.4 Bestimmung der Spurhüllen

Auf Basis der bestimmten Mittellinien werden anschließend die Spurhüllen definiert. In folgendem Abschnitt wird das hierzu eingesetzte Verfahren beschrieben.

Eine Spurhülle definiert die Breite einer Fahrbahn. In dieser Arbeit verlaufen sie idealerweise entlang realer Begrenzungslinien, welche zwei Spuren voneinander oder eine Fahrbahn von einem Seitenstreifen et cetera trennen. Eine Mittellinie und eine Hülle beschreiben zusammen die Geometrie einer Fahrspur. Diese Geometrie soll die realen Dimensionen einer Spur möglichst genau abbilden. Aus diesem Grund ist es nicht möglich, die Hüllen lediglich auf Basis von statistischen Informationen der Trajektorie-Cluster zu bestimmen, wie das beispielsweise in [Weiming et al., 2006] oder [Morris and Trivedi, 2011] gemacht wird. Der in dieser Arbeit verwendete Ansatz zur Bestimmung der Spurhüllen basiert daher lediglich auf den Spurmittellinien und nutzt deren relative Lage zueinander. Ansätze hierzu stammen aus den Arbeiten von [Hsieh et al., 2006] und [Makris and Ellis, 2005], welche in Abschnitt 4.2 vorgestellt wurden.

Die grundlegende Idee, auf welcher die Bestimmung der Spurhüllen basiert, ist konzeptiell in Abbildung 6.18 dargestellt. Für zwei parallel zueinander verlaufende Spuren l_1 und l_2 werden die Hüllen über den Abstand zwischen ihren Mittellinien bestimmt. Besitzen die Linien den Abstand d zueinander, so beträgt die Breite der Spuren ebenfalls d . Der Abstand e_d zwischen einer Mittellinie und einer Hülllinie beträgt folglich $1/2 d$.

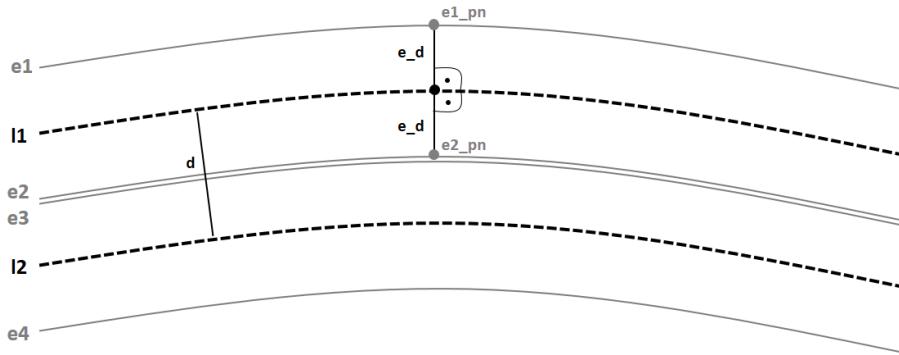


Abbildung 6.18: Konzept Bestimmung Spürhüllen - Ermittlung der Spurbreiten anhand des Abstandes paralleler Spuren

Die oben beschriebene Definition einer Bahn-Geometrie wird im Spurerkennungs-Modul über eine Klasse *LaneGeometry* repräsentiert. Diese ist in Abbildung 6.19 dargestellt. Das Feld *variance* entspricht dem Abstand e_d zwischen der *centerline* und den Hülllinien.

LaneGeometry	
+ id: Int	
+ variance: Double	
+ centerline: Trajectory	
+ envelopeLine1: Vector[Point]	
+ envelopeLine2: Vector[Point]	

Abbildung 6.19: Aufbau LaneGeometry Klasse

Einen ähnlichen Ansatz zur Bestimmung von Spurbegrenzungslinien verwenden auch Hsieh et al. in ihrer Arbeit. Sie gehen jedoch, da die von ihnen verwendeten Aufnahmen von einer statischen Kamera über einer Autobahn stammen, davon aus, dass alle Fahrspuren parallel zueinander verlaufen. Da das in dieser Arbeit entwickelte Spurerkennungs-Modul mit unterschiedlichen Aufnahmen und Straßentopologien umgehen können muss, kann diese Annahme nicht getroffen werden. Nachfolgend werden die Schritte vorgestellt, welche angewandt werden, um in einer Menge von Spuren jene zu finden, welche parallel zueinander verlaufen. Auf deren Basis werden anschließend die Spurbreiten bestimmt und die Hülllinien definiert.

Identifikation paralleler Fahrspuren

Um in einer Menge von Fahrspuren, welche über Mittellinien repräsentiert werden, jene zu finden, die parallel zueinander verlaufen, werden in einem ersten Schritt benachbarte Spur-Paare gesucht. Zwei Fahrspuren l_1 und l_2 gelten als benachbart, wenn sich der Start oder das Ende von Spur l_2 in einem Bereich mit Radius σ um den Start von l_1 befindet. Der Wert für σ wurde auf Basis der in Deutschland geltenden „Richtlinien für die

Anlage von Autobahnen“ (RAA) [FGSV, 2008] und der “*Richtlinien für die Anlage von Landstraßen*” (RAL) [FGSV, 2012] bestimmt. Diese Regelwerke spezifizieren die in der Bundesrepublik derzeit zulässigen Straßenquerschnitte. Die in ihnen festgelegten Spurbreiten variieren zwischen 2.75 und 3.75 Metern. Um auch besonders breite benachbarte Spur-Paare identifizieren zu können, wurde für σ der Wert 4m gewählt.

Die auf diese Weise gefundenen Trajektorie-Paare starten oder enden als benachbarte Spuren. Der Algorithmus welcher prüft, ob zwei Spuren tatsächlich parallel zueinander verlaufen, ist in Listing 6.6 beschrieben. Die zu vergleichenden Mittellinien werden jeweils in eine Reihe von Richtungsvektoren umgewandelt. Anschließend werden paarweise die Winkel zwischen zwei Vektoren berechnet und die Ergebnisse gemittelt. Liegt die sich so ergebende Abweichung unter einem Grenzwert δ , so handelt es sich um parallele Spuren. Zusätzlich wird geprüft, ob die Spuren eine ähnliche Länge besitzen.

```

1 algorithm lanesAreParallel:
2   input: lane-centerline: 11, lane-centerline: 12, delta
3   output: True or False
4
5   inOppositeDirections := check if 11 and 12 run in opposite directions
6   if inOppositeDirections then
7     reverse points of centerline 12
8   end
9
10  l1DirectionVec := calculate direction vectors for 11
11  l2DirectionVec := calculate direction vectors for 12
12  dirDifferences := calculate pairwise the angle between two direction vectors
13
14  meanDiff := calculate mean angle of deviation between 11 and 12
15  lengthDiff := calculate difference between length of 11 and 12
16
17  return meanDiff < delta && lengthDiff >= 0.8

```

Listing 6.6: Pseudocode Überprüfung der Parallelität zweier Mittellinien

Für δ wurde experimentell der Wert 0.1 bestimmt. In den verschiedenen Test-Datensätzen konnten so zuverlässig parallele Spur-Paare identifiziert werden. Anhand dieser werden im nächsten Schritt die Spurhüllen bestimmt.

Berechnung der Hüllen

Bevor für eine Mittellinie die sie umgebende Spurhülle definiert werden kann, muss die Breite der Spur ermittelt werden. Diese ergibt sich, für die im vorherigen Schritt identifizierten parallelen Spur-Paare, aus deren mittleren Abstand zueinander. Verlaufen zu einer Spurlinie zwei Bahnen parallel, werden die Abstände zu beiden berechnet und der kleinere Wert wird als Spurbreite gewählt. Allen Bahnen, welche keine parallele Nachbarspur besitzen, wird das Minimum der im vorherigen Schritt bestimmten Spurbreiten zugeordnet. Falls sich in einer Aufnahme keine parallelen Spuren befinden, wird für die Spurbreite ein Standartwert von 3.5 Metern verwendet, welcher sich ebenfalls aus den RAA und RAL Richtlinien ableitet.

Nachdem die Breiten für alle Fahrspuren bestimmt wurden, können die Hülllinien berechnet werden. Hierzu werden für jeden Punkt einer Mittellinie zwei zugehörige Hüllpunkte berechnet. Das verwendete Vorgehen ist in Abbildung 6.20 dargestellt.

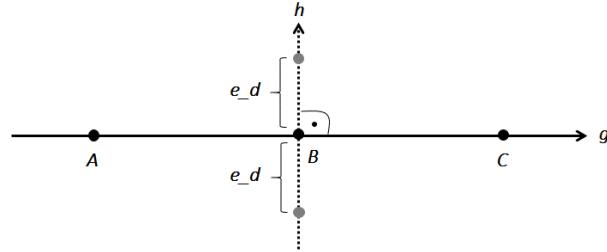


Abbildung 6.20: Konzept Berechnung Spurhüllpunkte

Um die Hüllpunkte für einen Punkt B einer Mittellinie zu bestimmen, wird eine Gerade g durch die Punkte A und C gelegt, welche sich vor und hinter B befinden.

$$g : \vec{x} = \overrightarrow{OA} + t \cdot \overrightarrow{AC} \quad (6.9)$$

Anschließend wird durch B eine Gerade h gelegt, welche orthogonal zu g verläuft.

$$h : \vec{x} = \overrightarrow{OB} + t \cdot \hat{X} \quad (6.10)$$

Für ihren Richtungsvektor \hat{X} , welcher sich aus \overrightarrow{AC} ergibt, gilt $\overrightarrow{AC} \cdot \hat{X} = 0$. Da \hat{X} ein Einheitsvektor ist, können die Hüllpunkte, welche auf h liegen und den Abstand e_d von B besitzen, einfach bestimmt werden, indem e_d beziehungsweise $-e_d$ für t in die Geradengleichung von h eingesetzt wird.

Auf diese Weise werden die Hülllinien für alle Fahrspuren bestimmt. In Abbildung 6.21 sind die Ergebnisse der Spur-Geometrie-Bestimmung dargestellt. Teil a) zeigt die Spurmittellinien mit ihren sie umgebenden Hüllen in einem Plot. Teil b) zeigt die in die Anwendung *Vehicle-Tracker* visualisierten Spuren.

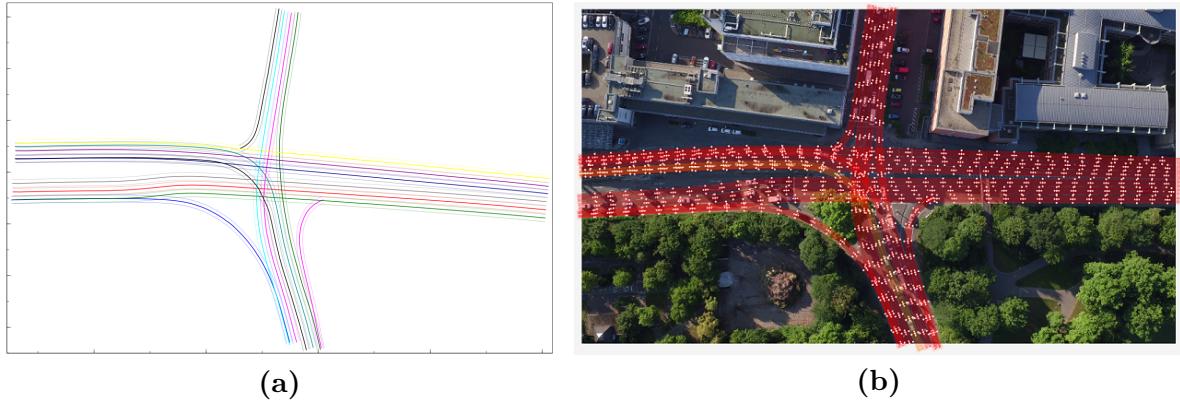


Abbildung 6.21: Plot Spur-Geometrien a), Ergebnis Visualisierung Spur-Geometrien in *Vehicle-Tracker* Applikation b)

Die obige Abbildung zeigt, dass die berechneten Spur-Geometrien in den meisten Fällen bereits gut mit den realen Spur-Dimensionen übereinstimmen. Bevor die Spuren partitioniert werden, um Überlagerungen von Fahrspuren zu entfernen, werden in einem weiteren Schritt Pseudo-Spur-Geometrien entfernt.

Entfernung von Pseudo-Spur-Geometrien

Mit Pseudo-Spur-Geometrien sind jene Geometrien gemeint, welche keine real existierende Fahrspur beschreiben. Am häufigsten treten Pseudo-Fahrspuren in Form von zu kurzen Geometrien auf, oder in Form von Geometrien, welche einen Spurwechsel beschreiben. Diese zwei Arten von Spur-Geometrien werden daher identifiziert und entfernt. Beispiele für solche Geometrien sind in Abbildung 6.22 dargestellt.

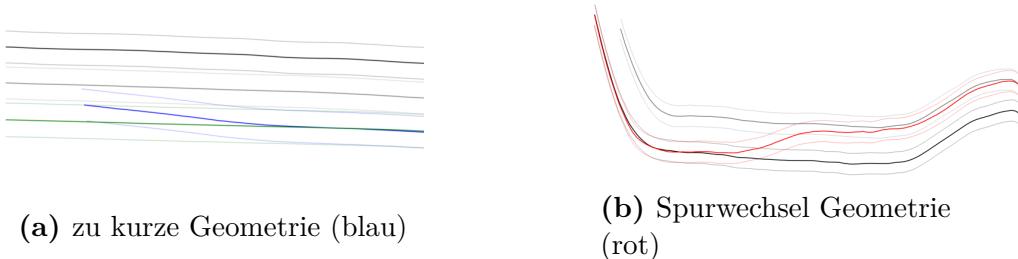


Abbildung 6.22: Beispiele Pseudo-Spur-Geometrien

Zu kurz ist eine Spur-Geometrie dann, wenn sie einen Streckenabschnitt beschreibt, welcher gleichzeitig noch von einer anderen, längeren Spur beschrieben wird. Sie wird daher gänzlich oder fast gänzlich überlagert. Diese Art von Pseudo-Spur ist leicht zu identifizieren. Es wird für jede Spur geprüft, ob eine andere Spur existiert, welche sie zu 95% oder

mehr überlagert. Wie die Überlagerung von zwei Spuren bestimmt wird, ist in Abschnitt 6.3.5 beschrieben.

Geometrien, welche nicht eine Spur sondern den Wechsel zwischen zwei Spuren darstellen, können existieren, wenn die Trajektoriedaten viele Spurwechselvorgänge enthalten und in der Clusteranalyse für diese ein extra Cluster erstellt wird. Um diese Spuren zu identifizieren, müssen Kriterien eines Spurwechselvorgangs definiert werden. Diese zeichnen sich primär dadurch aus, dass sie auf einer Spur A beginnen und auf einer Spur B enden, wobei die Spuren A und B parallel zueinander verlaufen. Es kann zudem davon ausgegangen werden, dass sich weniger Fahrzeuge auf einer Spurwechsel-Spur bewegen, als auf den zwei eigentlichen Fahrspuren. Auf Basis dieser Eigenschaften, ergibt sich der nachfolgende Algorithmus.

```

1 algorithm isLaneChangeLane:
2   input: lane-geo: l1, sequence of other lane-geos: otherGeos
3   output: True or False
4
5   overlaysAtStart := find lanes in otherGeos that are overlaid by l1 at its start
6   overlaysAtEnd := find lanes in otherGeos that are overlaid by l1 at its end
7
8   if overlaysAtStart.nonEmpty && overlaysAtEnd.nonEmpty then:
9     a := identify more traveled parallel lanes in overlaysAtStart
10    b := identify more traveled parallel lanes in overlaysAtEnd
11    return a.nonEmpty && b.nonEmpty
12  else return false
13 end

```

Listing 6.7: Pseudocode Identifikation Spurwechsel-Spur

Eine Spurwechsel-Spur muss also im Bereich ihres Starts und ihres Endes jeweils mindestens eine andere mehr befahrene, parallele Fahrspur überlagern. Nachdem auf diese Weise die Pseudo-Spur-Geometrien entfernt wurden, werden die übrigen partitioniert.

6.3.5 Partitionierung von Fahrspuren

Fahrspuren, welche mithilfe dieser Arbeit erkannt werden, kommen bei der Verkehrsanalyse zum Einsatz. Unter anderem können mit ihrer Hilfe Spurwechsel- oder Überholvorgänge von Fahrzeugen untersucht werden. Damit eine solche Analyse sinnvoll ist, dürfen sich Fahrspuren nicht über einen größeren Bereich hinweg überlagern. Aus diesem Grund werden Spuren, welche in Teilen identisch mit anderen verlaufen, partitioniert. Die identischen Teile werden verworfen und nur die separaten beibehalten. Unproblematisch ist es, wenn sich Spuren lediglich kreuzen, ihre Überlagerung also geringfügig ist. In diesem Fall werden die Spuren nicht partitioniert. Es wird daher zwischen sich überlagernden und sich kreuzenden Spuren unterschieden. Nachfolgend wird das Verfahren zur Identifikation von sich überlagernden Fahrspuren und der Partitionierungs-Vorgang beschrieben.

Um Fahrspuren zuverlässig und sinnvoll partitionieren zu können, müssen grundlegend zwei Probleme bewältigt werden. Es müssen zuerst die sich überlagernden Spur-Paare und

deren Schnittpunkte gefunden werden und anschließend muss für jedes Paar entschieden werden, welche Spur partitioniert wird und welche erhalten bleibt. Hierzu werden die Spur-Geometrien zuerst in drei Kategorien unterteilt:

- isolierte Fahrspuren
- primäre Fahrspuren
- sekundäre Fahrspuren

Isolierte Fahrspuren sind hierbei jene, welche keine Überschneidung mit anderen Spuren besitzen. Primäre Fahrspuren besitzen keine Überschneidungen untereinander, können sich aber mit anderen Spuren kreuzen oder von ihnen überlagert werden. In einer Menge von Spur-Geometrien bildet das größte Subset von parallel zueinander verlaufenden Spuren die primären Fahrspuren. Sekundäre Fahrspuren sind all jene, welche weder isoliert noch primär sind. In Abbildung 6.23 sind die primären und sekundären Spur-Geometrien der Neckartor-Kreuzung dargestellt.

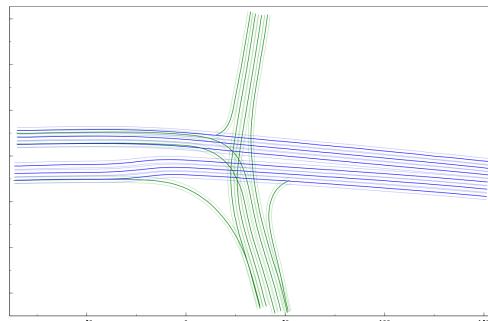


Abbildung 6.23: Primäre (blau) und sekundäre (grün) Spuren auf einer Kreuzung

Nachdem die Fahrspuren, anhand der oberen Definition, in die drei Kategorien unterteilt wurden, werden anschließend die primären und sekundären Spuren nach sich überlagern- den Paaren durchsucht. Zwei Spuren überschneiden sich, wenn, wie in Abbildung 6.24 zu sehen, die Mittellinie einer Spur innerhalb der Hülle einer anderen Spur liegt. Die Punkte b_1 und b_2 entsprechen hierbei den äußeren und inneren Grenzpunkten der Überschneidung der Mittellinie von l_2 mit der Hülle von l_1 . Zur Bestimmung der Schnittmenge wird die JTS Topology Suite eingesetzt.

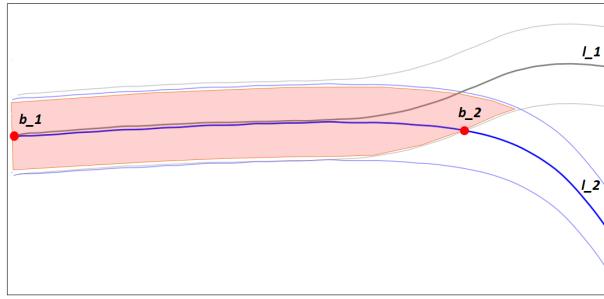


Abbildung 6.24: Überlagerung zweier Spur-Abschnitte (roter Bereich) zwischen den Punkten b_1 und b_2

Zwei Spuren l_1 und l_2 kreuzen sich nicht nur, sondern überlagern sich, wenn der Abschnitt zwischen den Grenzpunkten b_1 und b_2 mindestens 10% der Spurlänge ausmacht. Auf diese Weise werden die sich überlagernden Spur-Paare und die zugehörigen Schnittpunkte bestimmt. Aus jeder Überschneidung ergeben sich zwei Spur-Paare. Im Fall von Abbildung 6.24 wird einerseits l_1 von l_2 überlagert und andererseits l_2 von l_1 .

Es kann vorkommen, dass in einem Bereich, in welchem sich zwei Spuren überlagern, die Mittellinie der einen Spur sich kurzzeitig außerhalb der Hülle der anderen befindet. Bei der Bestimmung der überlagerten Bereiche, wie oben beschrieben, würde dies dazu führen, dass zwei Überlagerungen statt einer erkannt werden. Um mit einer solchen Situation korrekt umzugehen, werden die identifizierten Schnittmengen zwischen zwei Spuren fusioniert, falls die Distanz zwischen ihnen sehr gering ist. Hiervon wird sichergestellt, dass eine Spur anschließend nicht fälschlicherweise zweimal oder zu früh beziehungsweise zu spät partitioniert wird.

Nachdem die sich überlagernden Spur-Paare bestimmt wurden, wird anschließend entschieden, welche Spur der Paare partitioniert wird und welche erhalten bleibt. Zuerst wird hierzu überprüft, ob es sich bei einer der Geometrien um eine primäre Fahrspur handelt. Ist dies der Fall, so bleibt diese erhalten. Existiert in einem Paar keine primäre Spur, so werden verschiedene Eigenschaften der Fahrspuren untersucht, um eine Entscheidung zu treffen, welche Geometrie zu partitionieren ist. Der hierzu verwendete Algorithmus ist vereinfacht in Listing 6.8 dargestellt.

Grundlegend wird zuerst das Krümmungsverhalten der zwei Fahrspuren im Bereich ihres Schnittpunktes untersucht. Liegt die Differenz der Krümmungen der beiden Spuren oberhalb eines Grenzwertes δ , so wird jene Spur partitioniert, welche die höhere Krümmung besitzt. Die Annahme ist, dass es sich bei dieser Spur mit höherer Wahrscheinlichkeit um eine Abbiegespur et cetera handelt, welche in eine gerade Spur übergeht. Ist die Differenz der Krümmungen kleiner als δ , so verlaufen die zwei Spuren im Bereich des Schnittpunktes annähernd parallel. In diesem Fall wird entweder anhand der Länge oder der Fahrzeuganzahl entschieden, welche Spur geteilt wird. Der Anwender des *Vehicle-Trackers* kann das Verhalten des Algorithmus an dieser Stelle über einen Parameter steuern. Standardmäßig

ßig wird die Anzahl der Fahrzeuge, welche sich auf einer Spur befinden, als Kriterium verwendet.

```

1 algorithm selectLaneGeometryForPartitioning:
2   input: lane-geo: l1, lane-geo: l2, boundPoints: bounds
3   output: l1 or l2 based on curviness around bounds
4
5   innerBoundPoint := select inner bound point based on distance
6       from b1 and b2 to the edges of l1
7
8   l1Subset := get subset of l1 around innerBoundPoint
9   l2Subset := get subset of l2 around innerBoundPoint
10
11  l1CurvMea := estimate curvature of l1Subset
12  l2CurvMea := estimate curvature of l2Subset
13
14  if | l1CurvMea - l2CurvMea | > delta then
15    partition lane with bigger curvMea
16  else
17    if check length? then partition shorter lane
18    if check vehicle-count? then partition lane with less vehicles
19  end

```

Listing 6.8: Pseudocode Auswahl zu partitionierende Fahrspur

Im Fall der sich überlagernden Spur-Paare in Abbildung 6.24 ist b_2 der *innerBoundPoint*. Zur Bestimmung der Krümmung einer Fahrspur in einem Bereich, siehe Listing 6.8 Zeile 11 + 12, wird der Winkel φ zwischen den Richtungsvektoren des Anfang und Endes der Teilstpur berechnet. Er ergibt sich anhand Gleichung 6.11.

$$\varphi = \arccos \frac{\vec{a} \cdot \vec{b}}{|\vec{a}| |\vec{b}|} \quad (6.11)$$

Nachdem alle zu teilenden Spuren und die zugehörigen Grenzpunkte bestimmt wurden, folgt die eigentliche Partitionierung. Aus den Spur-Geometrien werden alle Bereiche entfernt, welche zwischen den zwei Grenzpunkten einer Überlagerung liegen. In Abbildung 6.24 wird so beispielsweise der rot gekennzeichnete Bereich der Spur l_2 zwischen b_1 und b_2 entfernt.

Abbildung 6.25 zeigt das Ergebnis der Spur-Partitionierung im Fall des *Neckartor* Datensatzes. Es wurden alle Spur-Überlagerungen entfernt.

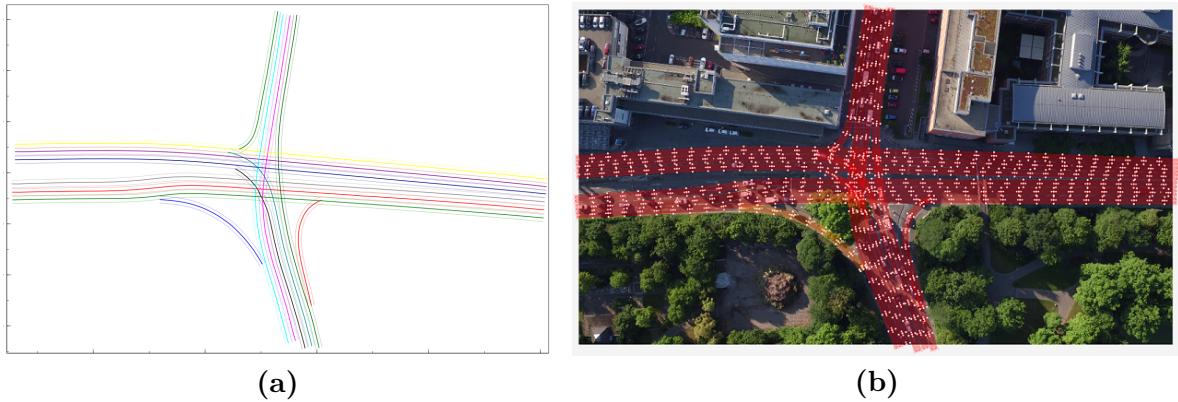


Abbildung 6.25: Plot der partitionierten Spur-Geometrien a), Visualisierung der Ergebnisse in der Anwendung *Vehicle-Tracker* b)

Die so ermittelten Spur-Geometrien entsprechen in den meisten Fällen bereits dem gewünschten Ergebnis, da sie die realen Fahrspurverläufe gut wiederspiegeln und keine Überlagerungen mehr existieren. In einigen Szenarien kann es jedoch vorkommen, dass nach der Geometrie-Ermittlung und der Partitionierung die Fahrspur-Geometrien die reale Straßen-topologie noch nicht korrekt abbilden. Aus diesem Grund werden die Spur-Geometrien in einem weiteren Schritt nochmals optimiert.

6.3.6 Optimierung der Spur-Geometrien

Die nach dem Partitionierungs-Schritt vorliegenden Spur-Geometrien besitzen in einigen Fällen noch Defekte. Das am häufigsten auftretende Problem ist, dass die Spur-Geometrien nicht breit genug sind. Abbildung 6.26 zeigt beispielsweise die Spur-Geometrien eines Straßen-Abschnitts, in welchem sich rechts zwei parallele Fahrspuren befinden, welche sich links in vier Spuren aufteilen. Es ist erkennbar, dass die zwei Fahrspuren zu Beginn nicht direkt aneinander angrenzen und daher in diesem Abschnitt nicht breit genug sind. In diesem Fall resultiert die zu niedrige Fahrbahnbreite aus der starken Überlagerung der vier Spur-Geometrien im rechten Bereich vor deren Partitionierung. Diese verursacht eine falsche Schätzung der Spurbreite (siehe Abschnitt 6.3.4).

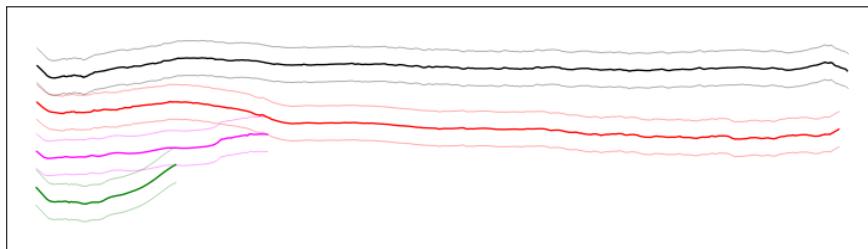


Abbildung 6.26: Beispiel zu schmaler Spur-Geometrien - Parallelle rote und schwarze Spur-Geometrien grenzen nicht aneinander an

Um Effekte wie diesen zu korrigieren, werden nach der Partitionierung nochmals die Breiten aller Spur-Geometrien neu bestimmt. Im Gegensatz zu dem verwendeten Vorgehen aus Abschnitt 6.3.4, bei welchem für jede Spur eine feste Breite berechnet wurde, wird diese nun für jeden Punkt der Spur einzeln berechnet. Hierdurch wird es möglich, dass beispielsweise die rote und grüne Spur aus Abbildung 6.26 zu Beginn breiter sind, als an ihrem Ende.

Der zur Bestimmung der neuen Spurbreiten eingesetzte Algorithmus hat vereinfacht den nachfolgenden Ablauf:

- Wähle eine Spur-Geometrie l
- Für jeden Punkt p der Mittellinie von l mit Position i :
 - Suche korrespondierende Punkte $P_k = \{pk_0 \dots pk_n\}$ auf benachbarten Spuren
 - Wähle einen benachbarten Punkt $pk_j \in P_k$
 - Verwende die Distanz zwischen p und pk_j als Spurbreite von l an Position i

Entscheidend bei diesem Verfahren ist es, den richtigen Punkt pk_j auszuwählen. Dieser muss grundsätzlich auf jener Spur liegen, welche im Bereich des Punktes p parallel zu l verläuft und ihr am nächsten liegt.

Nachdem auf diese Weise für eine Spur punktweise die neuen Breiten bestimmt wurden, werden diese noch mithilfe eines gleitenden Mittelwert Verfahrens geglättet. Anschließend werden neue Spurhüllen, mittels dem in Abschnitt 6.3.4 vorgestellten Vorgehen, erzeugt. Das Ergebnis der Geometrie-Optimierung für den Fall der in Abbildung 6.27 enthaltenen Spuren, ist nachfolgend dargestellt.

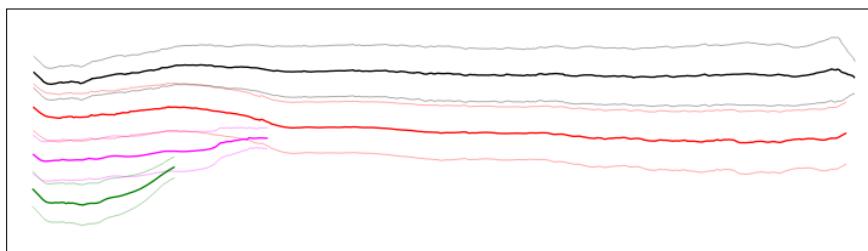


Abbildung 6.27: Ergebnis Spur-Optimierung - rote und schwarze Spuren grenzen aneinander an

Die Fahrspurerkennung ist nach dem Optimierungsschritt abgeschlossen. Auf Basis der vorliegenden Spur-Geometrien können anschließend die Spuren in die Anwendung *Vehicle-Tracker* eingefügt werden.

6.3.7 Anlegen der Fahrspuren in der Anwendung Vehicle-Tracker

Nachdem die Spur-Geometrien auf Basis der Fahrzeugtrajektorien bestimmt wurden, müssen diese in einem finalen Schritt noch in das von der *Vehicle-Tracker* Applikation verwendete Datenmodell zur Repräsentation von Fahrspuren überführt werden. Dieses Vorgehen ist nachfolgend beschrieben.

Wie bereits zu Beginn der Arbeit erwähnt, wurden Fahrspuren bislang manuell über die Benutzeroberfläche der *Vehicle-Tracker* Anwendung angelegt. Das verwendete Datenmodell, welches auch weiterhin für die automatisch erkannten Spuren verwendet wird, ist in Abbildung 6.28 dargestellt.

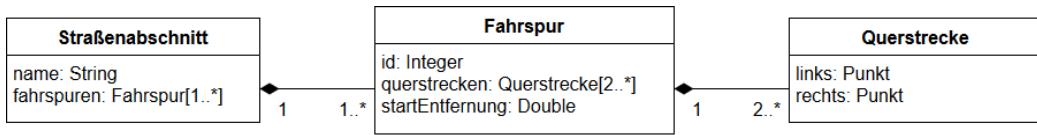


Abbildung 6.28: Datenmodell der Fahrspurdefinition

Eine Fahrspur in einem Streckenabschnitt besteht aus mindestens zwei *Querstrecken*. Jede Querstrecke legt über zwei Punkte die Breite der Fahrspur auf einer bestimmten Höhe der Spur fest. Eine Fahrspur kann aus beliebig vielen Querstrecken bestehen, wodurch es möglich ist, die Fahrspuren beliebig detailliert zu definieren.

Die Fahrspuren und Querstrecken werden im Fall der automatisch erkannten Fahrbahnen anhand der Spurhüllen definiert. Über Punkt-Paaren der beiden Hülllinien (siehe Abbildung 6.19), werden Querstrecken erstellt. Da eine Fahrspur möglichst über die kleinste Menge an Querstrecken beschrieben werden soll, welche die Geometrie der Bahn zuverlässig abbildet, wird nicht für jedes Hüllpunkt-Paar eine Querstrecke definiert. Die Anzahl und Distanz zwischen den Querstrecken richtet sich nach der Krümmung der Spuren. Zur Beschreibung einer geraden Fahrspur werden weniger Querlinien benötigt, als zur Beschreibung einer Kurve. Zur Bestimmung der Querstrecken werden daher die Hülllinien abschnittsweise untersucht und jeweils die Richtungsänderungen zwischen aufeinanderfolgenden Abschnitten betrachtet. Hierzu wird erneut die Gleichung 6.11 eingesetzt. Übersteigt die Richtungsänderung einer Hülle einen Grenzwert von $\phi = 0.02$, so wird eine neue Querstrecke erstellt. Andernfalls verläuft die Spur im untersuchten Bereich annähernd gerade. In Abbildung 6.29 ist das Ergebnis der Spurerstellung dargestellt. Es ist gut zu erkennen, dass im Fall der geraden Fahrspuren der Autobahn nur wenige Querstrecken zur Definition der Spur verwendet werden, und für die gekrümmten Spuren deutlich mehr.

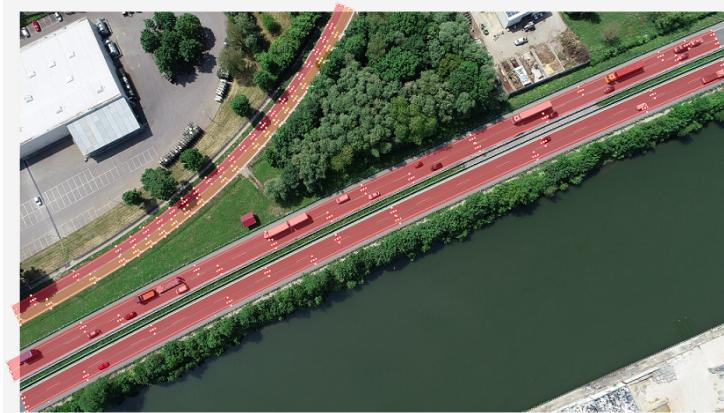


Abbildung 6.29: Angelegte Fahrspuren in der *Vehicle-Tracker* Anwendung

Ein Vorteil, welcher sich durch die Weiterverwendung des in Abbildung 6.28 dargestellten Datenmodells ergibt, ist, dass Benutzer weiterhin Spuren manuell anlegen können und automatisch detektierte Fahrbahnen sich nachträglich noch leicht modifizieren lassen. Falls eine vom Algorithmus erkannte Spur also beispielsweise in einem Abschnitt zu schmal oder zu breit ist, kann dies leicht vom Nutzer korrigiert werden.

Nachdem die Fahrspuren in der *Vehicle-Tracker* Anwendung angelegt wurden, können sie zur Analyse des Verkehrs in der Luftbeobachtung verwendet werden. Die Ergebnisse und Qualität des in diesem Kapitel vorgestellten Algorithmus, werden im nachfolgenden Auswertungskapitel vorgestellt.

7 Auswertung und Ergebnisse

Die Stärken, Schwächen und Ergebnisse des entwickelten Algorithmus werden im nachfolgenden Kapitel zusammengefasst, diskutiert und ausgewertet. Es wird zuerst abschnittsweise auf die drei primären Schritte des entwickelten Spurerkennungsverfahrens eingegangen. Endergebnisse werden anschließend in Form von Screenshots vorgestellt, in welchen die erkannten Fahrspuren zu sehen sind.

7.1 Evaluierung der Datenvorverarbeitung

Die Datenvorverarbeitung ist ein wichtiger Teilschritt bei der Erkennung von Fahrspuren. Nur wenn aus den Roh-Trajektorien die meisten Defekte entfernt wurden, können die nachfolgenden Schritte zuverlässig funktionieren. Die angewandten Schritte zur Entfernung der Defekte sind in Abschnitt 6.1.2 beschrieben.

Anhand von Abbildung 6.5 im Umsetzungskapitel wurde bereits gezeigt, dass die Datenvorverarbeitung grundsätzlich funktioniert. In Abbildung 7.1 sind nun die Roh-Trajektorien und bereinigte Bewegungsbahnen eines weiteren Datensatzes dargestellt, welcher von der Heilbronner-Straße in Stuttgart stammt.

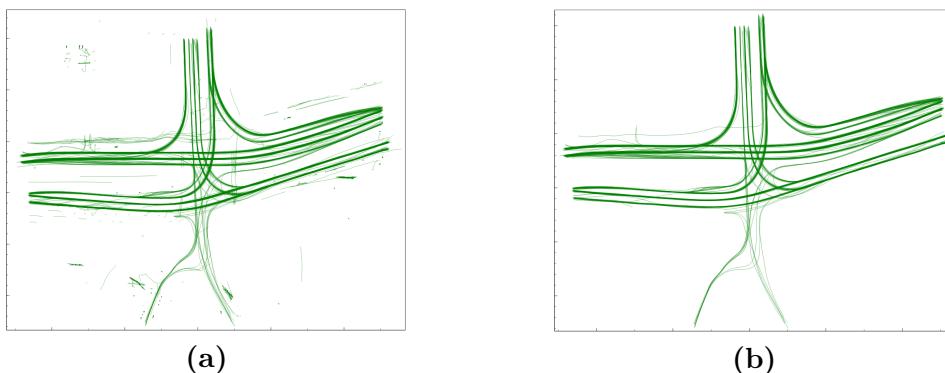


Abbildung 7.1: Fahrzeugtrajektorien im Rohformat a), vorverarbeitete Trajektorien b) - Datensatz *Heilbronner-Straße*

Die Plots zeigen gut, dass die vielen in a) vorkommenden Defekte entfernt wurden. Von den circa 1050 Roh-Trajektorien im ursprünglichen Datensatz bleiben nach der Vorverarbeitung etwa 450 intakte Bewegungsbahnen übrig. Die Mehrzahl der Defekte in diesem Fall

stammt von *False-Positive*-Detektionen und unterbrochener Fahrzeug-Detektionen (siehe Abschnitt 2.3).

Ein problematisches Verhalten der Datenvorverarbeitung wurde beim Testen der Spurerkennung anhand eines Datensatzes aus Steinheim deutlich. In Abbildung 7.2 a) ist der untersuchte Straßenabschnitt dargestellt.



Abbildung 7.2: Straßenabschnitt Datensatz Steinheim mit am Horizont verschwindenden Fahrspuren

Schwierig an dieser Aufnahme ist, dass die Fahrzeuge, welche sich auf der oben links startenden Fahrbahn bewegen, am Anfang beziehungsweise Ende ihrer Fahrt sehr klein sind. Da Fahrzeuge in einer Videoaufnahme ab einer gewissen Größe nur noch sehr unzuverlässig detektiert werden, brechen die Trajektorien in diesem Fall auf sehr unterschiedlichen Höhen ab. Aufgrund der stark variierenden Start- und End-Positionen, entfernt der in Abschnitt 6.1.2 beschriebene Algorithmus zur Identifikation unterbrochener Trajektorien, auch die meisten Bewegungsbahnen von Fahrzeugen, welche sich auf den Horizont zu oder von im weg bewegen. Somit können für diese Fahrspuren auch keine Spur-Geometrien bestimmt werden. Dieses Verhalten kann immer dann auftreten, wenn Fahrbahnen auf einen von der Kamera weit entfernten Horizont zulaufen.

Da Fahrzeuge im Bereich eines solchen Horizonts grundsätzlich unzuverlässig erkannt werden, ist auch eine Fahrverhaltensanalyse mithilfe von Fahrspuren hier nicht sinnvoll. Es wurde daher entschieden, dem Anwender die Möglichkeit zu geben, eine Horizont-Linie zu definieren. Diese sollte vor der Höhe liegen, ab welcher die Fahrzeugerkennung unzuverlässig wird. In einem ersten Vorverarbeitungsschritt werden alle Trajektorie-Punkte oberhalb dieser Linie entfernt. Dank der Beschneidung der Trajektorien bleiben diese in den nachfolgenden Verarbeitungsschritten erhalten und es können Spuren im gewünschten Ausschnitt erkannt werden.

Mit Ausnahme des unerwünschten Verhaltens im Fall von Trajektorien, welche am Horizont sehr unterschiedliche Start- beziehungsweise End-Positionen besitzen, funktioniert die Datenvorverarbeitung zuverlässig und wie gewünscht. Voraussetzung dafür, dass nach der Vorverarbeitung noch genug Trajektorien vorliegen, welche weiterverarbeitet werden können, ist, dass in den Rohdaten ausreichend intakte Bewegungsbahnen vorhanden sind.

7.2 Evaluierung der Clusteranalyse

Die Clusteranalyse der Trajektorien bildet die Grundlage für die anschließende Bestimmung der Spur-Geometrien. Sie ist daher ein kritischer Bestandteil der Spurerkennung. Der in dieser Arbeit eingesetzte Ansatz zur Gruppierung der Trajektorien wurde in Abschnitt 6.2.2 beschrieben. Hier wurden auch bereits Ergebnisse der Clusteranalyse für die Datensätze *Esslingen* und *Neckartor* vorgestellt.

Da der angewandte Clustering-Algorithmus die vollständigen Verläufe der Trajektorien vergleicht, ist die wichtigste Voraussetzung zur Identifikation eines Clusters, dass ausreichend Trajektorien vorliegen, welche eine identische Bewegung durch einen Straßenabschnitt beschreiben. In Abschnitt 6.2.2 wurde erwähnt, dass ein Cluster mindestens aus fünf Trajektorien bestehen muss. Diese Untergrenze wurde gewählt, um nicht zu viele Cluster zu identifizieren, welche eigentlich keine Fahrspur beschreiben. Würde die Grenze niedriger angesetzt werden, so würden beispielsweise vermehrt Cluster aus Trajektorien gebildet, welche Überholvorgänge beschreiben.

In den meisten Datensätzen, anhand derer der in dieser Arbeit entwickelte Algorithmus getestet wurde, existierten ausreichend Trajektorien pro Fahrspur, um diese zuverlässig zu identifizieren. Eine Ausnahme stellt der Datensatz von der Heilbronner-Straße in Stuttgart dar, dessen Trajektorien bereits in Abschnitt 7.1 dargestellt sind. In Teil b) dieser Abbildung wird deutlich, dass die Fahrspuren im unteren Bereich des Straßenabschnitts nur wenig befahren sind. Dies wirkt sich auch auf das Ergebnis der Clusteranalyse aus, welches in Abbildung 7.3 dargestellt ist. Zwar existieren ausreichend Trajektorien, welche sich von oben nach unten links bewegen, allerdings können keine Gruppen aus den Trajektorien gebildet werden, welche sich unten rechts befinden. Die wenigen in diesem Bereich existierenden Trajektorien haben sehr unterschiedliche Bewegungsbahnen, weshalb hier kein Cluster identifiziert wird.

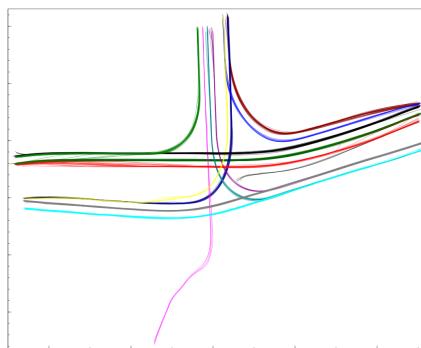


Abbildung 7.3: Ergebnis Trajektorie-Cluster der Heilbronner-Straße

Die Plots in Abbildung 7.4 a) und b) zeigen das Ergebnis der Clusteranalyse für den *Neckartor*-Datensatz, aus welchem vor Anwendung des Algorithmus zufällig 50% der Trajektorien entfernt wurden.

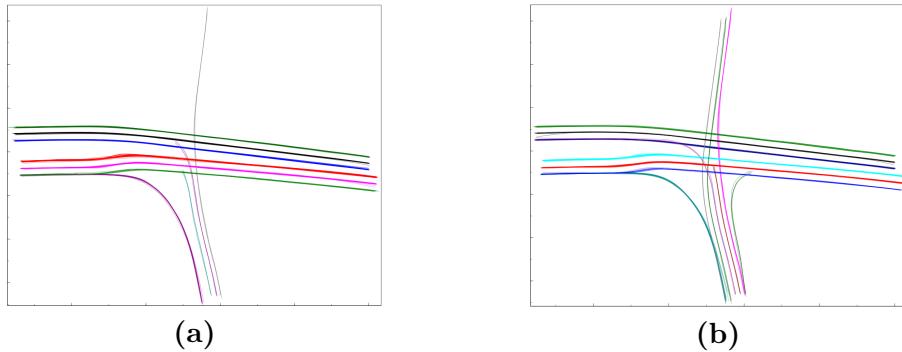


Abbildung 7.4: Trajektorie-Cluster des Neckartor-Datensatzes nach zufälliger Entfernung von 50% der Trajektorien

Auch hier wird deutlich, dass das Ergebnis maßgeblich von der Anzahl der Trajektorien pro Spur abhängt. In Plot a) wurden vorwiegend vertikal verlaufende Trajektorien entfernt, weshalb hier nur wenige Spurcluster identifiziert werden. In Plot b) wurden hingegen, trotz des Fehlens von 50% der Trajektorien, fast alle Spurcluster erkannt (vergleiche Abbildung 6.9 c)).

Außer von der Anzahl der Trajektorien, hängt das Ergebnis der Clusteranalyse primär von den gewählten Parametern des DBSCAN Clusteralgorithmus ab. Die Standardparameter für das Clustering-Verfahren wurden in Abschnitt 6.2.2 definiert. In Abschnitt 6.2.4 wurde zudem ein Verfahren vorgestellt, mit dessen Hilfe der Parameter ϵ_{DBSCAN} automatisch angepasst wird, wenn die Qualität der ermittelten Spur-Cluster nicht den Erwartungen entspricht. Alle bislang in der Arbeit gezeigten Ergebnisse der Clusteranalysen wurden ohne manuelle Parameteranpassungen bestimmt. Die Spur-Cluster beschreiben die in einem Straßenabschnitt existierenden Fahrspuren meist sehr gut, weshalb auch die daraus abgeleiteten Spur-Geometrien die Fahrbahnen gut abbilden.

In speziellen Fällen kann es allerdings vorkommen, dass trotz schlechter Clustering-Ergebnisse keine automatische Neuparametrisierung und Durchführung der Clusteranalyse vorgenommen wird. In dieser Situation können nur über eine manuelle Parametrisierung die Spur-Cluster zuverlässig identifiziert werden. Dies trifft beispielsweise auf den Datensatz *Steinheim* zu. Die unter Einsatz der Standardparameter ermittelten Spur-Cluster sind in Abbildung 7.5 a) dargestellt.

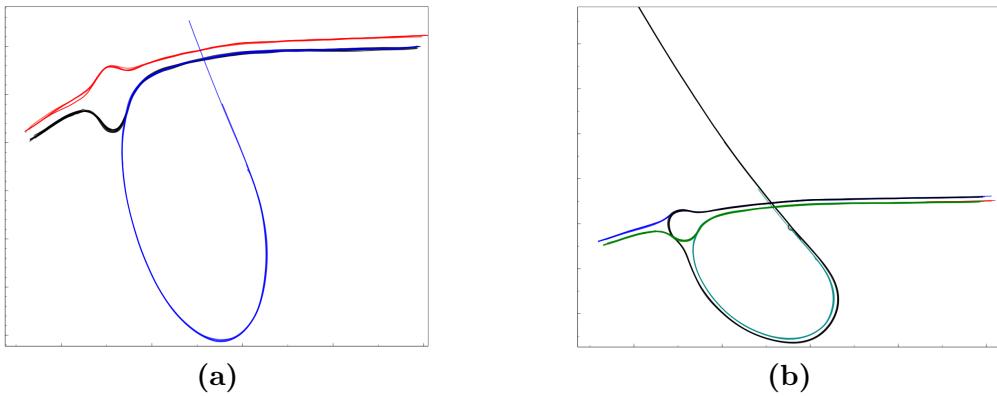


Abbildung 7.5: a) Ergebnis Standard-Clusteranalyse ($\epsilon_{DBSCAN} = 0.3$), b) Ergebnis Clusteranalyse nach manuelle Anpassung von ϵ_{DBSCAN} auf 0.1

Da die Spur-Geometrien, welche anhand der in Abbildung 7.5 a) zu sehenden Cluster gebildet werden, jeweils nur eine Fahrspur des Straßenabschnittes *Steinheim* beschreiben, existieren in den abgeleiteten Weg-Zeit-Trajektorien keine Überschneidungen. Die Spurerkennung wird daher nicht automatisch unter Verwendung eines angepassten Parameters wiederholt (siehe Abschnitt 6.2.4). Um die zweite, nach hinten verlaufende Fahrspur zu identifizieren, muss ϵ_{DBSCAN} manuell angepasst werden. Das Ergebnis ist in Abbildung 7.5 b) dargestellt. Da die Trajektorien auf den nach hinten verlaufenden Fahrspuren aufgrund der drei Brücken (siehe Abbildung 7.2) sehr viele Unterbrechungen aufweisen, kann der Clusteralgorithmus für die linke Spur zudem nur ein Cluster identifizieren, welches bis knapp vor die Brücken verläuft.

Für die Clusteranalyse kann zusammenfassend festgehalten werden, dass sie gut funktioniert, wenn ausreichend intakte Trajektorien zur Beschreibung einer Spur vorliegen. Dank sorgfältig gewählter Standardparameter und einer automatischen Parametrisierung können in den meisten Fällen die korrekten Spur-Cluster voll automatisch ermittelt werden. Nur in Ausnahmefällen muss die Clusteranalyse manuell konfiguriert werden.

7.3 Evaluierung der Spur-Geometrie-Bestimmung

Nach der Clusteranalyse werden anhand der identifizierten Spur-Cluster die Geometrien der Fahrspuren bestimmt. Die hierzu angewandten Verfahren sind in Abschnitt 6.3 beschrieben.

Wurden im vorherigen Schritt Trajektorie-Cluster für die in einer Aufnahme enthaltenen Fahrspuren identifiziert, so können auf Basis dieser meist zuverlässige Spur-Geometrien abgeleitet werden. In Abbildung 7.6 sind beispielhaft Spur-Geometrien aus drei unterschiedlichen Datensätzen dargestellt.

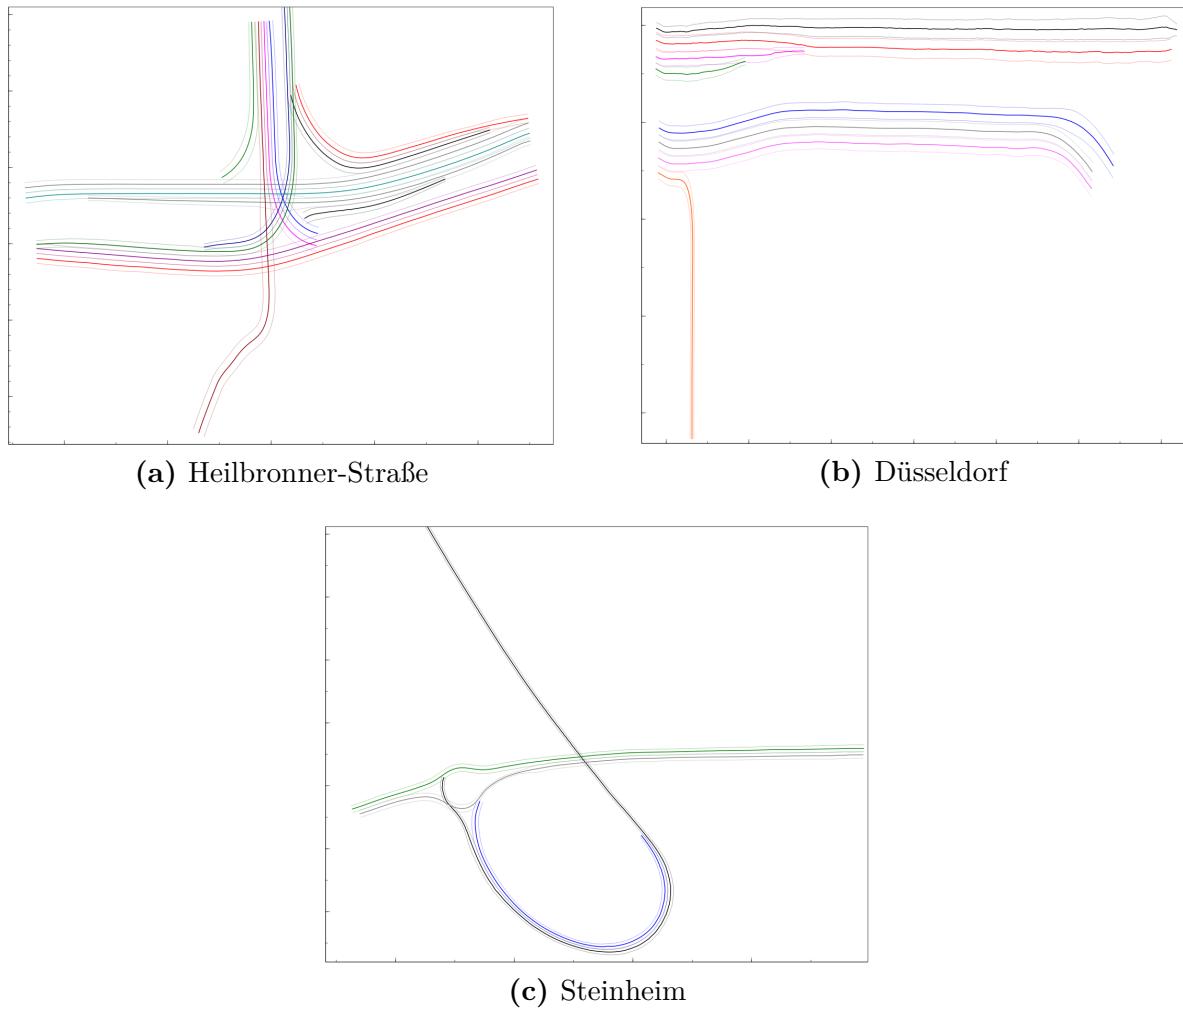


Abbildung 7.6: Ergebnisse der Spur-Geometrie-Bestimmung von verschiedenen Straßenabschnitten

Anhand der abgebildeten Spur-Geometrien ist zu erkennen, dass das in Abschnitt 6.3 beschriebene Verfahren gute Ergebnisse in unterschiedlichen Situationen liefert. Plot a) zeigt die Spur-Geometrien, welche im Fall des Datensatzes der Heilbronner-Straße bestimmt werden. Für jedes Spurcluster, welches in Abbildung 7.3 a) zu sehen ist, wurde eine Geometrie erstellt. Es ist zudem zu sehen, dass die Fahrspuren partitioniert wurden, um Überlagerungen zu vermeiden. Plot b) zeigt, dass Spur-Geometrien auch korrekt bestimmt werden, wenn in einer Aufnahme Fahrbahnerweiterung existieren, wie dies im *Düsseldorf*-Datensatz der Fall ist. Anhand von Plot c), welcher die für den Datensatz *Steinheim* ermittelten Spur-Geometrien zeigt, wird außerdem deutlich, dass auch die Geometrien kreisförmiger Fahrspuren und Kreisverkehre bestimmt werden können.

Ein Problem, welches bei der Bestimmung der Spur-Geometrien auftreten kann, ist in Abbildung 7.7 dargestellt.

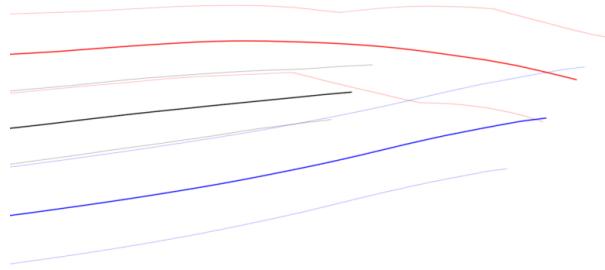


Abbildung 7.7: Partitionierungsproblem in den Spur-Geometrien

Das Beispiel zeigt einen Ausschnitt aus den Spur-Geometrien des Datensatzes *Heilbronner-Straße*. Auf dem entsprechenden Straßenabschnitt (vergleiche Abb. 7.9 b)), auf welchem sich die Spuren befinden, verbreitert sich am rechten Rand der Aufnahme die Fahrbahn nach oben hin. Es entstehen zwei neue Fahrspuren. In den partitionierten Spur-Geometrien sollte daher eigentlich die oberer Spur (rot) aus der mittlere Spur (schwarz) hervorgehen, welche wiederum selbst aus der unteren Spur (blau) hervorgeht. Wie in der Abbildung zu sehen ist, wird allerdings die mittlere Spur partitioniert und die obere bleibt erhalten. Hier trifft der in Abschnitt 6.3.5 beschrieben Algorithmus eine falsche Partitionierungsentscheidung.

Partitionierungsprobleme können in ähnlicher Art gelegentlich auftreten. Der Grund hierfür ist, dass es sehr schwierig ist, ein Verfahren zu definieren, welches in allen möglichen Spurüberlagerungs-Konstellationen die richtige Entscheidung trifft. Ein menschlicher Betrachter kann bei der Überlagerung zweier Spuren zwar meist intuitiv feststellen, welche partitioniert werden muss, einem Algorithmus dies beizubringen, ist allerdings schwierig, da die Entscheidung von vielen verschiedenen, situationsbezogenen Kriterien abhängt.

Der verwendete Partitionierungsansatz liefert, wie angestrebt, in der Mehrzahl der Fälle eine gute Lösung. Es musste bei der Entwicklung darauf geachtet werden, das keine Verfahren erstellt wird, welches zu sehr auf wenige Szenarien angepasst ist. Häufig gibt es bei der Teilung der Spuren auch kein eindeutiges "Richtig" oder "Falsch". Welche Spur erhalten bleiben soll, ist dann Interpretationssache. Daher, und da die Fehler leicht über die Oberfläche der *Vehicle-Tracker* Anwendung korrigiert werden können, wurde der verwendete Algorithmus hier nicht weiter angepasst.

7.4 Ergebnisse der Spurerkennung

Nachdem in den vorherigen Abschnitten auf die Fähigkeiten und Probleme der drei Hauptschritte des Spurerkennungsverfahrens eingegangen wurde, werden nun Ergebnisse in Form von Screenshots vorgestellt. In ihnen sind die automatisch erkannten und erstellten Spuren zu sehen, wie sie in der Anwendung *Vehicle-Tracker* dargestellt sind.

Die ersten zwei Screenshots, welche in Abbildung 7.8 dargestellt sind, zeigen die ermittelten Spuren für die Datensätze *Esslingen* und *Düsseldorf*. In den Aufnahmen ist zu erkennen, dass die erstellten Fahrspuren gut mit den realen Verläufen der Spuren auf der Fahrbahn übereinstimmen. Dies gilt auch im Fall des Datensatzes *Düsseldorf*, obwohl die hier detektierten Fahrzeugpositionen aufgrund des niedrigen Aufnahmewinkels nicht immer in der Nähe der Spurmitte liegen (siehe Abschnitt 2.3).

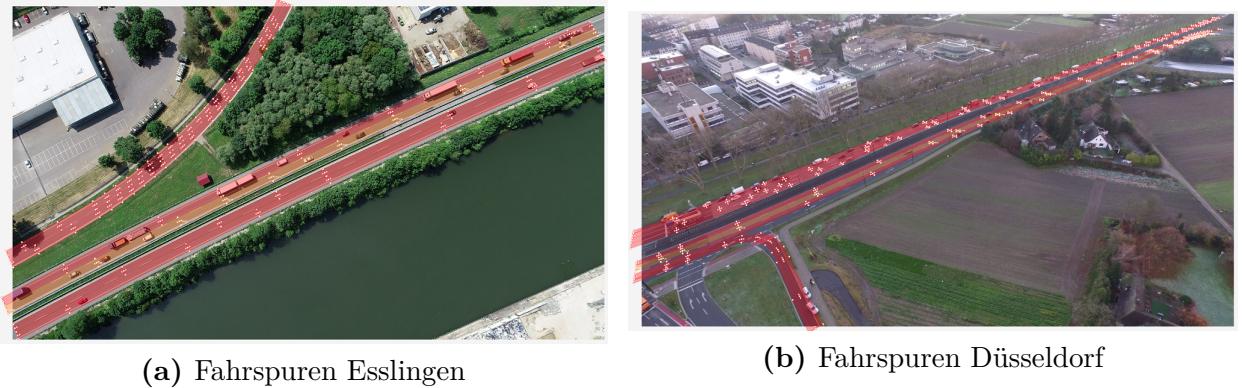


Abbildung 7.8: Erkannte Fahrspuren auf geraden Straßenabschnitten

In Abbildung 7.9 sind die erkannten Spuren der Datensätze *Neckartor* und *Heilbronner-Straße* dargestellt. Auch hier stimmen die Spur-Geometrien gut mit den realen Spur-Ausmaßen überein. Zudem wird deutlich, dass sowohl die Partitionierung der Spuren als auch das Angleichen benachbarter Spurenden die gewünschten Resultate liefern. Im Fall der Heilbronner-Straße ist nun auch zu sehen, dass im unteren rechten Bereich keine Spur erkannt wird. Der Grund hierfür wurde in Abschnitt 7.2 beschrieben.

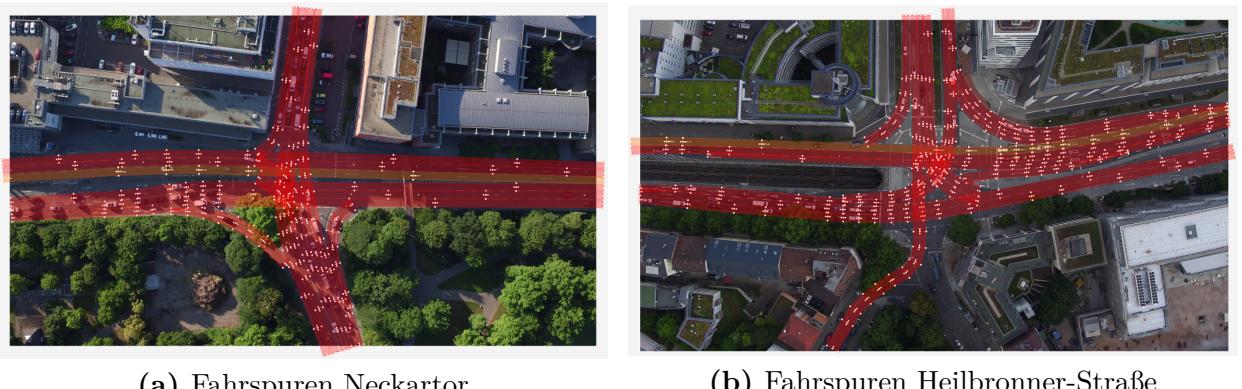


Abbildung 7.9: Erkannte Fahrspuren auf Kreuzungen

Der Screenshot in Abbildung 7.10 zeigt die erkannten Fahrspuren im Datensatz *Steinheim*. Dieses Beispiel zeigt, dass Fahrspuren auch in Straßenabschnitten mit Kreisverkehren oder

kreisförmigen Spuren erkannt werden. Auch hier stimmen, trotz des niedrigen Aufnahmewinkels, die Fahrspuren weitestgehend mit den realen Fahrbahnverläufen überein. Der frühe Abbruch der linken, nach oben verlaufenden Fahrspur lässt sich auf die Unterbrechungen der Trajektorien in diesem Bereich zurückführen.



(a) Fahrspuren Steinheim

Abbildung 7.10: Erkannte Fahrspuren auf kreisförmigen Fahrbahnen

Die oben abgebildeten und beschriebenen Ergebnisse zeigen, dass der entwickelte Spurerkennungsalgorithmus die in Abschnitt 5.2 aufgestellten Anforderungen erfüllt. Es können Fahrspuren in Straßen mit unterschiedlichen Topologien erkannt werden. Diese stimmen mit den realen Spur-Geometrien meist gut überein. Auch bei niedrigen Aufnahmewinkel können Fahrspuren aus den Trajektorien abgeleitet werden, welche den Verlauf der Fahrbahnen ausreichend genau beschreiben. Mit den meisten Defekten und Ausreißern in den Trajektorien kann umgegangen werden. Schwierigkeiten hat das Verfahren, wenn die Mehrzahl der Trajektorien einer Fahrspur Unterbrechungen aufweisen.

8 Zusammenfassung und Ausblick

Im Rahmen dieser Arbeit wurde ein Verfahren zur automatischen Erkennung von Fahrspuren in Videoaufnahmen anhand von Trajektoriedaten entwickelt. Nachfolgend werden die Ergebnisse der Thesis zusammengefasst und ein kurzer Ausblick gegeben.

8.1 Ergebnisse dieser Arbeit

Eine Untersuchung der Literatur zum Thema Fahrspurerkennung zu Beginn der Arbeit (siehe Kapitel 4) machte deutlich, dass die existierenden Ansätze nur für eingeschränkte Anwendungsfälle entwickelt wurden. Jene Lösungen, welche anhand von Fahrzeugtrajektorien die Fahrspuren ermitteln, können meist nur in sehr speziellen Straßentopologien eingesetzt werden. Des Weiteren stimmen die in den verwandten Arbeiten ermittelten Spur-Geometrien nur selten mit den realen Dimensionen der Fahrspuren auf der Straße überein. Aus diesen Gründen eignen sich die existierenden Verfahren nicht für den Einsatz in einer Anwendung, mit deren Hilfe detaillierte Verkehrsanalysen aus Luftbeobachtungen erstellt werden.

In dieser Arbeit werden Fahrspuren anhand von Fahrzeugtrajektorien erkannt. Die hierzu verwendeten Trajektorien wurden aus den zu analysierenden Luftaufnahmen rekonstruiert. Die Spurerkennung basiert auf einer Clusteranalyse der Bewegungsbahnen und einem neu entwickelten, mehrstufigen Verfahren zur Erstellung von Spur-Geometrien. Mithilfe der Clusteranalyse werden Spur-Cluster identifiziert, welche Bewegungen von Fahrzeugen auf einer Fahrspur beschreiben. Jene Cluster können auch in Trajektoriedatensätzen mit komplexen Fahrbahnverläufen identifiziert werden. Damit der Clusteralgorithmus in unterschiedlichen Situationen jeweils gute Ergebnisse liefert, wurde ein Verfahren entwickelt, um diesen automatisch zu parametrisieren. Die Ergebnisse der Clusteranalyse dienen als Grundlage für die Ermittlung der Spur-Geometrien. Zur Erstellung der Geometrien wurde ein robustes Verfahren für die Bestimmung der Spurmittellinien entwickelt. Anhand der Mittellinien und deren relativer Lage zueinander, werden Hülllinien definiert, welche die Dimensionen der Fahrspuren beschreiben. Diese werden partitioniert, um Überlagerungen zu entfernen, bevor sie in den Verkehrsanalysen verwendet werden können.

In einer Evaluation konnte bestätigt werden, dass das entwickelte Spurerkennungsverfahren die in Abschnitt 5.2 definierten Anforderungen erfüllt und die oben genannten Probleme der verwandten Arbeiten löst. Mithilfe des Spurerkennungsverfahrens können Fahrspuren in Straßenabschnitten mit unterschiedlichsten Fahrbahnverläufen identifiziert werden. Die

ermittelten Spur-Geometrien stimmen mit den realen Fahrbahnverläufen zudem meist gut überein und besitzen keine Überlagerungen. Dank der automatischen Parametrisierung des Verfahrens, können die Fahrspuren zudem meist vollautomatisch ermittelt werden, was dem Anwender eine manuelle Konfiguration unter Anwendung von Expertenwissen abnimmt.

Der entwickelte Algorithmus wurde in die Anwendung *Vehicle-Tracker* integriert, welche im Teilprojekt “Luftbeobachtung” des MEC-View Forschungsprojektes zur Analyse des Fahrverhaltens von Verkehrsteilnehmern eingesetzt wird.

8.2 Ausblick

Das im Rahmen dieser Thesis entwickelte Spurerkennungsverfahren ermöglicht in Zukunft eine schnellere Auswertung des Fahrverhaltens von Fahrzeugen in Luftaufnahmen. Die Spurerkennung ist ein wichtiger Schritt hin zu einer vollständig automatisierten Auswertung von langen Verkehrsmesskampagnen. Mithilfe der ermittelten Spurinformationen können unter anderem Überhol- und Spurwechselvorgänge sowie das Verhalten der Fahrzeuge auf einer Spur untereinander untersucht werden. Die Durchführung dieser Untersuchungen ist wichtig für die Erstellung detaillierter Verkehrsanalysen. Erkenntnisse, welche aus diesen gewonnen werden, können, im Rahmen des MEC-View Projektes, in Zukunft auch zur Optimierung des Fahrverhaltens von autonomen Fahrzeugen eingesetzt werden.

Die Spur-Geometrien können zudem auch zur Evaluierung der Qualität der Fahrzeugerkennung und Verfolgung, und insbesondere zur Identifikation von Ausreißern, eingesetzt werden. Da sich Fahrzeuge, deren Fahrverhalten untersucht werden soll, auf den Fahrbahnen eines Straßenabschnittes befinden, kann anhand der Spurinformationen ermittelt werden, welche Trajektorien außerhalb dieser liegen und daher vermutlich Ausreißer sind.

Die Zuverlässigkeit der Fahrspurerkennung könnte in Zukunft durch die Identifizierung und Implementierung eines alternativen Clustering-Verfahrens weiter gesteigert werden. Der derzeit eingesetzte Ansatz, welcher komplette Trajektorien gruppiert, liefert zwar in der Mehrzahl der Fälle gute Ergebnisse, führt jedoch auch dazu, dass in manchen Situationen Fahrspuren nicht korrekt erkannt werden. Ein alternatives Verfahren könnte sich beispielsweise an der Arbeit von [Xu et al., 2015] orientieren, in welcher anhand von Trajektoriedaten eine “*Heat-Map*” erstellt wird, aus welcher anschließend “Mittellinien” anhand eines “*Adaptive Multi-Kernel-Based Shrinkage*”-Algorithmus extrahiert werden. Hierbei fallen Unterbrechungen von Trajektorien nicht ins Gewicht. Ein Nachteil des von Xu et al. vorgestellten Verfahrens ist, dass die ermittelten Spurmittellinien teilweise nur schlecht mit den realen Spurverläufen übereinstimmen oder für eine Spur mehrere Zentrallinien bestimmt werden.

Da die einzelnen Schritte der Spurerkennung unabhängig voneinander arbeiten, kann ein alternatives Clustering-Verfahren mit geringen Auswirkungen auf den Rest des Algorithmus integriert werden.

Literaturverzeichnis

- M. Aly. Real time detection of lane markers in urban streets. In *IEEE Intelligent Vehicles Symposium, Proceedings*, pages 7–12, 2008. ISBN 9781424425693. doi: 10.1109/IVS.2008.4621152. URL <https://ieeexplore.ieee.org/abstract/document/4621152/>.
- Anders Drachen. Introducing Clustering II: Clustering Algorithms - GameAnalytics, 2014. URL <https://gameanalytics.com/blog/introducing-clustering-ii-clustering-algorithms.html>. Zugriff am: 22.10.2018.
- J. Apeltauer, A. Babinec, D. Herman, and T. Apeltauer. Automatic Vehicle Trajectory Extraction from Aerial Video Data. *Excel@FIT*, 2015. URL <http://excel.fit.vutbr.cz/submissions/2015/064/64.pdf>.
- S. Atev, O. Masoud, and N. Papanikolopoulos. Learning Traffic Patterns at Intersections by Spectral Clustering of Motion Trajectories. In *2006 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 4851–4856. IEEE, oct 2006. ISBN 1-4244-0258-1. doi: 10.1109/IROS.2006.282362. URL <http://ieeexplore.ieee.org/document/4059186/>.
- S. Atev, G. Miller, and N. P. Papanikolopoulos. Clustering of vehicle trajectories. *IEEE Transactions on Intelligent Transportation Systems*, 2010. ISSN 15249050. doi: 10.1109/TITS.2010.2048101.
- Y. Boykov and V. Kolmogorov. An experimental comparison of min-cut/max-flow algorithms for energy minimization in vision. *IEEE transactions on pattern analysis and machine intelligence*, 26(9):1124–1137, 2004.
- D. Buzan, S. Sclaroff, and G. Kollios. Extraction and Clustering of Motion Trajectories in Video. apr 2004. URL <https://open.bu.edu/handle/2144/1545>.
- J. Chen, R. Wang, L. Liu, J. S. , , C. Control, and undefined 2011. Clustering of trajectories based on Hausdorff distance. *ieeexplore.ieee.org*, 2011. URL <https://ieeexplore.ieee.org/abstract/document/6066483/>.
- L. Chen, M. T. Özsü, and V. Oria. Robust and fast similarity search for moving object trajectories. In *Proceedings of the 2005 ACM SIGMOD international conference on Management of data - SIGMOD '05*, page 491, New York, New York, USA, 2005. ACM Press. ISBN 1595930604. doi: 10.1145/1066157.1066213. URL <http://portal.acm.org/citation.cfm?doid=1066157.1066213>.

- Z. Chen and T. Ellis. Automatic lane detection from vehicle motion trajectories. In *2013 10th IEEE International Conference on Advanced Video and Signal Based Surveillance, AVSS 2013*, pages 466–471, 2013. ISBN 9781479907038. doi: 10.1109/AVSS.2013.6636684. URL <https://ieeexplore.ieee.org/abstract/document/6636684/>.
- Z. Chen, Y. Yan, and T. Ellis. Lane detection by trajectory clustering in urban environments. In *2014 17th IEEE International Conference on Intelligent Transportation Systems, ITSC 2014*, pages 3076–3081, 2014. ISBN 9781479960781. doi: 10.1109/ITSC.2014.6958184. URL <https://ieeexplore.ieee.org/abstract/document/6958184/>.
- G. Cookson, B. P. I. Research, undefined February, and undefined 2017. Inrix global traffic scorecard. *jschultheis.de*, 2017. URL http://jschultheis.de/wp-content/uploads/2018/02/INRIX_2017_Traffic_Scorecard_Report___German.pdf.
- D. Cornelisse. An intuitive guide to Convolutional Neural Networks, 2018. URL <https://medium.freecodecamp.org/an-intuitive-guide-to-convolutional-neural-networks-260c2de0a050>. Zugriff am: 08.01.2018.
- FGSV. *RAA - Richtlinien für die Anlage von Autobahnen*. Forschungsgesellschaft für Straßen- und Verkehrswesen (FGSV), Arbeitsgruppe Straßenentwurf., 2008. ISBN 978-3-939715-51-1. URL http://www.fgsv-verlag.de/catalog/product_info.php?products_id=2451.
- FGSV. *RAL - Richtlinien für die Anlage von Landstraßen*. Forschungsgesellschaft für Straßen- und Verkehrswesen (FGSV), Arbeitsgruppe Straßenentwurf., 2012. ISBN 978-3-86446-039-5. URL http://www.fgsv-verlag.de/catalog/product_info.php?products_id=3206.
- J. Gao. Clustering Lecture 4 : Density-based Methods. pages 1–16, 2012. URL https://cse.buffalo.edu/~jing/cse601/fa12/materials/clustering_density.pdf.
- George Seif. The 5 Clustering Algorithms Data Scientists Need to Know, 2018. URL <https://towardsdatascience.com/the-5-clustering-algorithms-data-scientists-need-to-know-a36d136ef68>. Zugriff am: 19.10.2018.
- R. Gopalan, T. Hong, M. Shneier, and R. Chellappa. A Learning Approach Towards Detection and Tracking of Lane Markings. *Intelligent Transportation Systems , IEEE Transactions on*, 13(3):1088–1098, 2012. ISSN 15249050. doi: 10.1109/TITS.2012.2184756. URL <https://ieeexplore.ieee.org/abstract/document/6155090/>.
- H. Grabner, M. Grabner, H. B. Bmvc, and undefined 2006. Real-time tracking via online boosting. *grabner.family*, 2006. URL <http://grabner.family/helmut/papers/Grabner2006RealTimeTracking.pdf>.
- G. Hamerly, C. E. A. in neural information Processing, and undefined 2004. Learning the k in k-means. *papers.nips.cc*, 2004. URL <http://papers.nips.cc/paper/2526-learning-the-k-in-k-means.pdf>.

- K. Hammouda and M. Kamel. Efficient phrase-based document indexing for Web document clustering. *IEEE Transactions on Knowledge and Data Engineering*, 16(10):1279–1296, oct 2004. ISSN 1041-4347. doi: 10.1109/TKDE.2004.58. URL <http://ieeexplore.ieee.org/document/1324634/>.
- M. S. Handcock, A. E. Raftery, and J. M. Tantrum. Model-based clustering for social networks. *Journal of the Royal Statistical Society. Series A: Statistics in Society*, 170(2):301–354, mar 2007. ISSN 09641998. doi: 10.1111/j.1467-985X.2007.00471.x. URL <http://doi.wiley.com/10.1111/j.1467-985X.2007.00471.x>.
- P. Hemmerle. Empirische physikalische Eigenschaften des übersättigten innerstädtischen Verkehrs und Energieeffizienz von Fahrzeugen. 2016. URL <https://d-nb.info/1122559259/34>.
- J.-W. Hsieh, S.-H. Yu, Y.-S. Chen, and W.-F. Hu. Automatic Traffic Surveillance System for Vehicle Tracking and Classification. *IEEE Transactions on Intelligent Transportation Systems*, 7(2):175–187, jun 2006. ISSN 1524-9050. doi: 10.1109/TITS.2006.874722. URL <http://ieeexplore.ieee.org/document/1637673/>.
- W. Hu, Z. Fu, and T. Tan. Similarity based vehicle trajectory clustering and anomaly detection. In *Proceedings - International Conference on Image Processing, ICIP*, 2005. ISBN 0780391349. doi: 10.1109/ICIP.2005.1530127.
- J. Huang, V. Rathod, and C. Sun. Tensorflow Object Detection API, 2018. URL https://github.com/tensorflow/models/tree/master/research/object_detection. Zugriff am: 27.12.2018.
- D. Huttenlocher, G. K. I. T. on . . ., and U. 1993. Comparing images using the Hausdorff distance. *ieeexplore.ieee.org*, 1993. URL <https://ieeexplore.ieee.org/abstract/document/232073/>.
- B. Jähne. *Digitale Bildverarbeitung und Bildgewinnung*. 2012. ISBN 9783642049514. doi: 10.1007/s13398-014-0173-7.2.
- A. K. Jain. Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8):651–666, jun 2010. ISSN 0167-8655. doi: 10.1016/J.PATREC.2009.09.011. URL <https://www.sciencedirect.com/science/article/pii/S0167865509002323>.
- A. K. Jain, M. N. Murty, and P. J. Flynn. Data clustering: a review. *ACM Computing Surveys*, 31(3):264–323, sep 1999. ISSN 03600300. doi: 10.1145/331499.331504. URL <http://portal.acm.org/citation.cfm?doid=331499.331504>.
- I. N. Junejo, O. Javed, and M. Shah. Multi feature path modeling for video surveillance. In *Proceedings - International Conference on Pattern Recognition*, volume 2, pages 716–719. IEEE, 2004. ISBN 0769521282. doi: 10.1109/ICPR.2004.1334359. URL <http://ieeexplore.ieee.org/document/1334359/>.

- Z. W. Kim. Robust lane detection and tracking in challenging scenarios. In *IEEE Transactions on Intelligent Transportation Systems*, volume 9, pages 16–26, 2008. ISBN 1524-9050. doi: 10.1109/TITS.2007.908582.
- A. H. Lai and N. H. Yung. Lane detection by orientation and length discrimination. *IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics*, 30(4):539–548, 2000. ISSN 10834419. doi: 10.1109/3477.865171. URL <https://ieeexplore.ieee.org/abstract/document/865171/>.
- P. Lingras, C. W. J. o. I. I. Systems, and U. 2004. Interval Set Clustering of Web Users with Rough K-Means. *Springer - Journal of Intelligent Information Systems*, 23(1):5–16, 2004. URL <https://link.springer.com/article/10.1023/B:JIIS.0000029668.88665.1a>.
- J. Liu and M. Wang. Lane segmentation in traffic monitoring systems based on probability map. In *Proceedings of the World Congress on Intelligent Control and Automation (WCICA)*, pages 6245–6249, 2010. ISBN 9781424467129. doi: 10.1109/WCICA.2010.5554395. URL <https://ieeexplore.ieee.org/abstract/document/5554395/>.
- D. Makris and T. Ellis. Learning semantic scene models from observing activity in visual surveillance. *IEEE Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics*, 35(3):397–408, 2005. ISSN 10834419. doi: 10.1109/TSMCB.2005.846652. URL <https://ieeexplore.ieee.org/abstract/document/1430826/>.
- J. McCall and M. Trivedi. Video-Based Lane Estimation and Tracking for Driver Assistance: Survey, System, and Evaluation. *IEEE Transactions on Intelligent Transportation Systems*, 7(1):20–37, mar 2006. ISSN 1524-9050. doi: 10.1109/TITS.2006.869595. URL <http://ieeexplore.ieee.org/document/1603550/>.
- MEC-View. Forschungsprojekt MEC-View. <http://www.mec-view.de>, 2018. Zugriff am: 22.12.2018.
- H. Meißner. Untersuchung und Evaluierung von Methoden zur Kalibrierung optischer Sensoren in Verbindung mit Lagesensoren. *Technische Universität Berlin*, 2007.
- J. Mélo, A. Naftel, A. Bernardino, and J. Santos-Victor. Detection and classification of highway lanes using vehicle motion trajectories. *IEEE Transactions on Intelligent Transportation Systems*, 2006. ISSN 15249050. doi: 10.1109/TITS.2006.874706.
- F. Meng, G. Yuan, S. Lv, Z. Wang, and S. Xia. An overview on trajectory outlier detection, feb 2018. ISSN 15737462. URL <http://link.springer.com/10.1007/s10462-018-9619-1>.
- V. Mirge, K. Verma, and S. Gupta. Outlier Detection in Vehicle Trajectories. *International Journal of Computer Applications*, 171(8):1–6, 2017. URL <https://www.ijcaonline.org/archives/volume171/number8/mirge-2017-ijca-915139.pdf>.

- B. Morris and M. Trivedi. Learning trajectory patterns by clustering: Experimental studies and comparative evaluation. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pages 312–319. IEEE, jun 2009. ISBN 978-1-4244-3992-8. doi: 10.1109/CVPR.2009.5206559. URL <http://ieeexplore.ieee.org/document/5206559/>.
- B. T. Morris and M. M. Trivedi. Trajectory learning for activity understanding: Unsupervised, multilevel, and long-term adaptive approach. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 33(11):2287–2301, 2011. ISSN 01628828. doi: 10.1109/TPAMI.2011.64. URL <https://ieeexplore.ieee.org/abstract/document/5740921/>.
- D. Neven, B. De Brabandere, S. Georgoulis, M. Proesmans, and L. Van Gool. Towards End-to-End Lane Detection: An Instance Segmentation Approach. In *IEEE Intelligent Vehicles Symposium, Proceedings*, volume 2018-June, pages 286–291, 2018. ISBN 9781538644522. doi: 10.1109/IVS.2018.8500547. URL <https://arxiv.org/abs/1802.05591>.
- A. Y. Ng, M. I. Jordan, and Y. Weiss. On spectral clustering: Analysis and an algorithm. *Advances in Neural Information Processing Systems 14, Vols 1 and 2*, 14:849–856, 2002. ISSN <null>. doi: 10.1.1.19.8100.
- D. OpenCV. Camera Calibration and 3D Reconstruction, 2018. URL https://docs.opencv.org/2.4/modules/calib3d/doc/camera_calibration_and_3d_reconstruction.html. Zugriff am: 28.12.2018.
- T. N. Pappas. An Adaptive Clustering Algorithm for Image Segmentation. *IEEE Transactions on Signal Processing*, 40(4):901–914, apr 1992. ISSN 19410476. doi: 10.1109/78.127962. URL <http://ieeexplore.ieee.org/document/127962/>.
- S. Patel and J. Pingel. Introduction to Deep Learning: What Are Convolutional Neural Networks? Video - MATLAB, 2017. URL <https://www.mathworks.com/videos/introduction-to-deep-learning-what-are-convolutional-neural-networks--1489512765771.html>. Zugriff am: 27.12.2018.
- D. Pelleg, A. M. Icml, and undefined 2000. X-means: Extending k-means with efficient estimation of the number of clusters. *cs.uef.fi*, 2000. URL <http://cs.uef.fi/~zhao/Courses/Clustering2012/Xmeans.pdf>.
- L. Portnoy, E. Eskin, and S. Stolfo. Intrusion detection with unlabeled data using clustering. *Proceedings of ACM CSS Workshop on Data Mining Applied to Security Philadelphia PA*, pages 1–25, 2001. doi: 10.1.1.13.7523. URL <https://academiccommons.columbia.edu/doi/10.7916/D8MP5904>.
- J. Ren, Y. Chen, L. Xin, and J. Shi. Lane Detection in Video-Based Intelligent Transportation Monitoring via Fast Extracting and Clustering of Vehicle Motion Trajectories. *Mathematical Problems in Engineering*, 2014. ISSN 15635147. doi: 10.1155/2014/156296.

- Saurav Kaushik. An Introduction to Clustering and different methods of clustering, 2016. URL <https://www.analyticsvidhya.com/blog/2016/11/an-introduction-to-clustering-and-different-methods-of-clustering/>. Zugriff am: 19.10.2018.
- J. Sochor. Fully Automated Real-Time Vehicles Detection and Tracking with Lanes Analysis. *Proceedings of CESC 2014: The 18th Central European Seminar on Computer Graphics*, 2014. URL http://www.cescg.org/CESC 2014/papers/Sochor-Fully_Automated_Real-Time_Vehicles_Detection_and_Tracking_with_Lanes_Analysis.pdf.
- I. Szottka and M. Butenuth. Tracking multiple vehicles in airborne image sequences of complex urban environments. In *2011 Joint Urban Remote Sensing Event, JURSE 2011 - Proceedings*, pages 13–16, 2011. ISBN 9781424486571. doi: 10.1109/JURSE.2011.5764707. URL <https://ieeexplore.ieee.org/abstract/document/5764707/>.
- P.-N. Tan et al. *Introduction to data mining*. Pearson Education India, 2007.
- S. Y. Teng, K. T. Chuang, C. R. Huang, and C. C. Li. Lane detection in surveillance videos using vector-based hierarchy clustering and density verification. In *Proceedings of the 14th IAPR International Conference on Machine Vision Applications, MVA 2015*, pages 345–348. IEEE, may 2015. ISBN 9784901122153. doi: 10.1109/MVA.2015.7153201. URL <http://ieeexplore.ieee.org/document/7153201/>.
- M. Vlachos, G. Kolios, and D. Gunopoulos. Discovering similar multidimensional trajectories. *Proceedings - International Conference on Data Engineering*, pages 673–684, 2002. ISSN 10844627. doi: 10.1109/ICDE.2002.994784. URL <https://ieeexplore.ieee.org/abstract/document/994784/>.
- H. Weiming, X. Xuejuan, F. Zhouyu, D. Xie, T. Tieniu, and S. Maybank. A system for learning statistical motion patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 28(9):1450–1464, sep 2006. ISSN 0162-8828. doi: 10.1109/TPAMI.2006.176. URL <http://ieeexplore.ieee.org/document/1661547/>.
- X. L. Xie and G. Beni. A validity measure for fuzzy clustering. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, (8):841–847, 1991.
- H. Xu, Y. Zhou, W. Lin, and H. Zha. Unsupervised trajectory clustering via adaptive multi-kernel-based shrinkage. In *Proceedings of the IEEE International Conference on Computer Vision*, volume 2015 Inter, pages 4328–4336, 2015. ISBN 9781467383912. doi: 10.1109/ICCV.2015.492. URL https://www.cv-foundation.org/openaccess/content_iccv_2015/html/Xu_Unsupervised_Trajectory_Clustering_ICCV_2015_paper.html.

Eidesstattliche Erklärung

Ich versichere, dass ich die vorstehende Arbeit selbständig verfasst und hierzu keine anderen als die angegebenen Hilfsmittel verwendet habe. Alle Stellen der Arbeit die wörtlich oder sinngemäß aus fremden Quellen entnommen wurden, sind als solche kenntlich gemacht.

Die Arbeit wurde bisher in gleicher oder ähnlicher Form in keinem anderen Studiengang als Prüfungsleistung vorgelegt oder an anderer Stelle veröffentlicht.

Ich bin mir bewusst, dass eine falsche Erklärung rechtliche Folgen haben kann.

Uhingen, den 11. Februar 2019 _____
Steffen Schmid

A Anhang - Verwendete Datensätze

Nachfolgend sind Aufnahmen der in dieser Arbeit verwendeten Luftaufnahmen zu sehen.

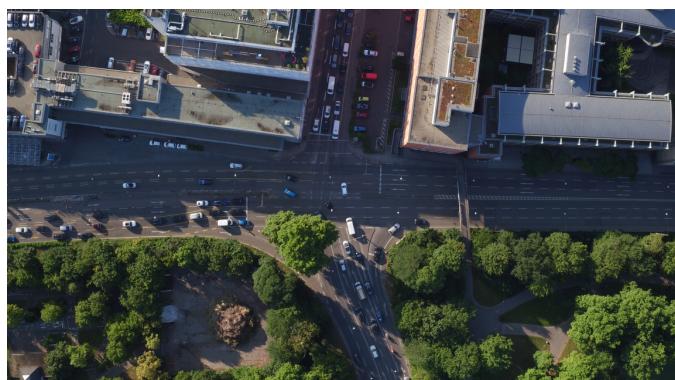
Datensatz Esslingen



Anzahl Trajektorien: 224
Anzahl Ziel-Fahrspuren: 6

Abbildung A.1: Straßenabschnitt Aufnahme
Esslingen

Datensatz Neckartor



Anzahl Trajektorien: 1240
Anzahl Ziel-Fahrspuren: 14

Abbildung A.2: Straßenabschnitt Aufnahme
Neckartor

Datensatz Heilbronner-Straße



Anzahl Trajektorien: 1056
Anzahl Ziel-Fahrspuren: 17

Abbildung A.3: Straßenabschnitt Aufnahme Heilbronner-Straße

Datensatz Düsseldorf



Anzahl Trajektorien: 1705
Anzahl Ziel-Fahrspuren: 10

Abbildung A.4: Straßenabschnitt Aufnahme Düsseldorf

Datensatz Steinheim



Anzahl Trajektorien: 754
Anzahl Ziel-Fahrspuren: 4

Abbildung A.5: Straßenabschnitt Aufnahme Steinheim