

Masterarbeit

# Erkennung von Fahrspuren mittels Fahrzeugtrajektorien aus Luftaufnahmen

im Master-Studiengang Informatik  
der Hochschule Furtwangen

Steffen Schmid

**Zeitraum:** Wintersemester 2018

**Prüfer:** Prof. Dr. Christoph Reich

**Zweitprüfer:** Stefan Kaufmann

---

**Firma:** IT-Designers GmbH

**Betreuer:** Stefan Kaufmann

# Eidesstattliche Erklärung

Hiermit versichere ich, die vorliegende Arbeit selbstständig und unter ausschließlicher Verwendung der angegebenen Literatur und Hilfsmittel erstellt zu haben.

Die Arbeit wurde bisher in gleicher oder ähnlicher Form keiner anderen Prüfungsbehörde vorgelegt und auch nicht veröffentlicht.

Esslingen, den 18. Oktober 2018

\_\_\_\_\_  
Unterschrift

# Zitat

*„Some fancy quote“*

Foober Muman

# Danksagung

# Kurzfassung

Schlagworte:

# Inhaltsverzeichnis

Kurzfassung	v
1 Einleitung	1
1.1 Rahmen der Arbeit . . . . .	1
1.1.1 Das Projekt MEC-View . . . . .	1
1.1.2 MEC-View Luftbeobachtung . . . . .	1
1.2 Motivation und Ziele . . . . .	1
1.3 Aufbau dieser Arbeit . . . . .	1
2 Grundlagen	2
2.1 Verkehrsanalyse mittels Luftaufnahmen . . . . .	2
2.2 Rekonstruktion von Fahrzeugtrajektorien aus Luftaufnahmen . . . . .	2
2.3 Datenaufbereitung und Bereinigung . . . . .	4
2.4 Clusteranalyse von Trajektorien . . . . .	4
2.4.1 Clustering Algorithmen . . . . .	4
2.4.2 Distanzmaße zum Vergleich von Fahrzeugtrajektorien . . . . .	4
2.5 Untersuchung möglicher Straßentopologien . . . . .	4
3 Stand der Technik	5
3.1 Clustering von Trajektoriedaten . . . . .	5
3.2 Erkennung von Fahrspuren . . . . .	5
3.3 Klassifizierung von Fahrspuren . . . . .	5
3.4 Defizite vorhandener Lösungen und benötigte Neuerungen . . . . .	5
4 Clustering von Fahrzeugtrajektorien	6
4.1 Vorverarbeitung der Roh-Trajektorien . . . . .	6
4.2 Gruppierung der Trajektorien . . . . .	6
5 Fahrbahn-Bestimmung aus Trajektorie-Clustern	7
6 Fahrbahn Klassifizierung	8
7 Realisierung LaneDetection in MEC-View TrackerApplication Software	9
8 Ergebnisse und Auswertung	10
9 Zusammenfassung und Fazit	11

Literaturverzeichnis

12

# Abbildungsverzeichnis

2.1	Übersicht Tracking mit Klassifikator . . . . .	3
2.2	a) Haar-ähnliche Merkmale b) Beispiele für erkannte Regionen in einem Gesicht [Divyansh Dwivedi, 2018] . . . . .	4



# Listings

# 1 Einleitung

Staus und zäh fließender Verkehr sind sowohl auf Schnell- und Autobahnen, als auch in Städten ein großes Problem und Ärgerniss für Autofahrer. Sie kosten diese nicht nur wertvolle Zeit, sondern auch viel Geld. Laut einer Studie von [Cookson u. a.] kostet Stau jeden deutschen Autofahrer pro Jahr durchschnittlich 1770 €. In Summe ergeben sich hieraus beinahe 80 Milliarden Euro an Kosten. Stau ist allerdings nicht nur finanziell für Privatpersonen oder auch Unternehmen ein großer Faktor, sondern er erhöht auch das Unfallrisiko und trägt maßgeblich zur schlechten Luftqualität in Innenstädten bei. Aufgrund längerer Fahrzeiten und der häufigen Be- und Entschleunigung, steigt der Kraftstoffverbrauch der Fahrzeuge und dadurch auch die Schadstoffbelastung in der Luft [Hemmerle, 2016].

Um Stau so gut wie möglich vermeiden zu können, muss man den Verkehr verstehen. Nötig ist ein Verständnis des Straßenverkehrs als Ganzes, sowie der Auswirkungen, welche einzelne Verkehrsteilnehmer und deren Verhalten, auf diesen haben. Hierzu ist das Erstellen von Simulationen sowie die Auswertung realer Verkehrsaufkommen unerlässlich. Die auf diese Weise gesammelten Erkenntnisse bilden die Grundlage, um Straßenabschnitte, insbesondere auch in Innenstädten, intelligent zu gestalten. Des Weiteren können sie eingesetzt werden, um beispielsweise Ampelschaltungen in Städten zu optimieren, wovon auch bestehende Infrastrukturen profitieren können.

Diese Arbeit beschäftigt sich mit der Realisierung einer automatischen Fahrspurerkennung aus Luftaufnahmen, welche bei der Analyse von Spurwechselvorgängen zum Einsatz kommt. Hierzu werden die Trajektoriedaten von Fahrzeugen ausgewertet.

## 1.1 Rahmen der Arbeit

### 1.1.1 Das Projekt MEC-View

### 1.1.2 MEC-View Luftbeobachtung

## 1.2 Motivation und Ziele

## 1.3 Aufbau dieser Arbeit

## 2 Grundlagen

In diesem Kapitel werden die für das Verständnis und die Durchführung der Arbeit benötigten Grundlagenthemen vorgestellt. Nach einer kurzen Erläuterung der Möglichkeiten der Verkehrsanalysen mittels Luftaufnahmen, wird daher darauf eingegangen, auf welche Weise die in dieser Arbeit verwendeten Fahrzeugtrajektorien ermittelt werden. Anschließend werden Methoden vorgestellt, welche zur Bereinigung der gewonnenen Daten verwendet werden können. Als wichtiges Mittel zur Identifizierung von Fahrspuren aus Trajektorien werden zudem verschiedene Cluster-Algorithmen und Distanzmaße vorgestellt.

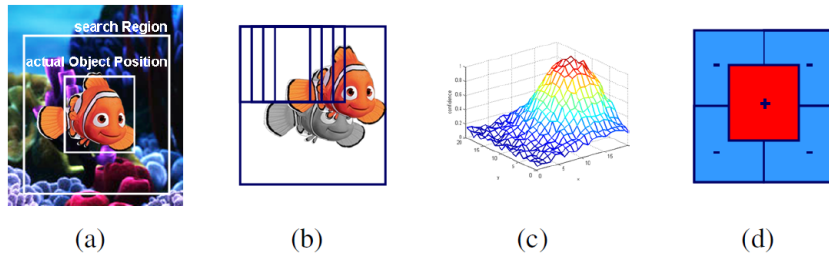
### 2.1 Verkehrsanalyse mittels Luftaufnahmen

### 2.2 Rekonstruktion von Fahrzeugtrajektorien aus Luftaufnahmen

Die in dieser Arbeit verwendeten Fahrzeugtrajektorien stammen aus der Anwendung “Tracker-Application” des MEC-View Teilprojektes *Luftbeobachtung*. Nachfolgend wird beschrieben, wie diese aus den Videoaufnahmen rekonstruiert werden.

Die Verfolgung von bewegten Objekten beziehungsweise Fahrzeugen, wird in der “Tracker-Application” mittels *Supervised Tracking* umgesetzt. Bei diesem Verfahren wird ein initial manuell ausgewählter Bildbereich automatisch mit Hilfe eines erlernten Klassifikators verfolgt. Der Klassifikator muss hierbei zwischen Fahrzeugen und der Umgebung unterscheiden können. Das grundlegende Vorgehen dieses Tracking-Ansatzes ist in Abbildung 2.1 dargestellt und kann wie folgt beschrieben werden:

- a) Verfolgtes Objekt befindet sich zum Zeitpunkt  $t$  an bekannter Position  $p_1$
- b) Zum Zeitpunkt  $t + 1$ : Anwendung des Klassifikators auf Positionen um  $p_1$
- c) Erstellen einer *Confidence Map*, welche die Wahrscheinlichkeit darstellt, das verfolgte Objekt gefunden zu haben
- d) Updaten des Trackers auf Position des Maxima der *Confidence Map*




**Abb. 2.1:** Übersicht Tracking mit Klassifikator [Grabner u. a.]

Das Erlernen eines stabilen Klassifikators in der “Tracker-Application” basiert auf der Arbeit “*Real-Time Tracking via On-line Boosting*” von [Grabner u. a.]. Die Autoren verwenden einen On-line AdaBoost Algorithmus, welcher mehrere *schwache* Klassifikatoren zu einem *starken* Klassifikator kombiniert. Schwache Klassifikatoren müssen hierbei nur eine Erkennungsrate von mehr als 50% besitzen und somit wenig besser als zufallsbedingtes Auswählen sein. Starke Klassifikatoren entstehen durch die Kombination von mehreren schwachen Klassifikatoren. Die Auswahl von schwachen Klassifikatoren erfolgt über sogenannte Selektoren, welche aus einer Menge immer jenen wählen, welcher die geringste Fehlerrate bei der Erkennung der Trainings-Objekte besitzen. Der Klassifikator mit der schlechtesten Erkennungsrate wird in jeder Trainingsiteration ersetzt, um das Training zu verbessern. Großer Vorteil der On-line AdaBoost Methode ist, dass sie es ermöglicht, starke Klassifikatoren während des eigentlichen Trackingvorganges zu erlernen. Nach jedem Trackingschritt wird das erfolgreich erkannte Objekt in Trainingssätze zerlegt, auf welche die Klassifikatoren angewandt werden um ihre Performance zu evaluieren. So wird in jedem Schritt die Menge der schwachen Klassifikatoren und der Selektoren aktualisiert. Die Wahl von effizient berechenbaren schwachen Klassifikatoren macht dies möglich.

Die in [Grabner u. a.] und der “Tracker-Application” verwendeten Klassifikatoren sind binär, das heißt, sie teilen Objekte in die zwei Klassen *erkannt* und *nicht erkannt* auf. Konkret werden Haar-ähnliche Bildmerkmale nach [Viola u. a.] als schwache Klassifikatoren verwendet. Diese sind ein Mittel zur Identifikation von Kontrastunterschieden in Bildern, welche sich sehr gut zur Erkennung von Kanten und Linien eignen. Ein Beispiel der Haar-ähnlichen Merkmale und ihres Einsatzes bei der Gesichtserkennung ist in Abbildung 2.2 dargestellt.

Diese Merkmale werden als schwache Klassifikatoren mit zufälliger Skalierung, Größe und Position auf dem Bild platziert. Sie suchen in dieser Region anschließend nach den von dem Muster definierten Konturunterschieden. Ein Bereich gilt als erkannt, wenn der Betrag der Differenz der Pixelsumme des weißen und schwarzen Bereiches des Musters unter einem festgelegten Grenzwert liegt.



**Abb. 2.2:** a) Haar-ähnliche Merkmale b) Beispiele für erkannte Regionen in einem Gesicht [Divyansh Dwivedi, 2018]

## 2.3 Datenaufbereitung und Bereinigung

## 2.4 Clusteranalyse von Trajektorien

### 2.4.1 Clustering Algorithmen

### 2.4.2 Distanzmaße zum Vergleich von Fahrzeugtrajektorien

## 2.5 Untersuchung möglicher Straßentopologien

## 3 Stand der Technik

3.1 Clustering von Trajektoriedaten

3.2 Erkennung von Fahrspuren

3.3 Klassifizierung von Fahrspuren

3.4 Defizite vorhandener Lösungen und benötigte Neuerungen

## 4 Clustering von Fahrzeugtrajektorien

### 4.1 Vorverarbeitung der Roh-Trajektorien

### 4.2 Gruppierung der Trajektorien

## 5 Fahrbahn-Bestimmung aus Trajektorie-Clustern



## 6 Fahrbahn Klassifizierung

## 7 Realisierung LaneDetection in MEC-View TrackerApplication Software

## 8 Ergebnisse und Auswertung

## 9 Zusammenfassung und Fazit

# Literaturverzeichnis

- [Cookson u. a. ] COOKSON, G ; RESEARCH, B Pishue I. ; FEBRUARY undefined ; 2017 undefined: Inrix global traffic scorecard. In: *jschultheis.de*. – URL [http://jschultheis.de/wp-content/uploads/2018/02/INRIX{}\\_2017{}\\_Traffic{}\\_Scorecard{}\\_Report{}\\_{}\\_{}\\_German.pdf](http://jschultheis.de/wp-content/uploads/2018/02/INRIX{}_2017{}_Traffic{}_Scorecard{}_Report{}_{}_{}_German.pdf)
- [Divyansh Dwivedi 2018] DIVYANSH DWIVEDI: *Face Detection For Beginners – Towards Data Science*. 2018. – URL <https://towardsdatascience.com/face-detection-for-beginners-e58e8f21aad9>. – Zugriffsdatum: 2018-10-18
- [Grabner u. a. ] GRABNER, H ; GRABNER, M ; BMVC, H B. ; 2006 undefined: Real-time tracking via on-line boosting. In: *grabner.family*. – URL <http://grabner.family/helmut/papers/Grabner2006RealTimeTracking.pdf>
- [Hemmerle 2016] HEMMERLE, P: Empirische physikalische Eigenschaften des übersättigten innerstädtischen Verkehrs und Energieeffizienz von Fahrzeugen. (2016). – URL <https://d-nb.info/1122559259/34>
- [Viola u. a. ] VIOLA, P ; RECOGNITION, M Jones V. ; PATTERN ; CVPR, 2001. ; 2001 undefined: Rapid object detection using a boosted cascade of simple features. In: *ieeexplore.ieee.org*. – URL <https://ieeexplore.ieee.org/abstract/document/990517/>